



В кого стрелять?

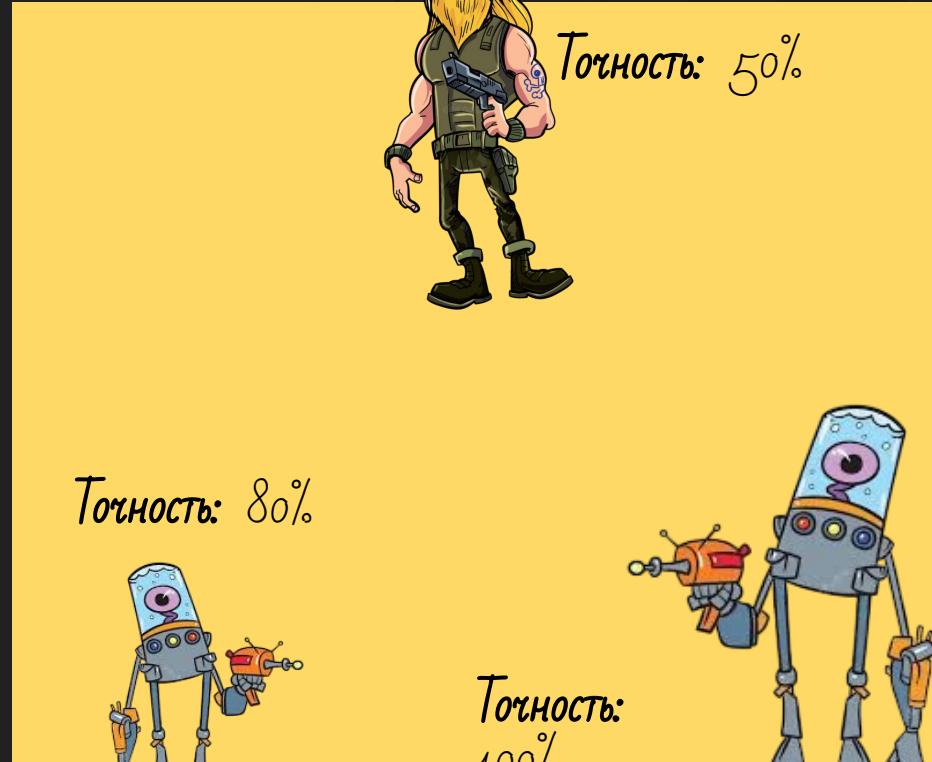
otus

# RL 1-03

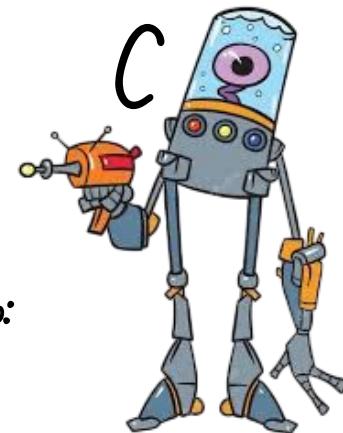
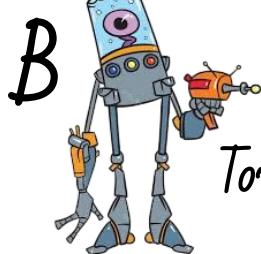
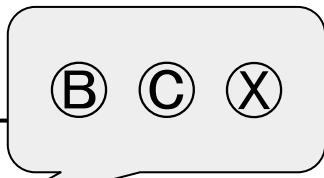
Value Iteration

Начнем в 20:01

otus.ru



# Что будем делать?



# Дисклеймер

---

## Занятие «Основные алгоритмы RL: Value based»

### Цели занятия

познакомиться с основными алгоритмами, используемыми в обучении с подкреплением;  
понять, что такое v-функция и q-функция;

[Показать еще](#)

### Краткое содержание

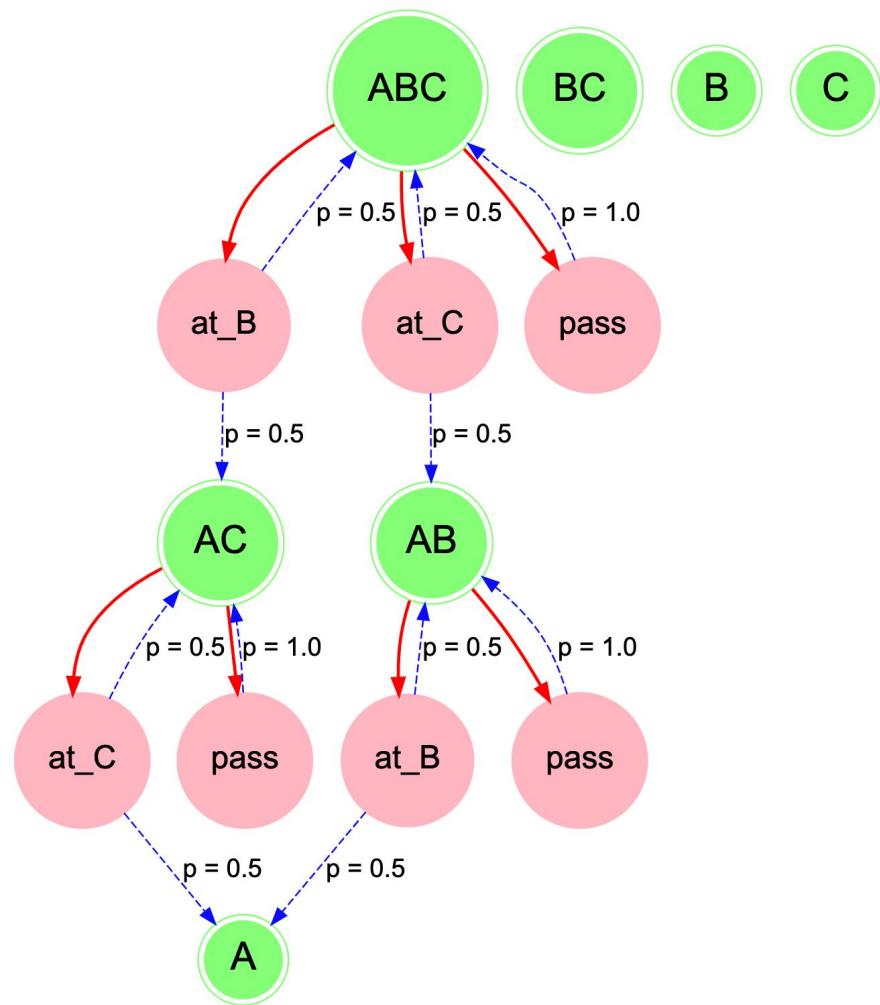
v-функция и q-функция;  
уравнение Беллмана;  
алгоритмы группы Value-based: SARSA, Q-learning.

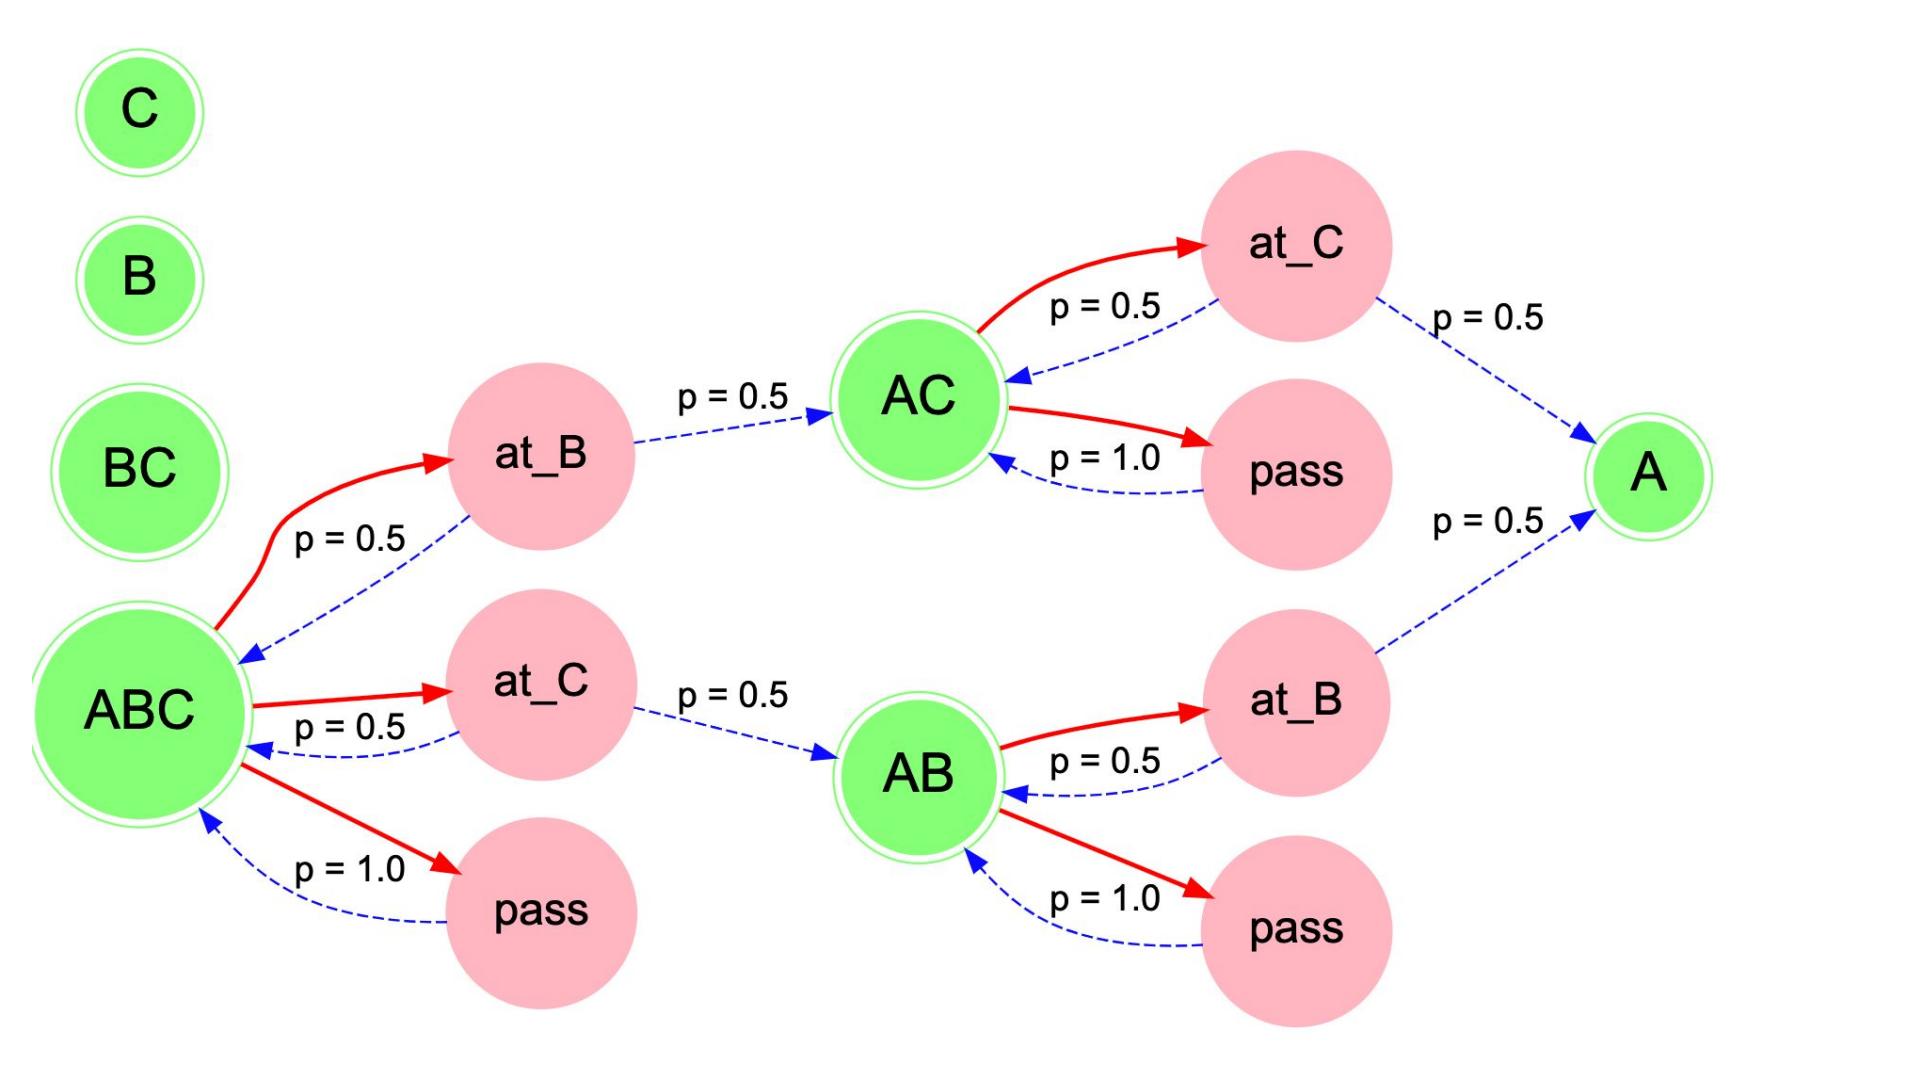
[Свернуть](#)

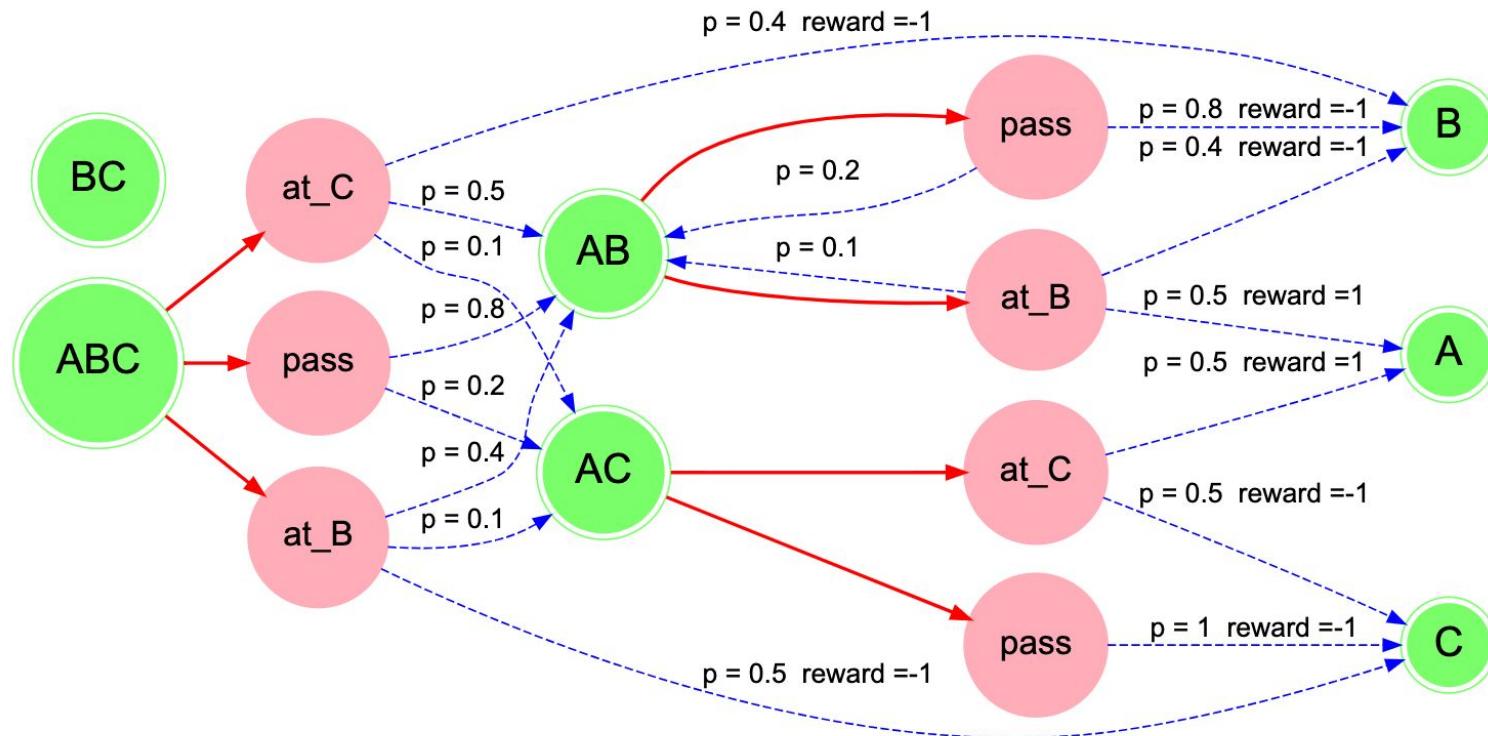
### Результаты

конспект занятия;  
ноутбук с кодом класса агента, реализующего алгоритм q-learning и мониторинг процесса обучения;  
ответы на вопросы.

[Свернуть](#)



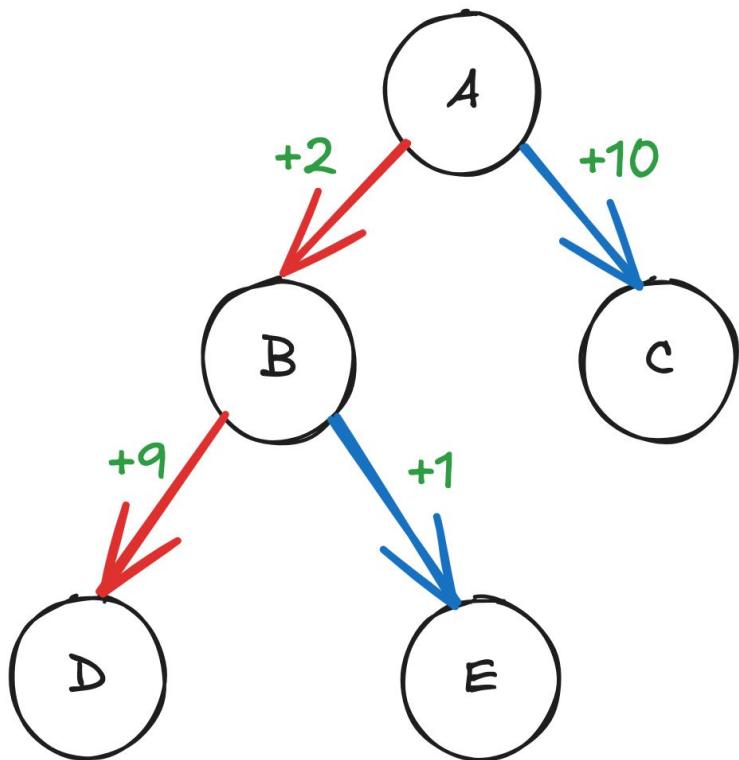




*Value function*

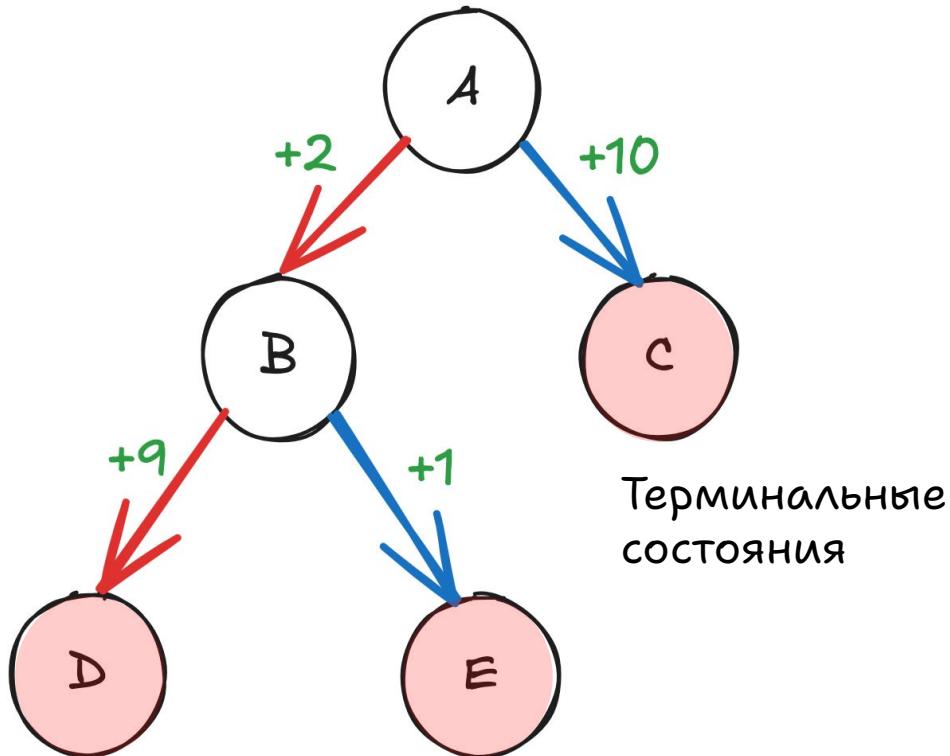
# Детерминированная MDP

---



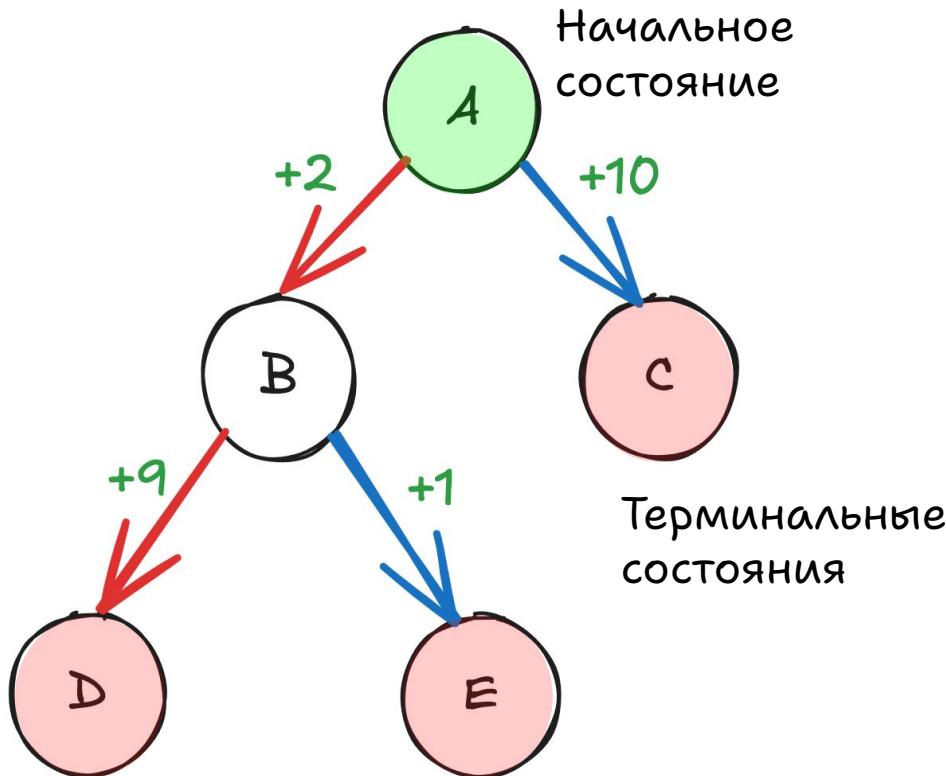
# Детерминированная MDP

---



# Детерминированная MDP

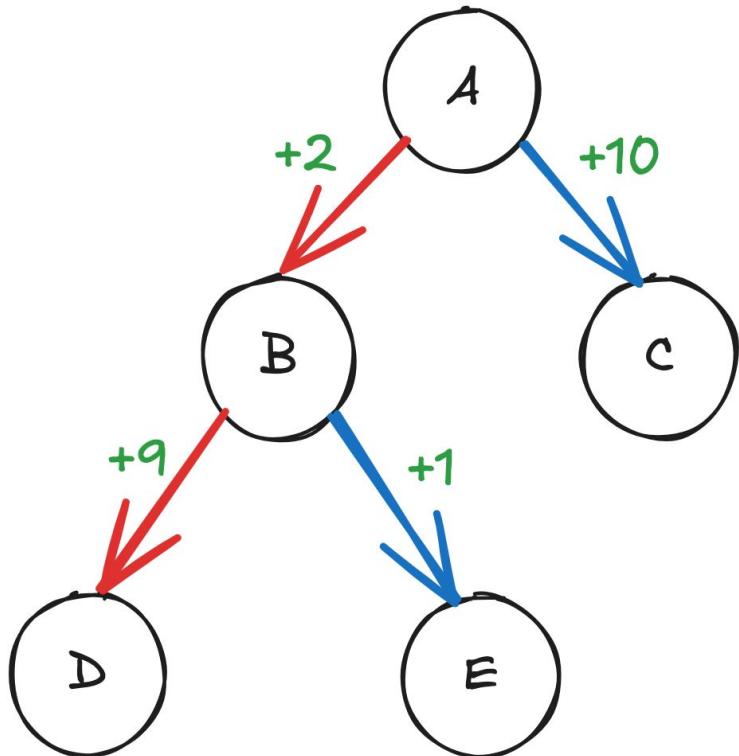
---



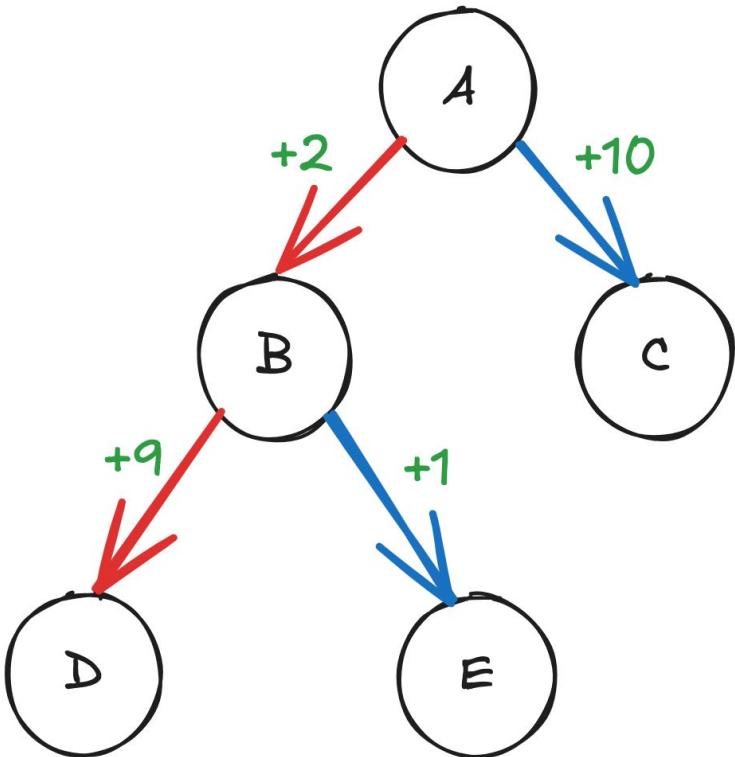
# Детерминированная MDP

---

Какая цель?



# Детерминированная MDP



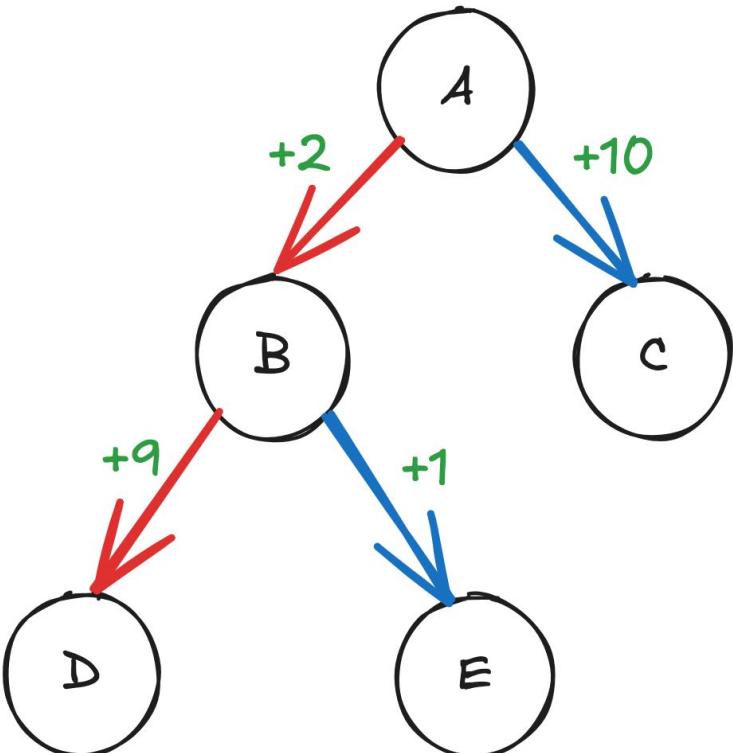
Какая цель?

Найти политику  $\pi$ , чтобы максимизировать сумму наград

$$\sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

# Детерминированная MDP

---

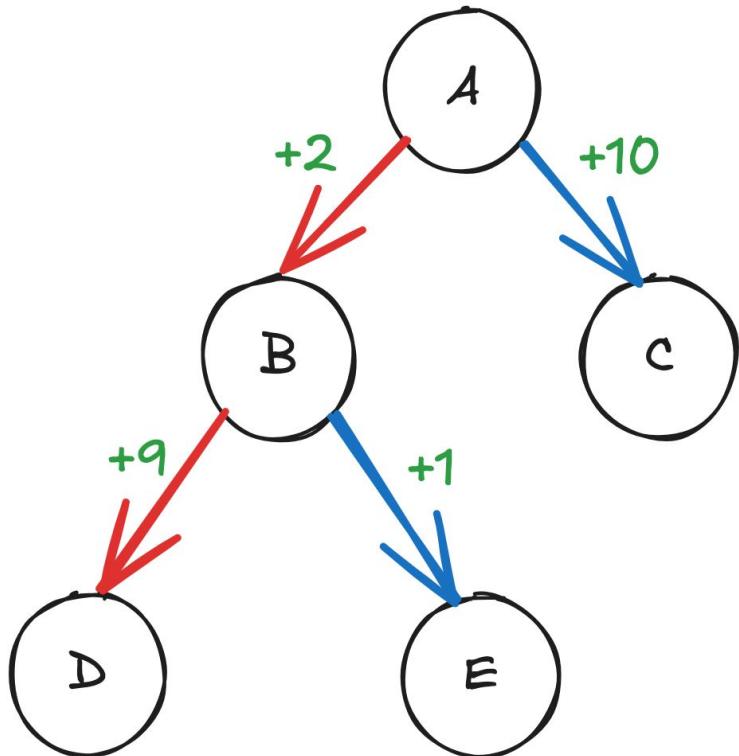


$$R(\pi) = \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

# Детерминированная MDP

---



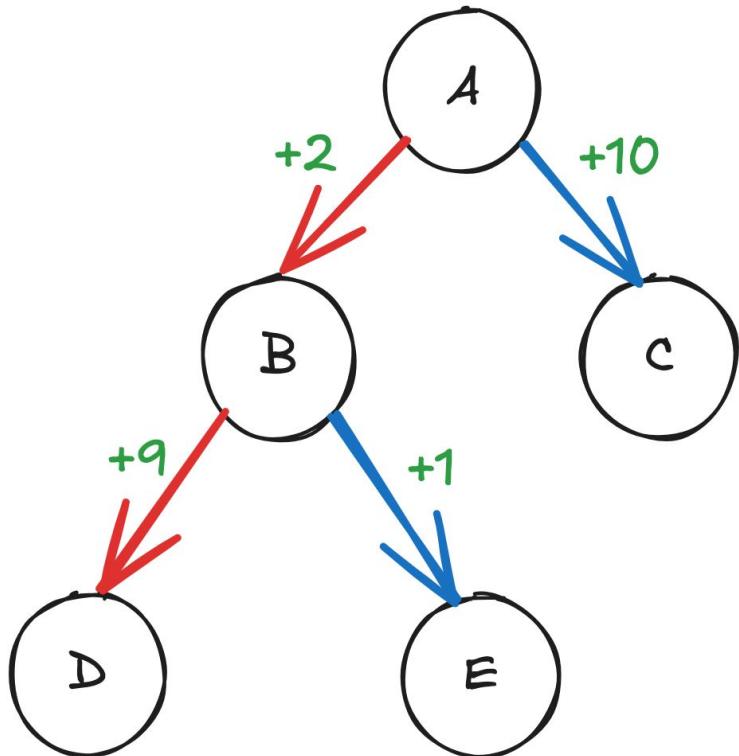
$$R(\pi) = \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$\rho_1 = \{ \begin{array}{l} A: \text{red} \\ B: \text{red} \end{array} \}$$

# Детерминированная MDP

---



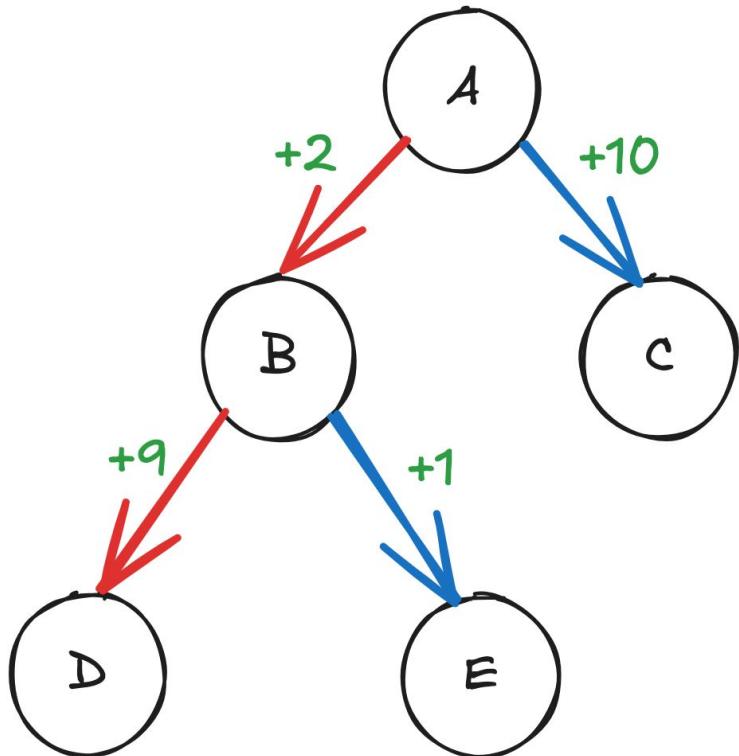
$$R(\pi) = \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$\rho_1 = \{ \begin{array}{l} A: \text{red} \\ B: \text{red} \end{array} \}$$

$$\rho_2 = \{ \begin{array}{l} A: \text{red} \\ B: \text{blue} \end{array} \}$$

# Детерминированная MDP



$$R(\pi) = \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$\rho_1 = \{$$

A: red  
B: red

$$\}$$

$$\rho_2 = \{$$

A: red  
B: blue

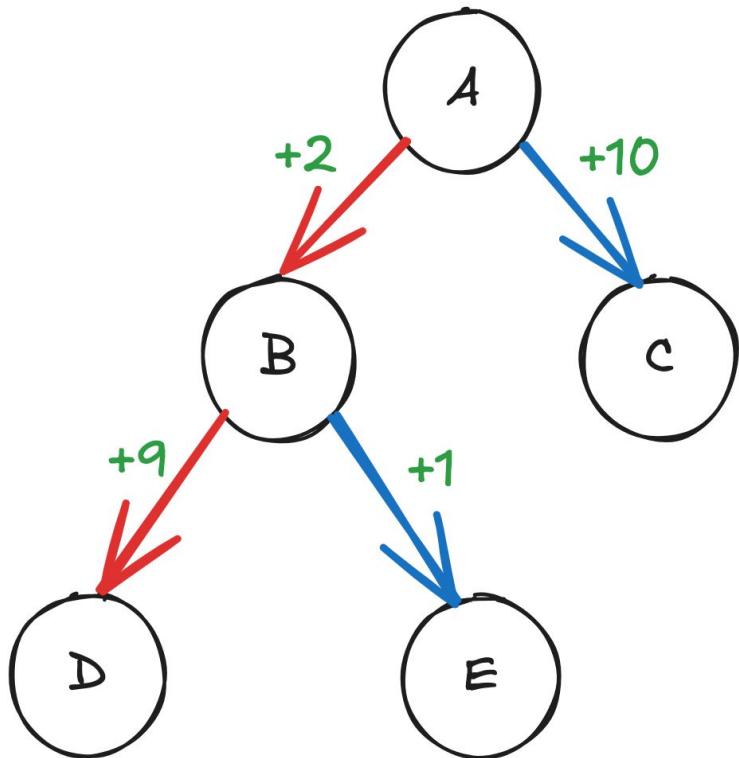
$$\}$$

$$\rho_3 = \{$$

A: blue

$$\}$$

# Детерминированная MDP



$$R(\pi) = \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$\rho_1 = \{$$

A: red  
B: red

$$\}$$

$$\rho_3 = \{$$

A: blue

$$\}$$

$$\rho_4 = \{$$

A: {  
B: {

blue: 0.2  
red: 0.8

$$\}}$$

$$\rho_4 = \{$$

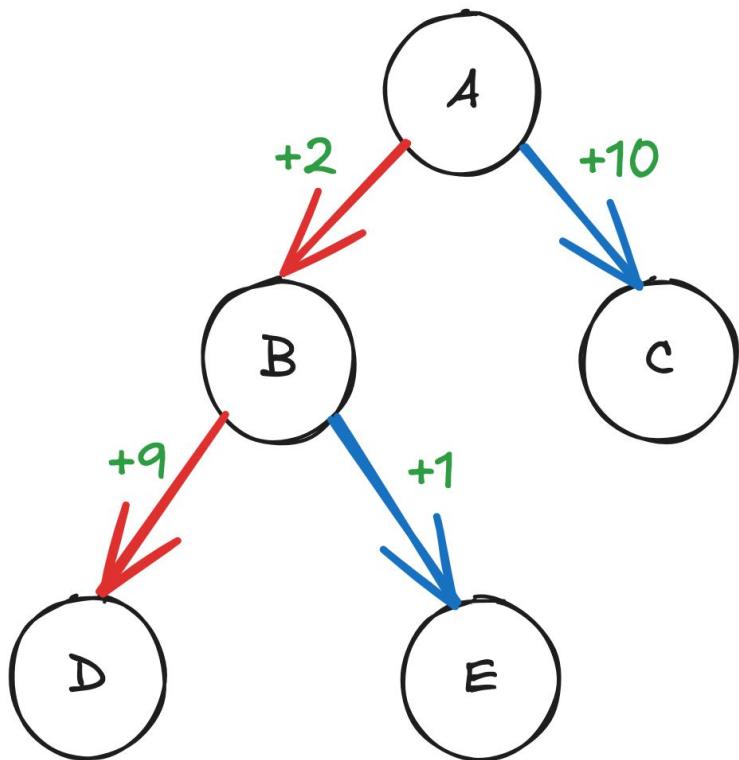
B: {  
C: {

blue: 0.5  
red: 0.5

$$\}}$$

...

# Детерминированная MDP



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$\rho_1 = \{$$

A: red  
B: red

$$\}$$

$$\rho_4 = \{$$

A: {  
    color:blue} blue: 0.2  
    color:red} red: 0.8

$$\}$$

$$\rho_3 = \{$$

A: blue

$$\}$$

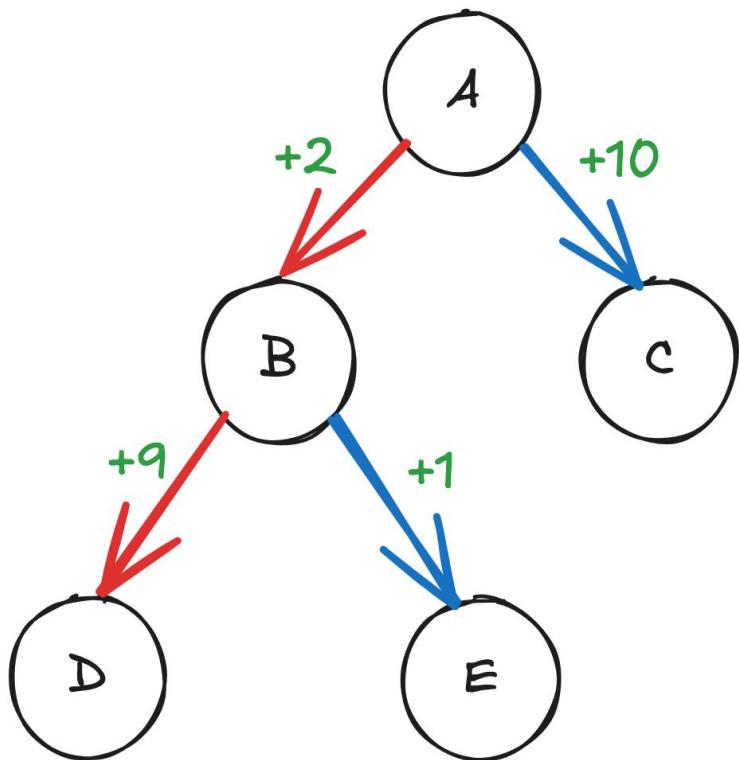
$$\rho_2 = \{$$

B: {  
    color:blue} blue: 0.5  
    color:red} red: 0.5

$$\}$$

...

# Детерминированная MDP



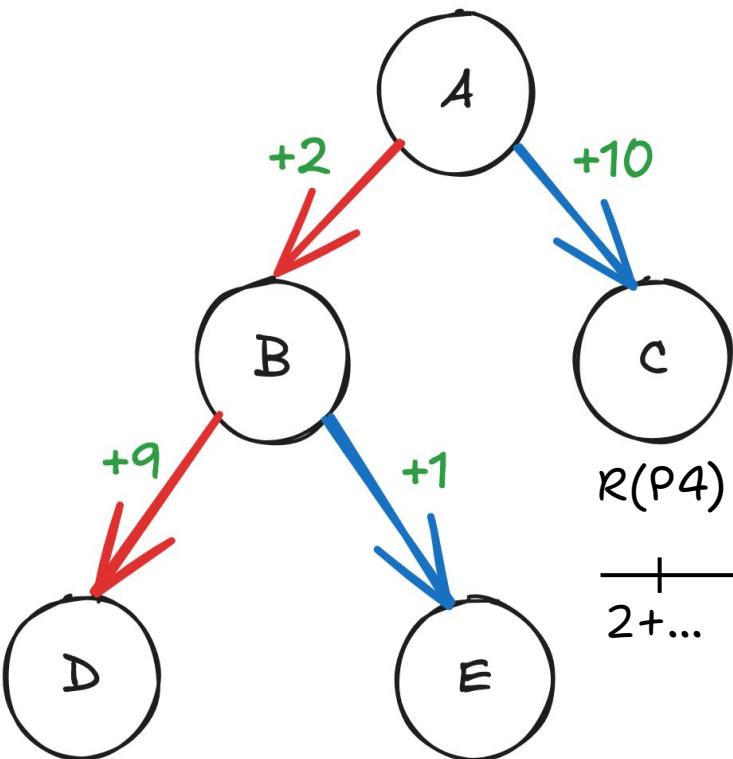
$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$R(\pi) = ?$$

$\rho_A = \{$   
A: {  
    blue: 0.2  
    red: 0.8  
}  
B: {  
    blue: 0.5  
    red: 0.5  
}  
}  
...

# Детерминированная MDP



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$\rho_4 = \{$$

A: {  
blue: 0.2  
red: 0.8}

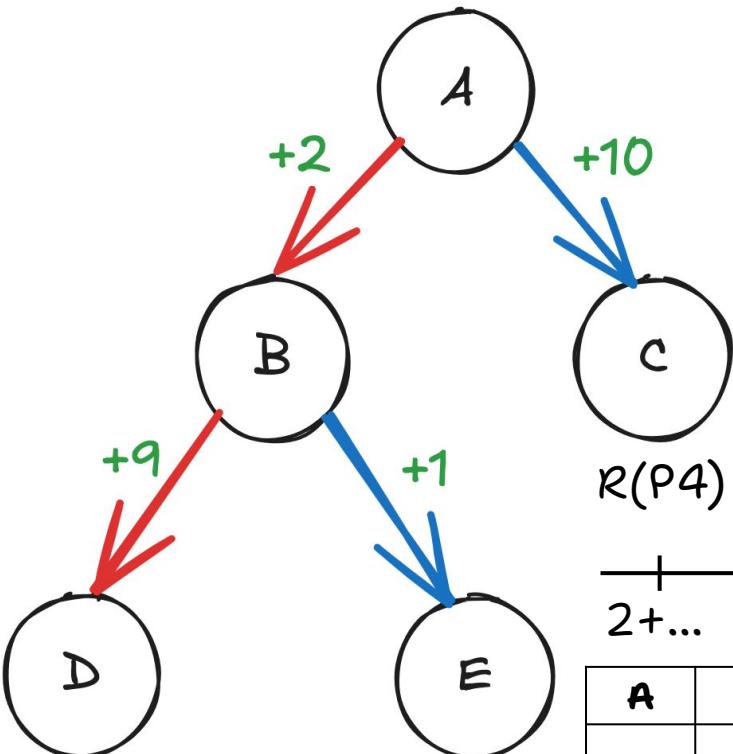
B: {  
blue: 0.5  
red: 0.5}

}  
...

$$R(\rho_4) = 0.2 * 10 + 0.8 * _-$$

—  
2+...

# Детерминированная MDP



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

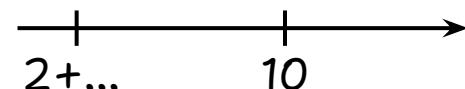
Какие политики есть?

$$\rho_4 = \{$$

A: {  
blue: 0.2  
red: 0.8}

B: {  
blue: 0.5  
red: 0.5}

$$R(\rho_4) = 0.2 * 10 + 0.8 * _-$$

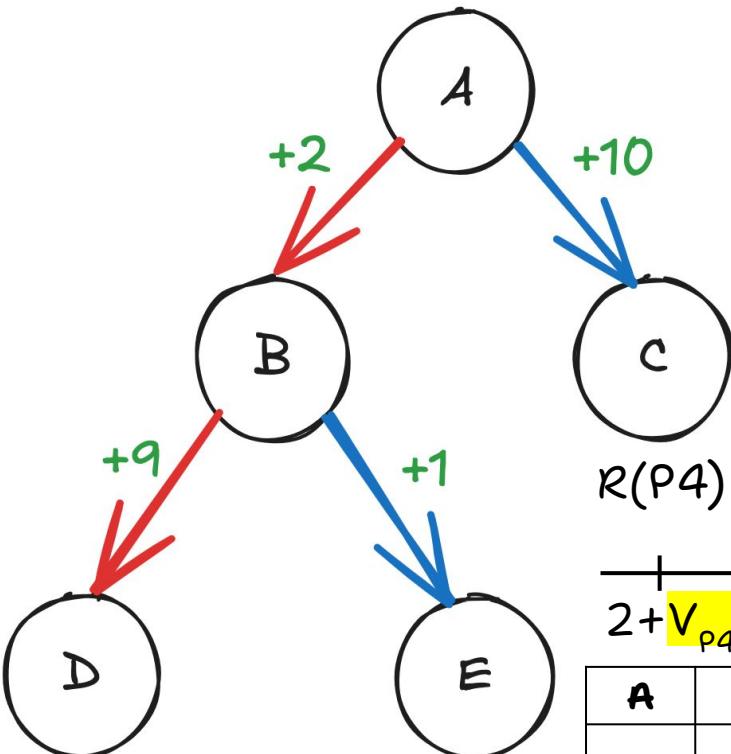


A	B	C	D	E

}

...

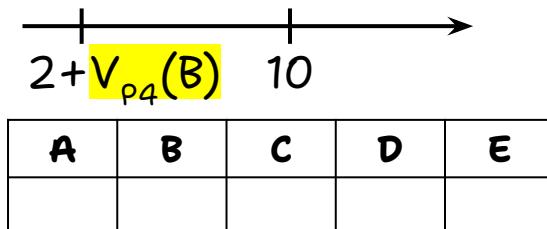
# Value-функция



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$R(P4) = 0.2 * 10 + 0.8 * _$$



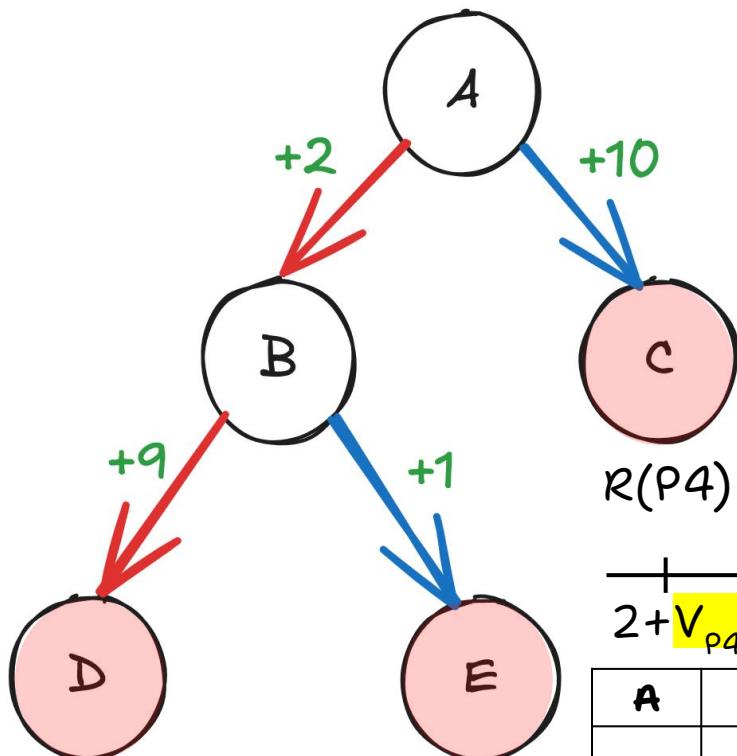
$$P4 = \{$$

A: {  
    blue: 0.2  
    red: 0.8  
}

B: {  
    blue: 0.5  
    red: 0.5  
}

...  
}

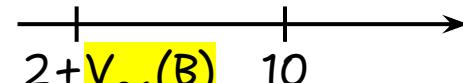
# Value-функция



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$R(P4) = 0.2 * 10 + 0.8 * _$$

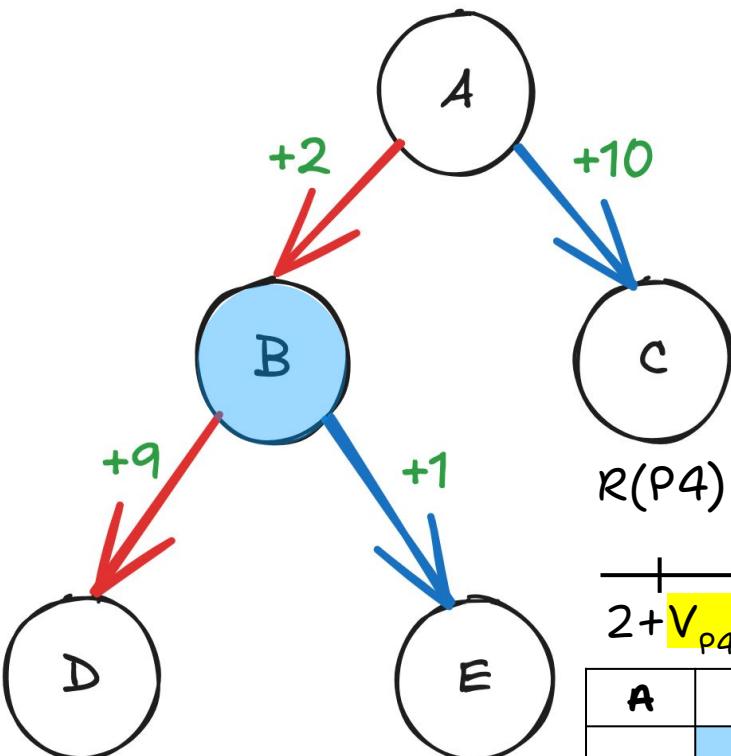


A	B	C	D	E
		0	0	0

$P4 = \{$   
A: {  
blue: 0.2  
red: 0.8  
}

B: {  
blue: 0.5  
red: 0.5  
}  
}  
...

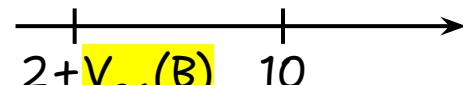
# Value-функция



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$R(P_4) = 0.2 * 10 + 0.8 * -$$

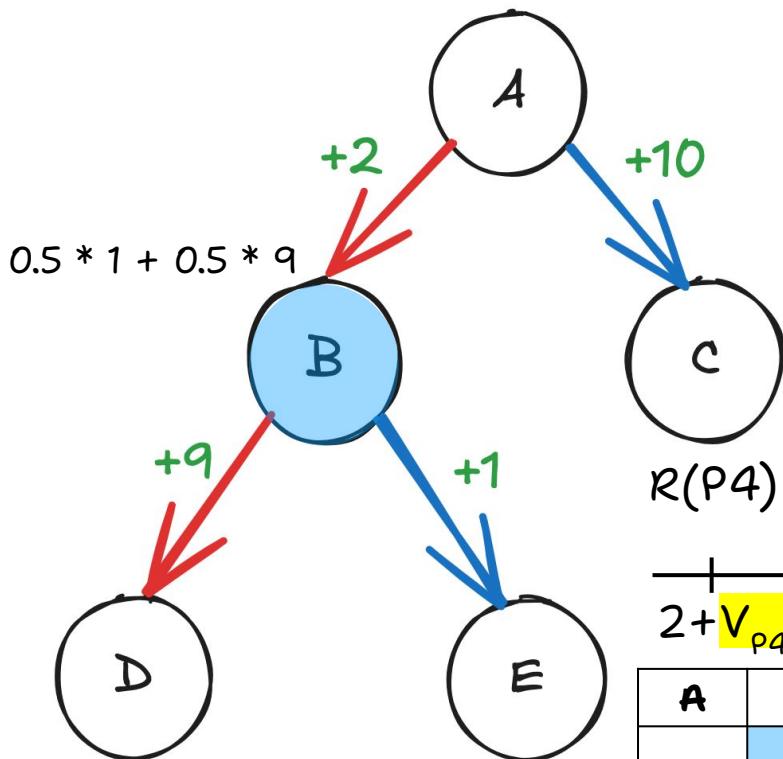


A	B	C	D	E
		0	0	0

$P_4 = \{$   
A: {  
    blue: 0.2  
    red: 0.8  
}

B: {  
    blue: 0.5  
    red: 0.5  
}  
}  
...

# Value-функция



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

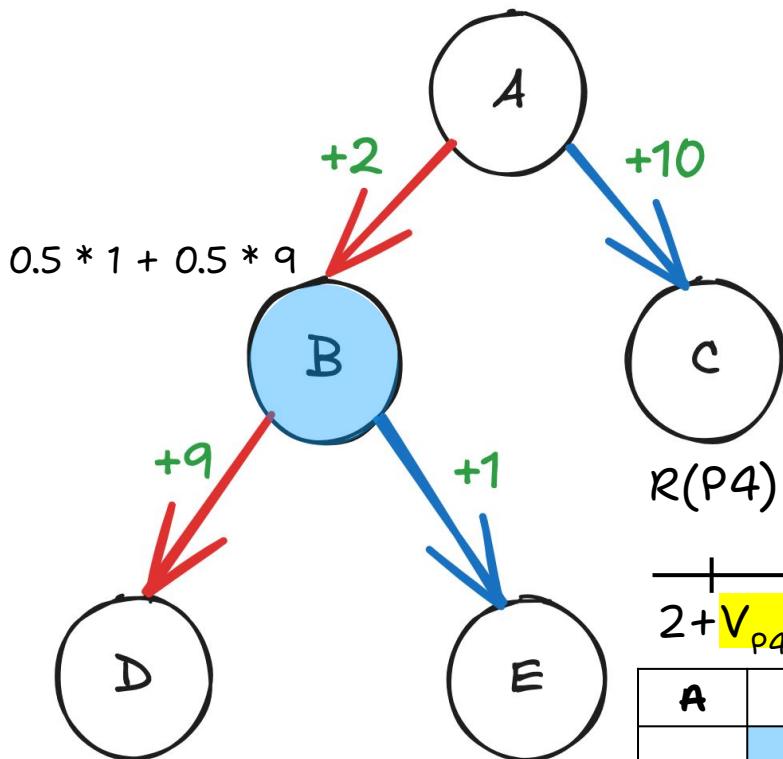
$$R(P_4) = 0.2 * 10 + 0.8 * -$$



A	B	C	D	E
		0	0	0

$P_4 = \{$   
A: {  
    blue: 0.2  
    red: 0.8  
}  
B: {  
    blue: 0.5  
    red: 0.5  
}  
}  
...

# Value-функция



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

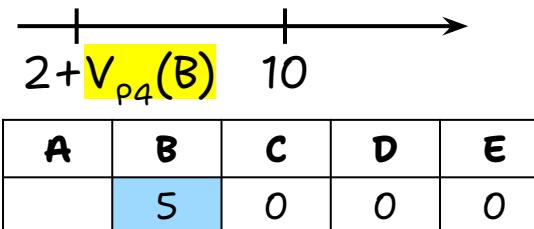
Какие политики есть?

$$\rho_4 = \{$$

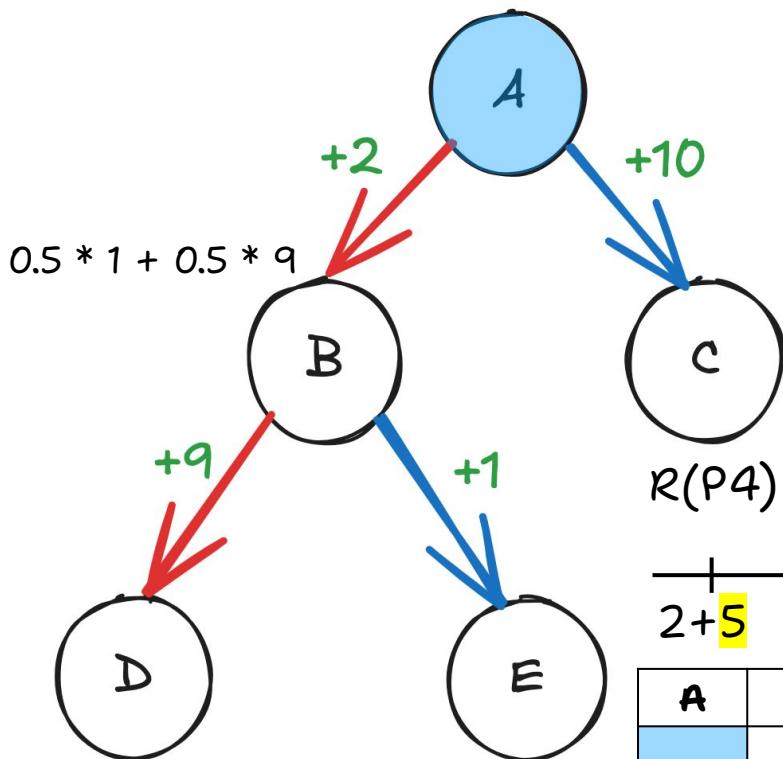
A: {  
    blue: 0.2  
    red: 0.8  
}}

B: {  
    blue: 0.5  
    red: 0.5  
}  
}  
...

$$R(\rho_4) = 0.2 * 10 + 0.8 * -$$



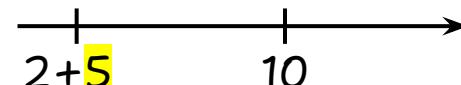
# Value-функция



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?

$$R(P4) = 0.2 * 10 + 0.8 * 7$$



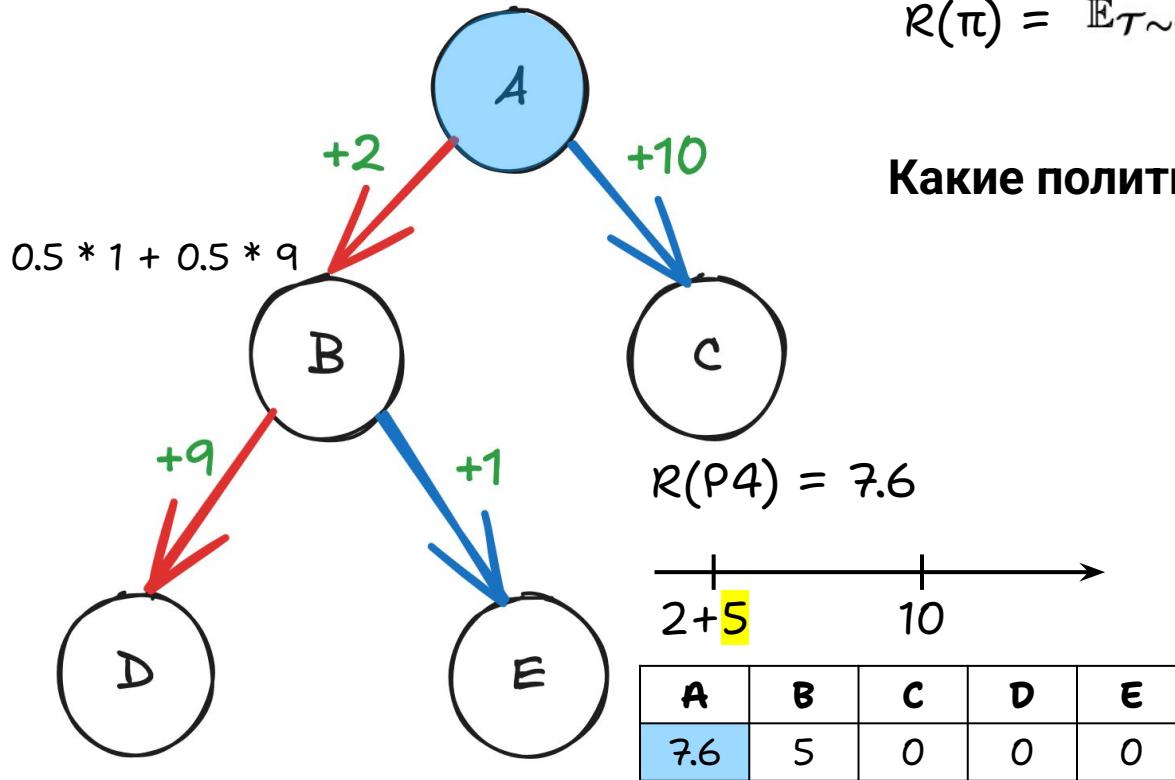
A	B	C	D	E
5	0	0	0	0

P4 = {  
A: {  
    blue: 0.2  
    red: 0.8  
}  
B: {  
    blue: 0.5  
    red: 0.5  
}  
}  
...  
}

# Value-функция

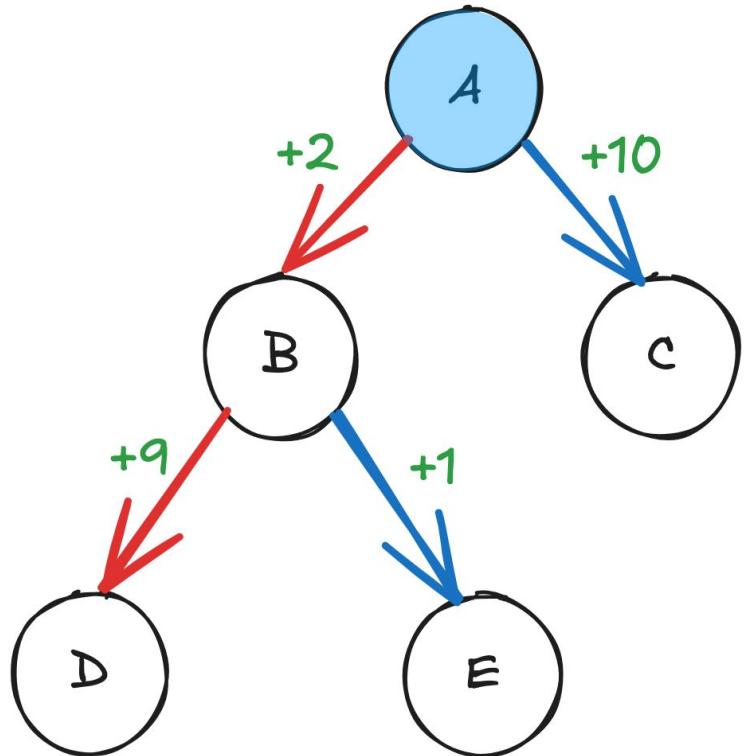
$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

Какие политики есть?



$P4 = \{$   
A: {  
    blue: 0.2  
    red: 0.8  
}  
B: {  
    blue: 0.5  
    red: 0.5  
}  
}  
...  
}

# Какую политику назовем жадной?



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

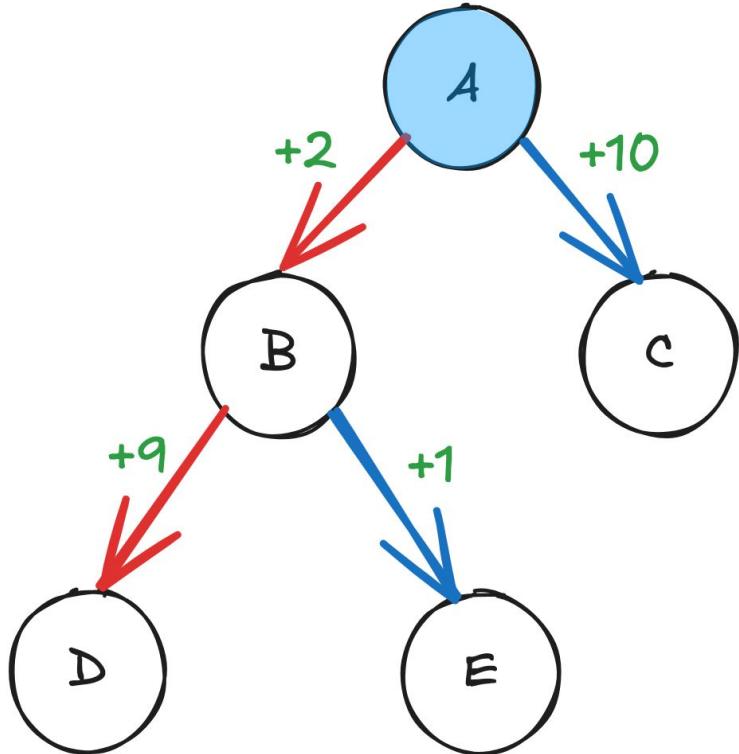
$\rho_1 = \{$   
A: red  
B: red  
 $\}$

$\rho_3 = \{$   
A: blue  
 $\}$

$\rho_2 = \{$   
A: red  
B: blue  
 $\}$

$\rho_4 = \{$   
A: {  
blue: 0.2  
red: 0.8  
}  
B: {  
blue: 0.5  
red: 0.5  
}

# Какую политику назовем жадной?



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

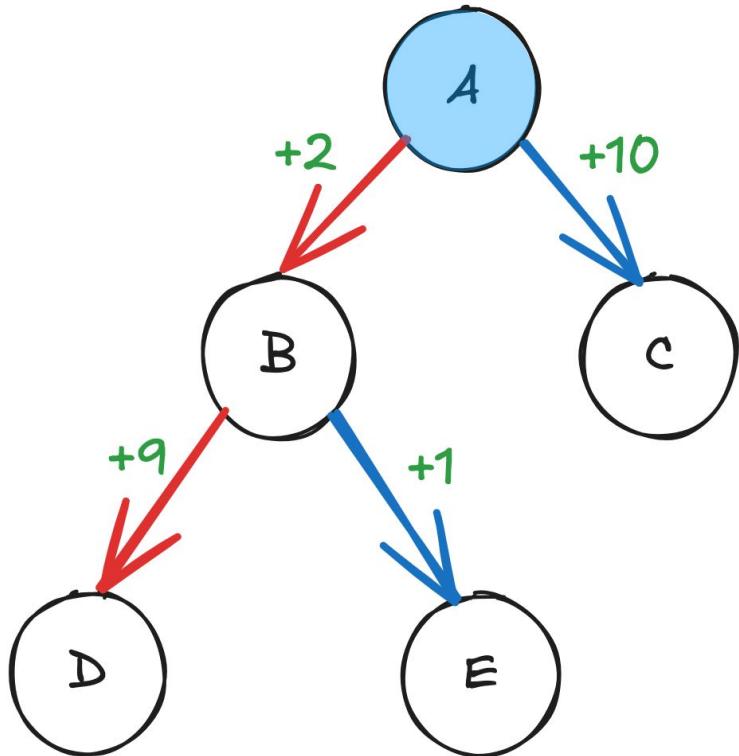
$P_1 = \{$   
A: red  
B: red  
 $\}$

$P_3 = \{$   
A: blue  
 $\}$

$P_2 = \{$   
A: red  
B: blue  
 $\}$

$P_4 = \{$   
A: {  
blue: 0.2  
red: 0.8  
}  
B: {  
blue: 0.5  
red: 0.5  
}

# Какую политику назовем оптимальной?



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

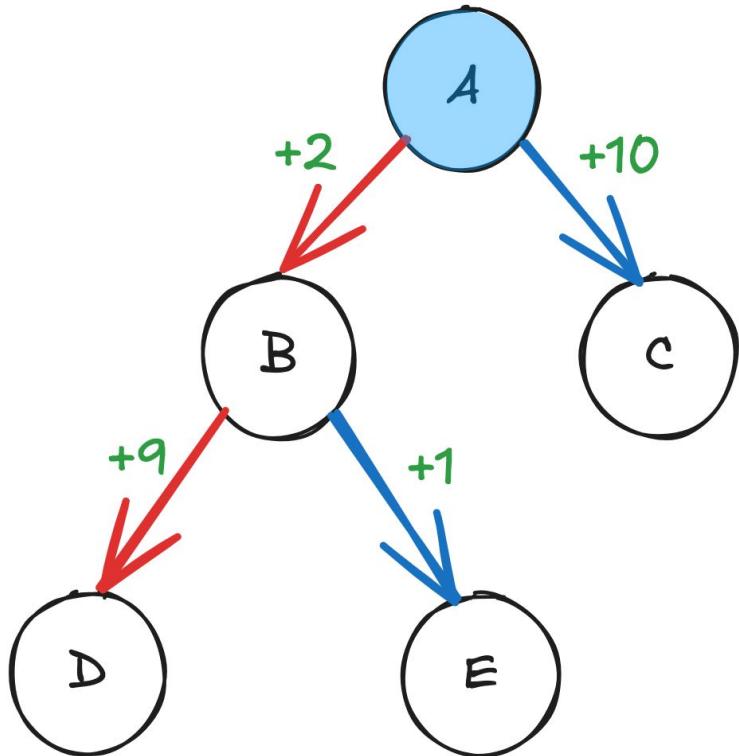
$\rho_1 = \{$   
    A: red  
    B: red  
 $\}$

$\rho_3 = \{$   
    A: blue  
 $\}$

$\rho_2 = \{$   
    A: red  
    B: blue  
 $\}$

$\rho_4 = \{$   
    A: {  
        blue: 0.2  
        red: 0.8  
    }  
    B: {  
        blue: 0.5  
        red: 0.5  
    }  
 $\}$

# Какую политику назовем оптимальной?



$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

$\rho_1 = \{$   
A: red  
B: red  
 $\}$

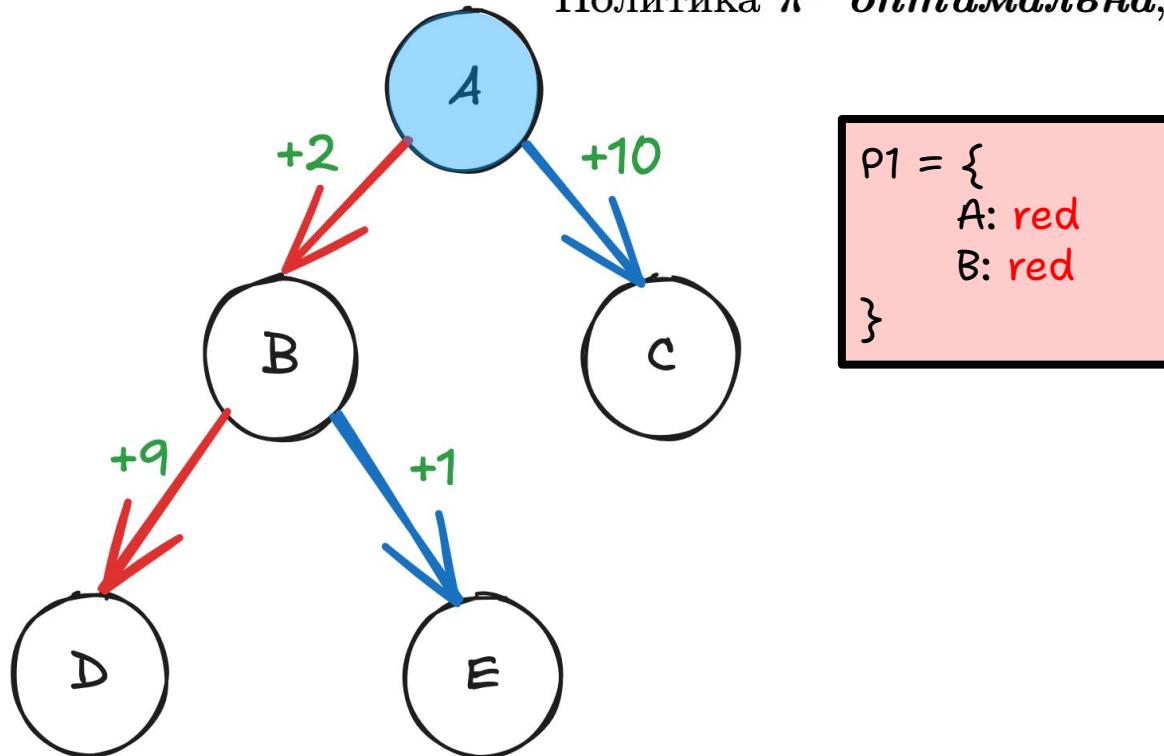
$\rho_3 = \{$   
A: blue  
 $\}$

$\rho_2 = \{$   
A: red  
B: blue  
 $\}$

$\rho_4 = \{$   
A: {  
blue: 0.2  
red: 0.8  
}  
B: {  
blue: 0.5  
red: 0.5  
}

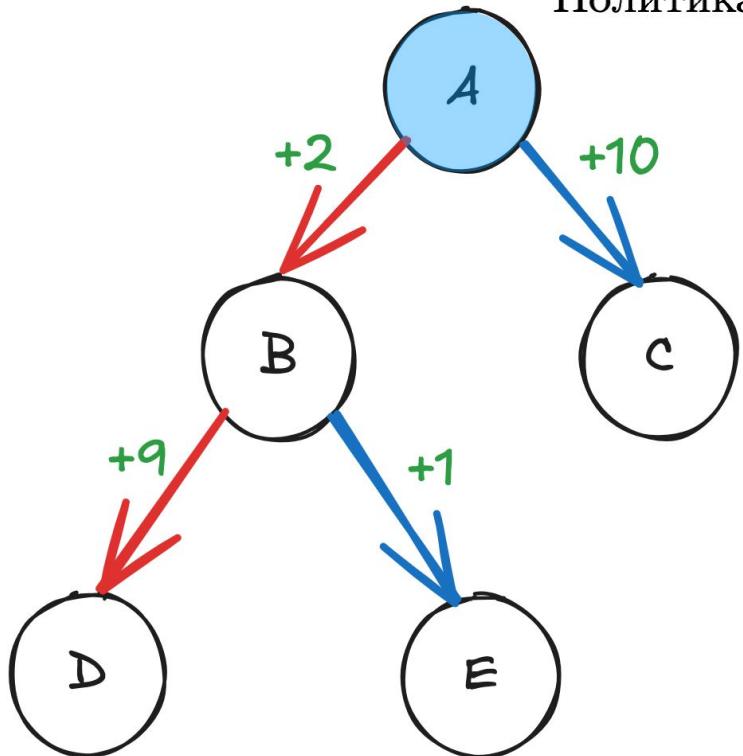
# Оптимальная политика

Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



# Value-функция

Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P1 = \{$   
A: red  
B: red  
 $\}$

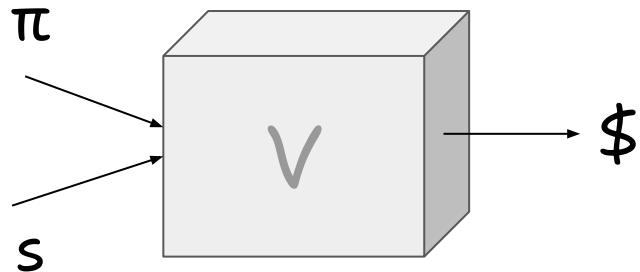
Сколько мы можем заработать, стартуя из данной вершины

$$V^\pi(s) := \mathbb{E}_{\mathcal{T} \sim \pi | s_0 = s} R(\mathcal{T})$$

Value-функция  
(оценочная функция)

# Value-функция

Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P1 = \{$   
A: red  
B: red  
 $\}$

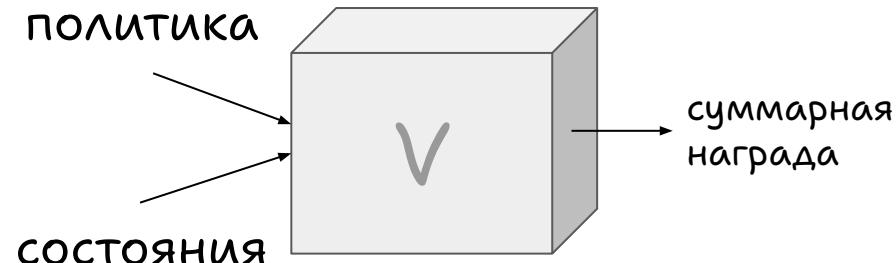
Сколько мы можем  
заработать, стартуя из  
данной вершины

$$V^\pi(s) := \mathbb{E}_{\mathcal{T} \sim \pi | s_0 = s} R(\mathcal{T})$$

Value-функция  
(оценочная функция)

# Value-функция

Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P1 = \{$   
A: red  
B: red  
 $\}$

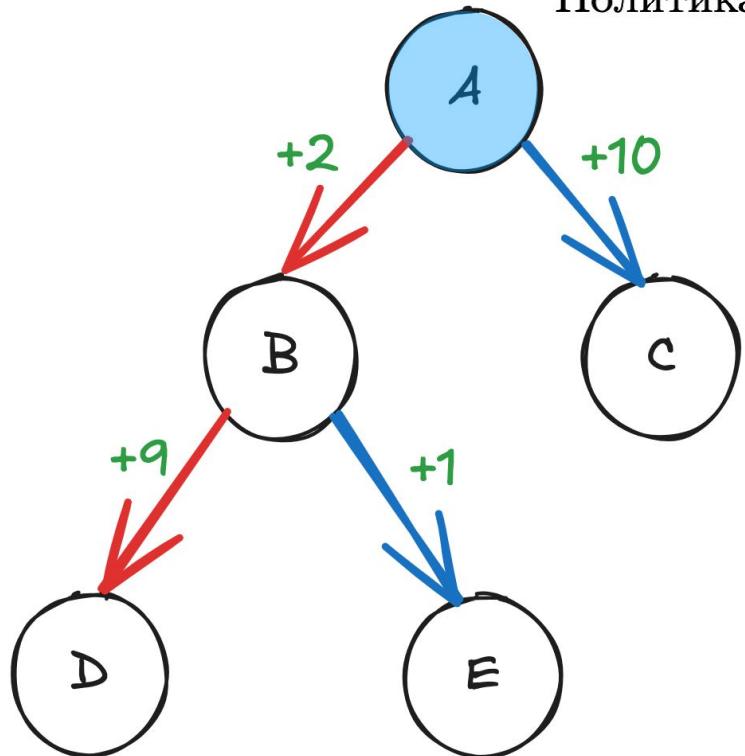
↓  
Сколько мы можем заработать, стартуя из данной вершины

$$V^\pi(s) := \mathbb{E}_{\mathcal{T} \sim \pi | s_0 = s} R(\mathcal{T})$$

Value-функция  
(оценочная функция)

# Value-функция

Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$

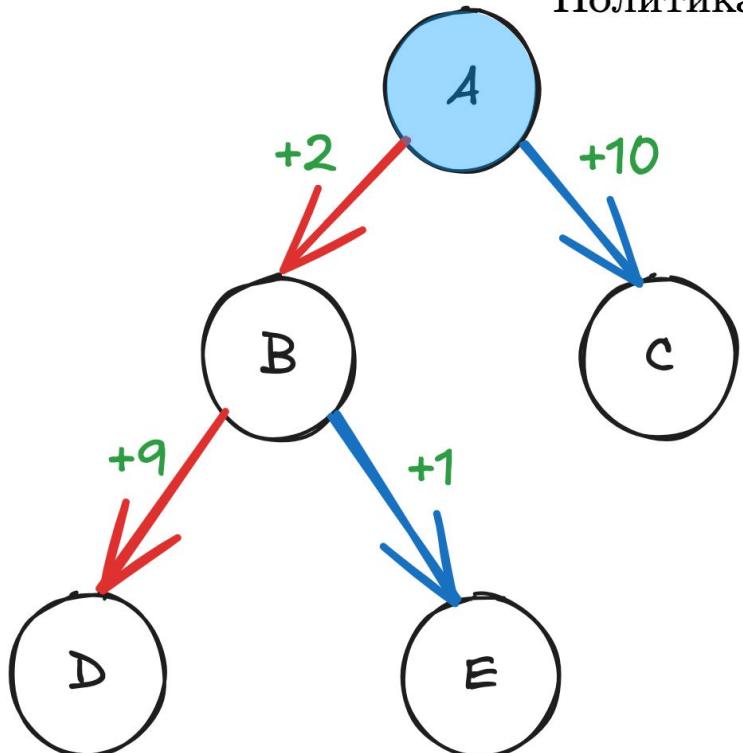


$P1 = \{$   
A: red  
B: red  
 $\}$

Как докажем?

# Оптимальная value-функция

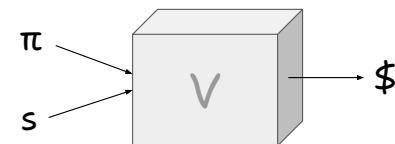
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$$\rho_1 = \{ \begin{array}{l} A: \text{red} \\ B: \text{red} \end{array} \}$$

$$V^* = V^{\pi^*}$$

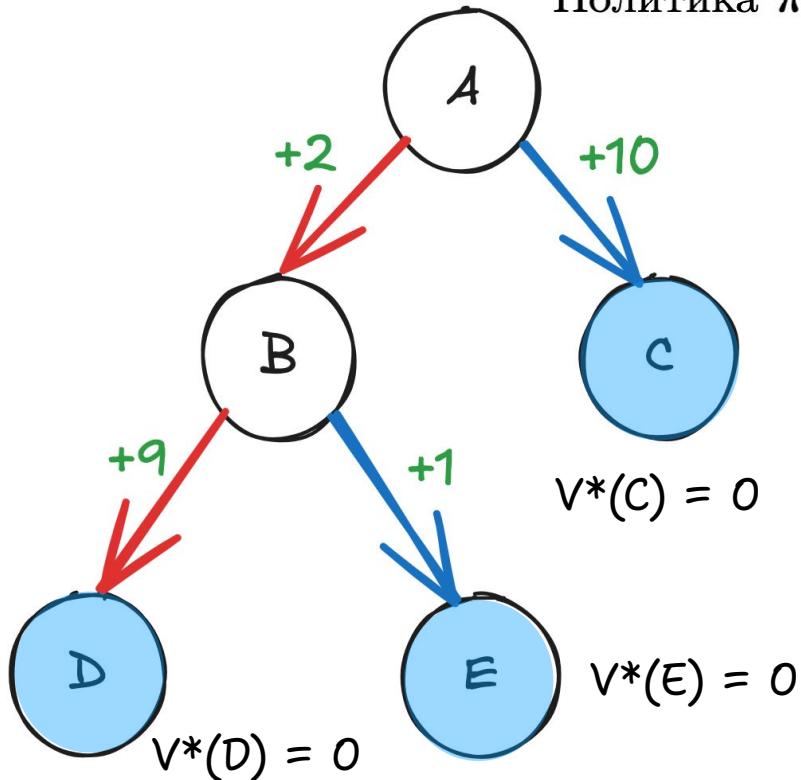
Как докажем?



# Оптимальная value-функция

A	B	C	D	E
		0	0	0

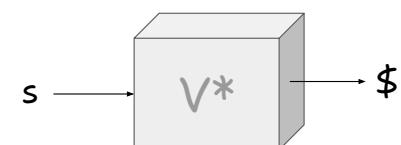
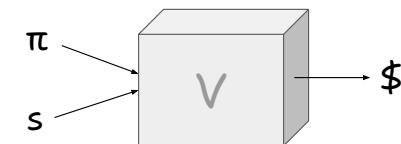
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P_1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

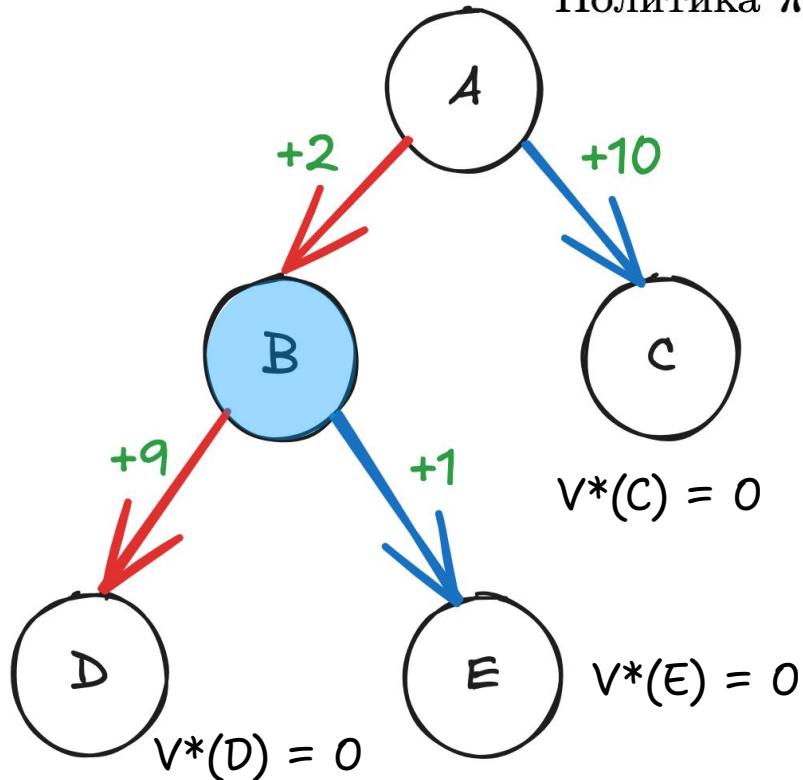
Как докажем?



# Оптимальная value-функция

A	B	C	D	E
		0	0	0

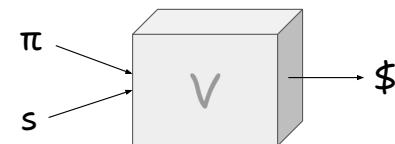
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P_1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

Как докажем?

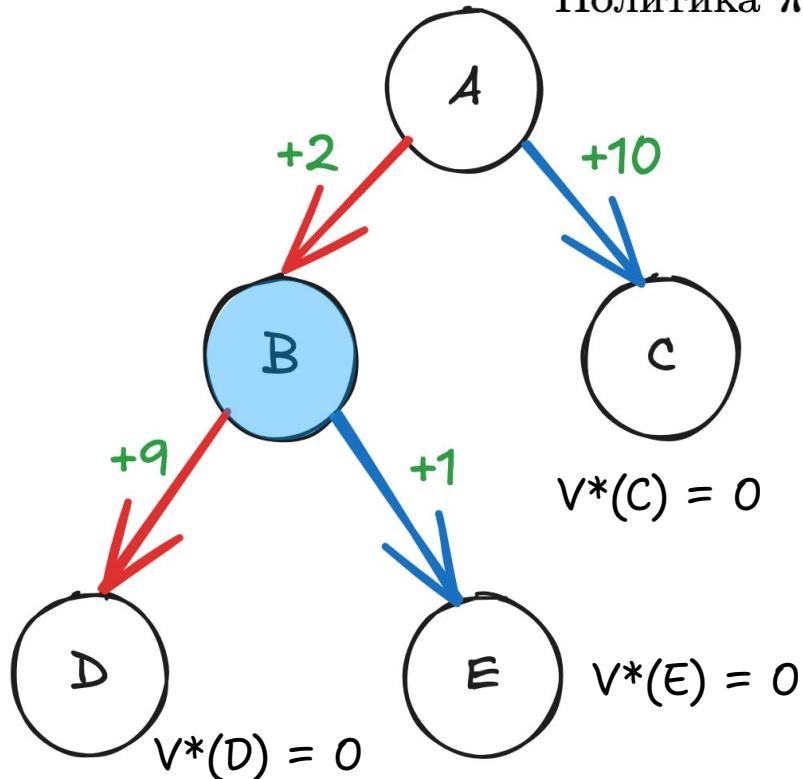


$$V^*(B) =$$

# Оптимальная value-функция

A	B	C	D	E
		0	0	0

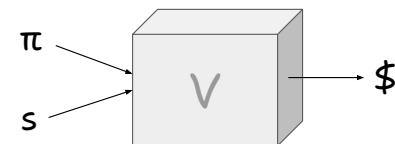
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

Как докажем?

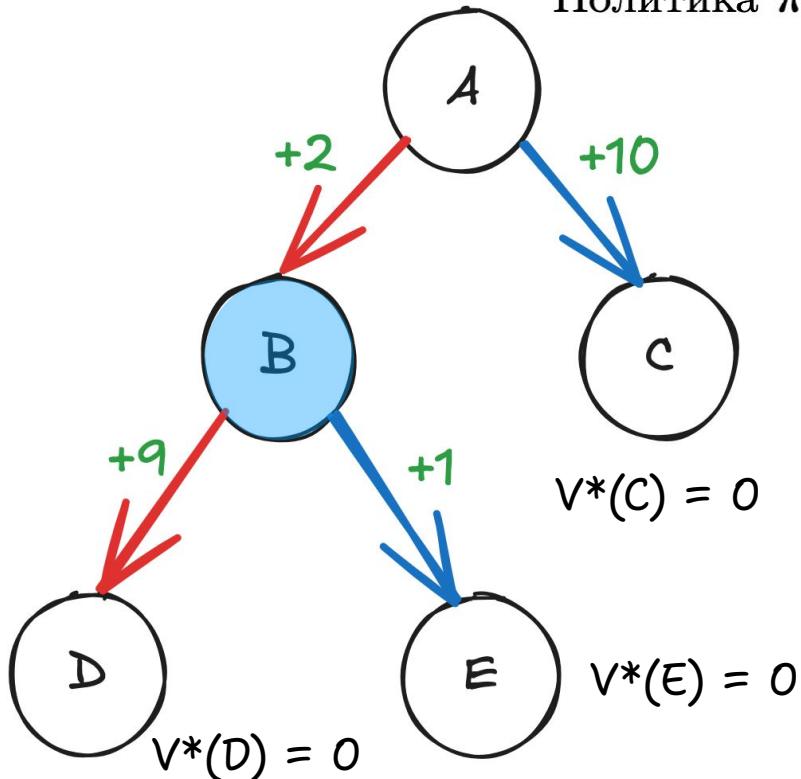


$$V^*(B) = \max(9 + V^*(D), 1 + V^*(E))$$

# Оптимальная value-функция

A	B	C	D	E
	9	0	0	0

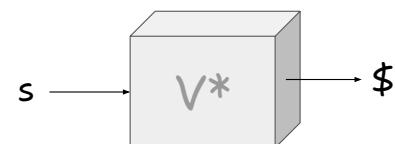
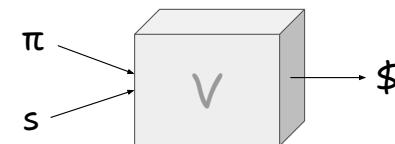
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

Как докажем?

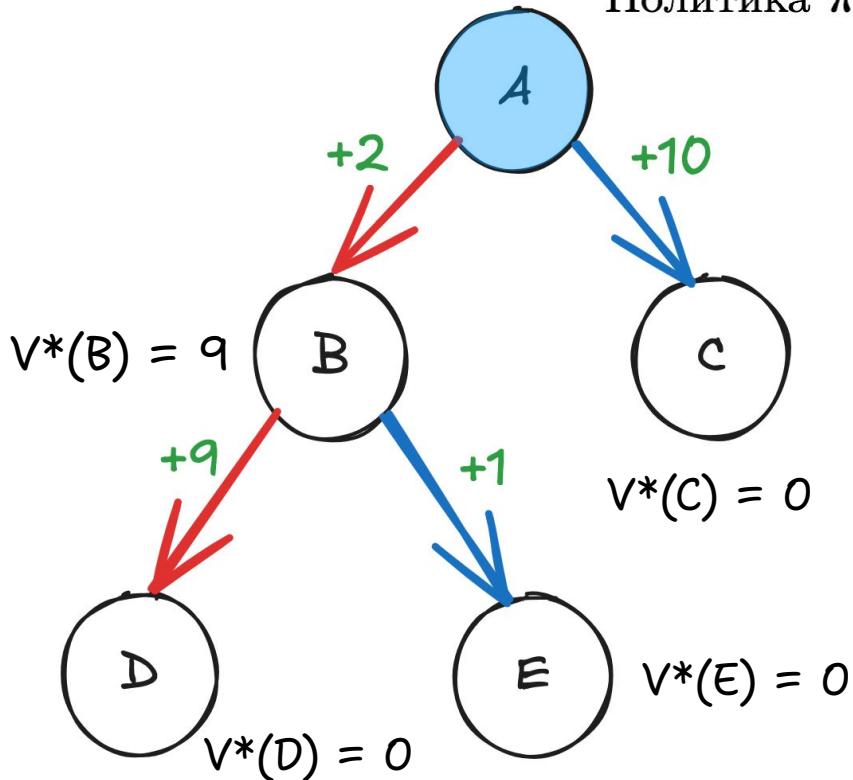


$$V^*(B) = \max(9 + 0, 1 + 0)$$

# Оптимальная value-функция

A	B	C	D	E
	9	0	0	0

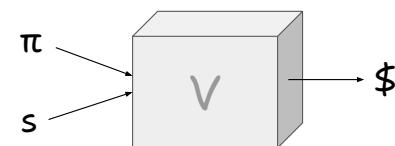
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P_1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

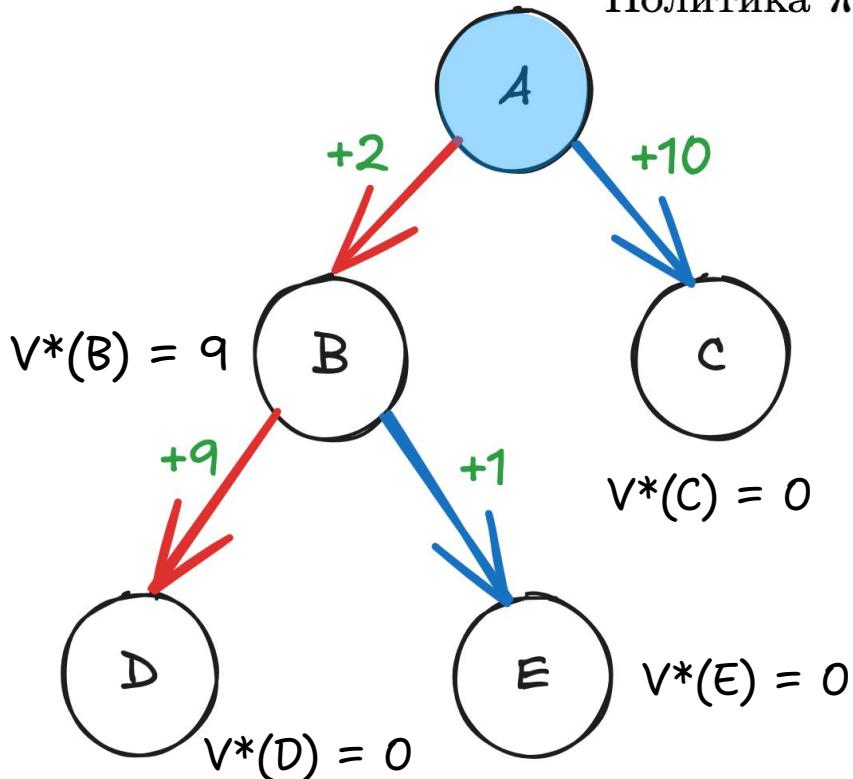
Как докажем?



# Оптимальная value-функция

A	B	C	D	E
	9	0	0	0

Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$

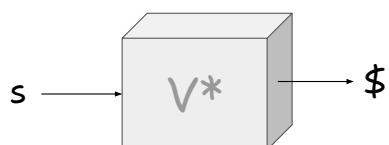


$P_1 = \{$   
A: red  
B: red  
}

$$V^* = V^{\pi^*}$$

Как докажем?

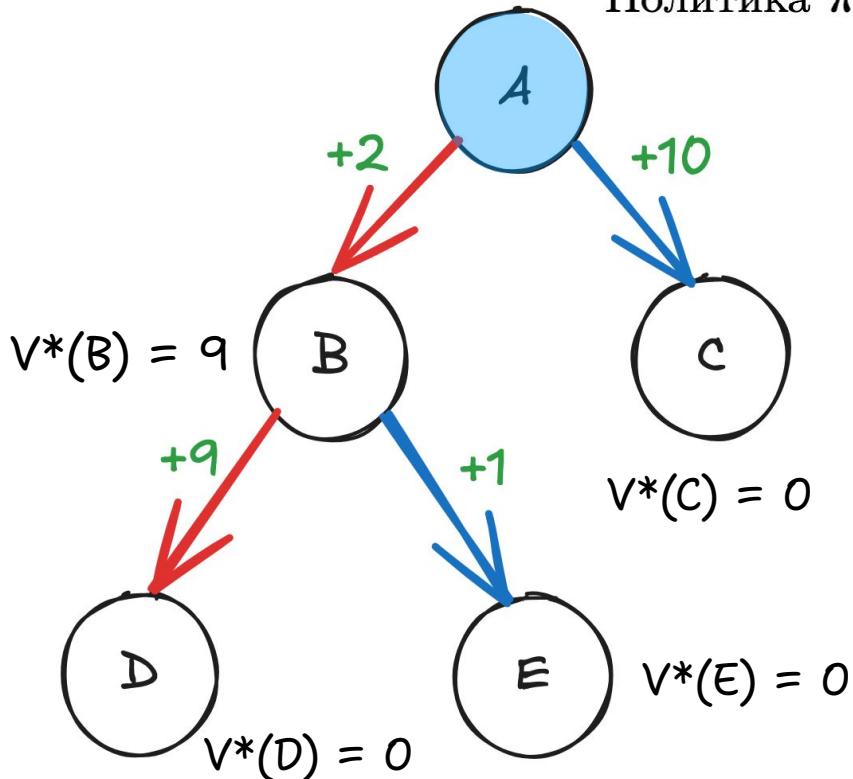
$$V^*(A) =$$



# Оптимальная value-функция

A	B	C	D	E
	9	0	0	0

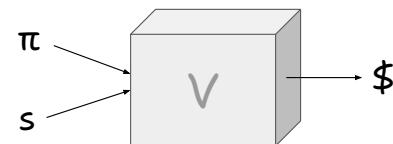
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

Как докажем?

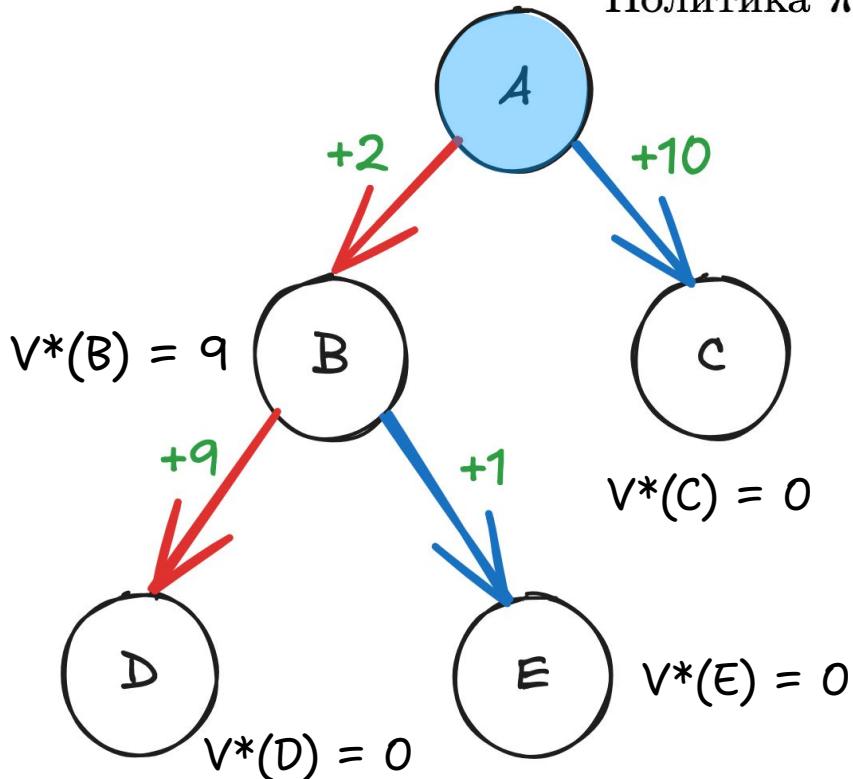


$$V^*(A) = \max(2 + V^*(B), 10 + V^*(C))$$

# Оптимальная value-функция

A	B	C	D	E
	9	0	0	0

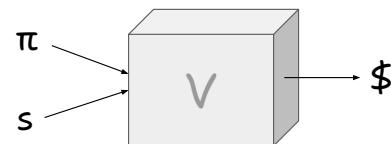
Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$



$P_1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

Как докажем?

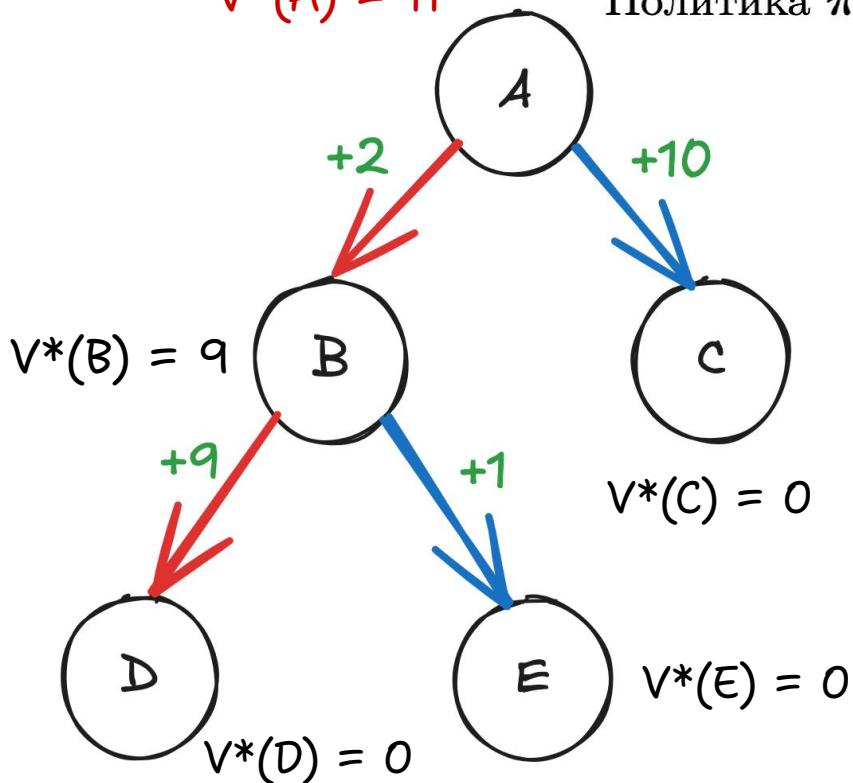


$$V^*(A) = \max(2 + 9, 10 + 0)$$

# Оптимальная value-функция

A	B	C	D	E
11	9	0	0	0

$$V^*(A) = 11$$

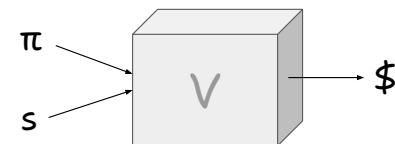


Политика  $\pi^*$  оптимальна, если  $\forall \pi: V^{\pi^*}(s_0) \geq V^\pi(s_0)$

$P_1 = \{$   
A: red  
B: red  
 $\}$

$$V^* = V^{\pi^*}$$

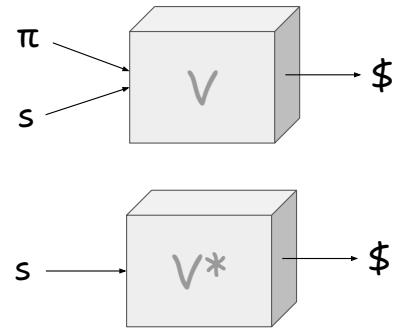
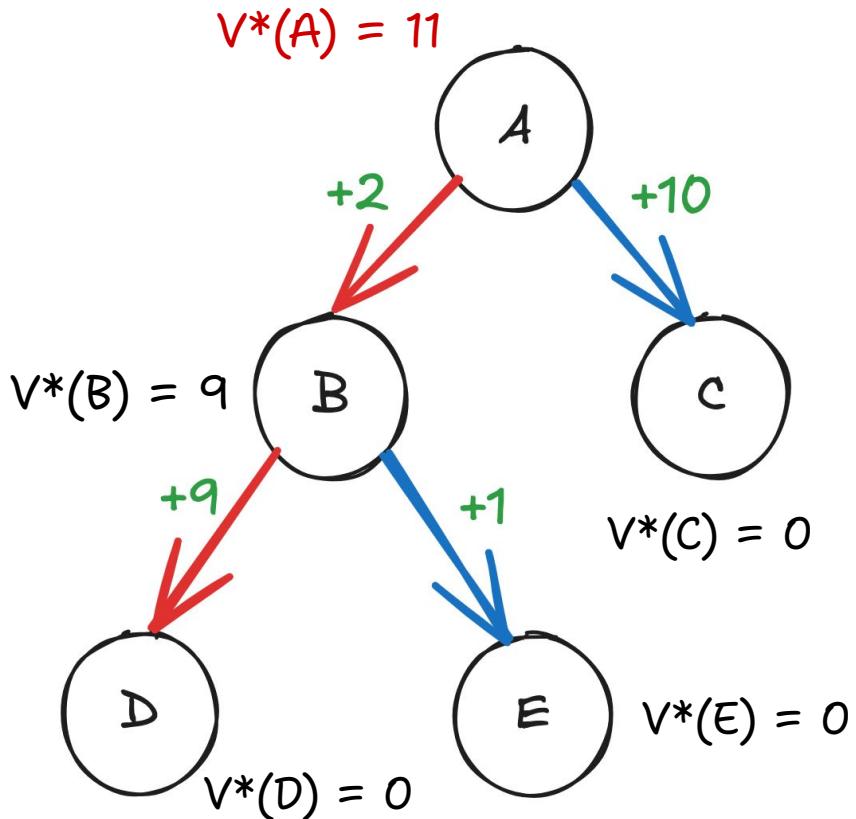
Как докажем?



*А как найти саму  
политику?*

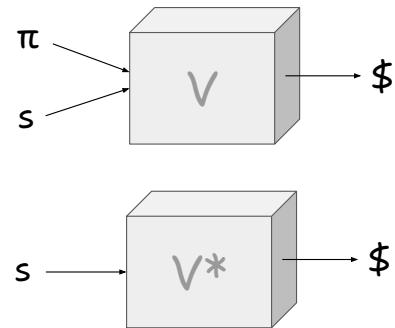
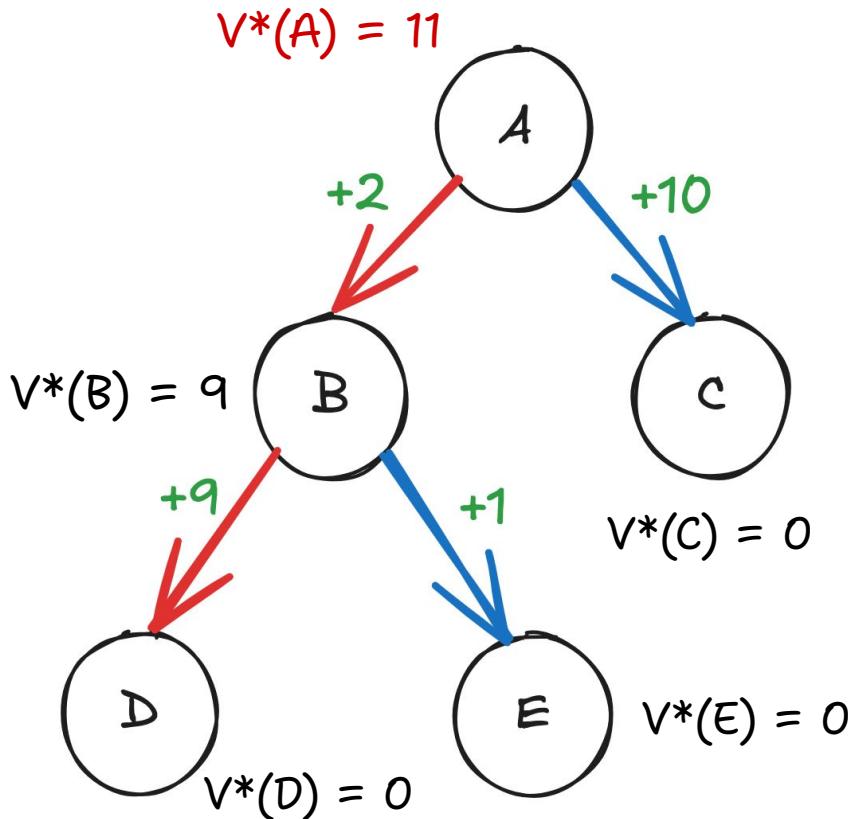
# Метод обратного хода?

A	B	C	D	E
11	9	0	0	0



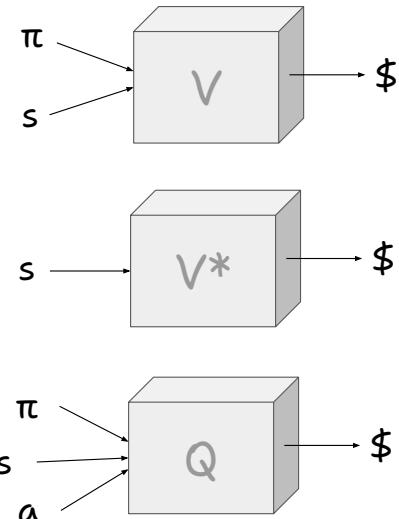
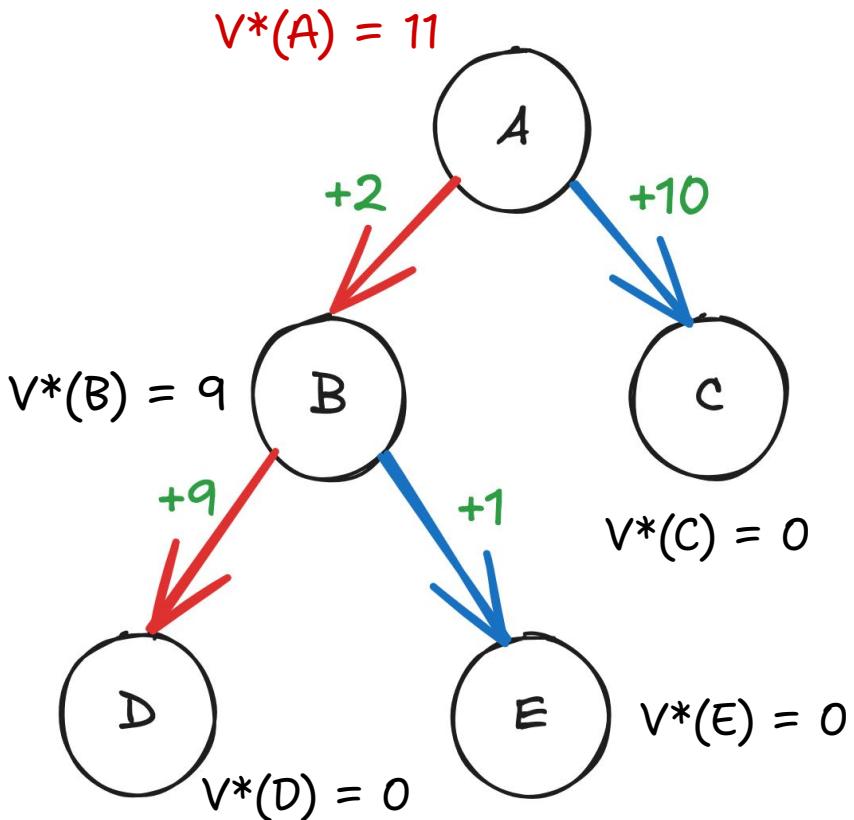
# Можем сохранять сразу!

A	B	C	D	E
11	9	0	0	0



# Quality function

A	B	C	D	E
11	9	0	0	0

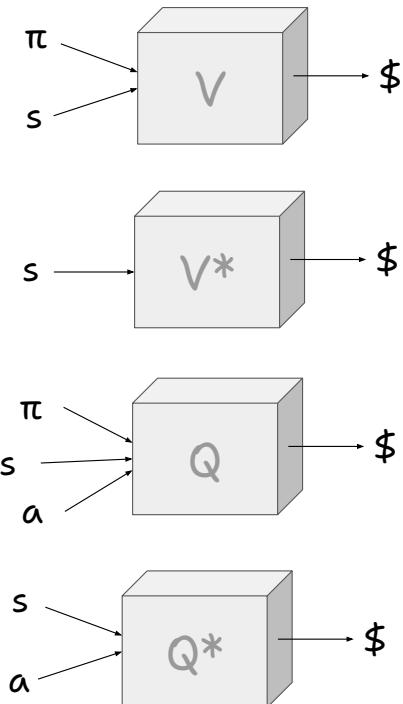
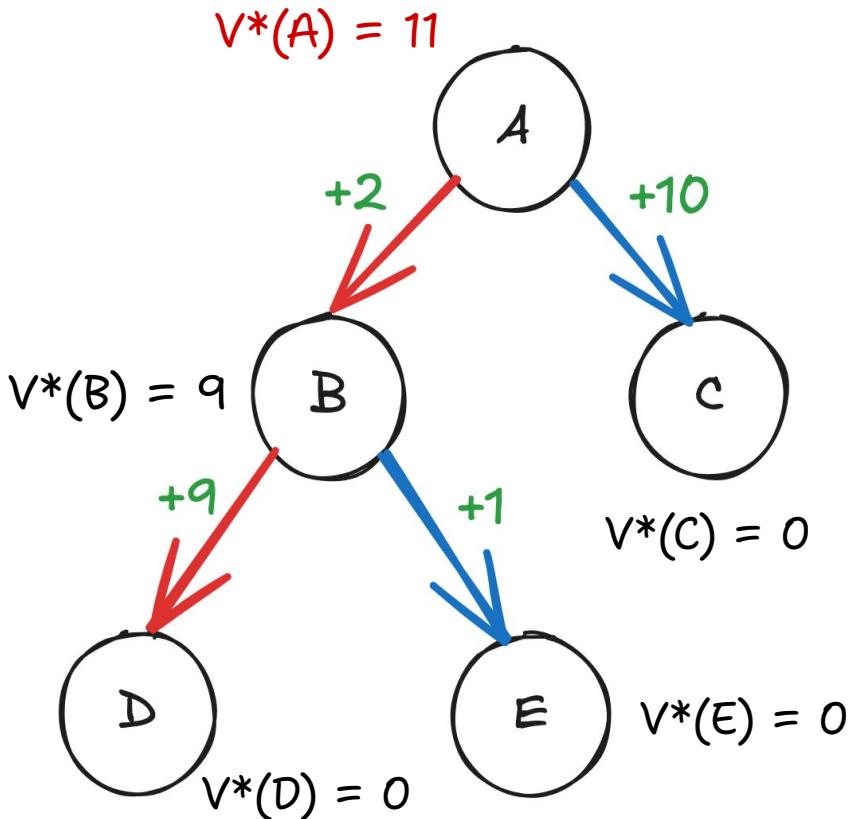


$$Q^\pi(s, a) := \mathbb{E}_{\mathcal{T} \sim \pi | s_0 = s, a_0 = a} \sum_{t \geq 0} r_t$$

Выполняем  $a$ , а потом по политики  $\pi$

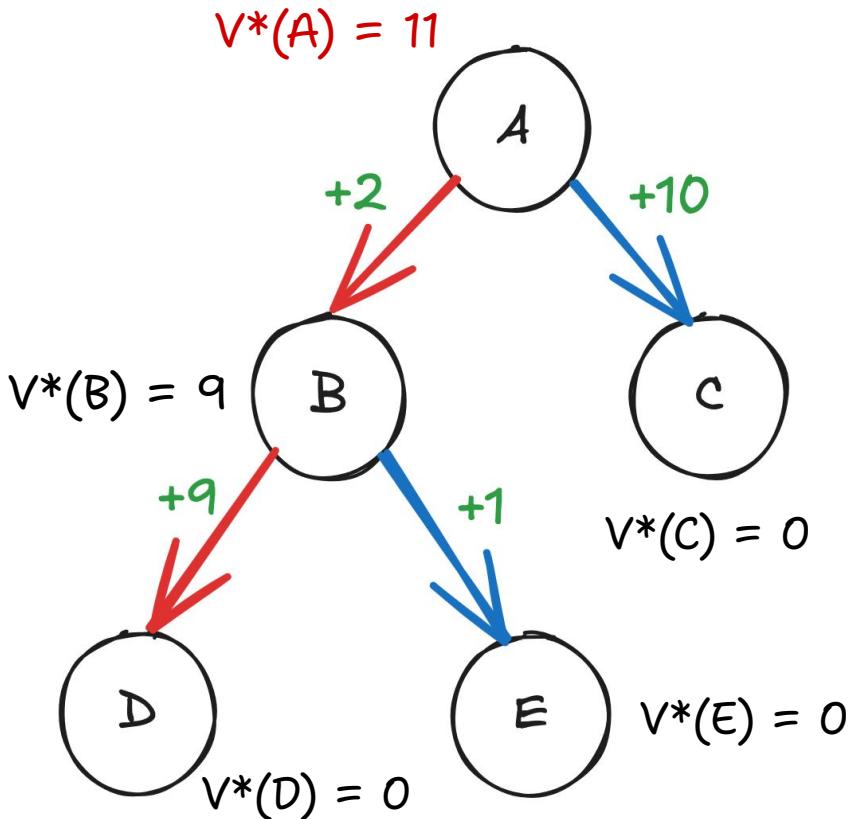
# Quality function

A	B	C	D	E
11	9	0	0	0



Выполняем  $a$ , а потом по политики  $\pi$

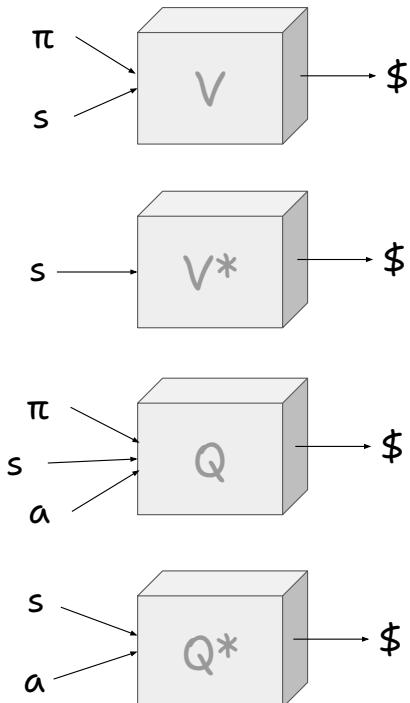
# Quality function



	A	B	C	D	E
V*	11	9	0	0	0

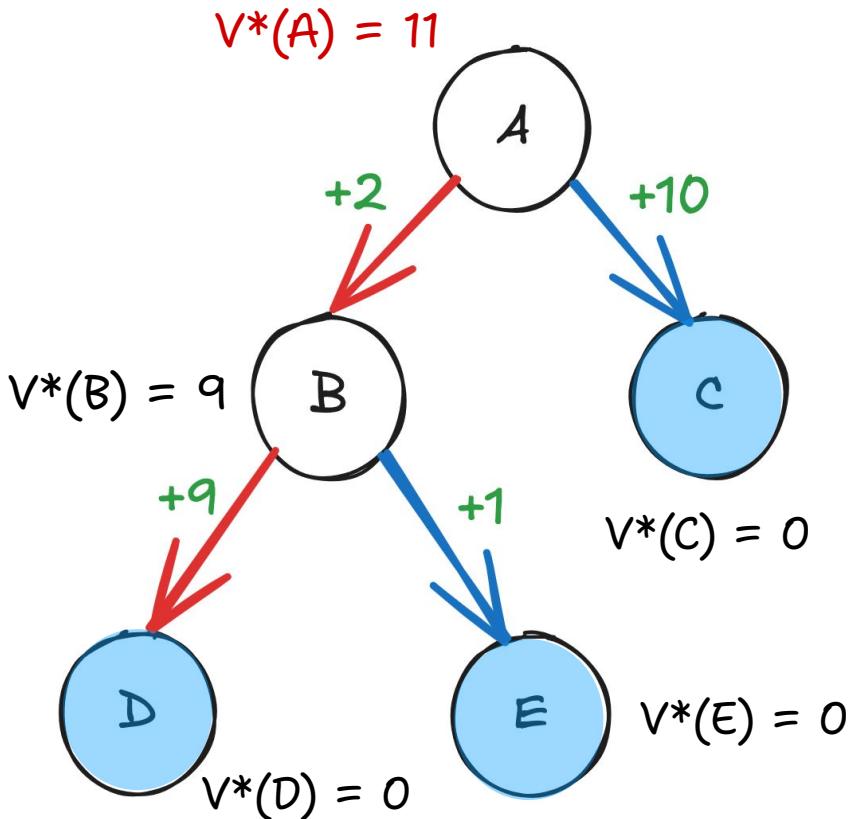
$Q^*$ :

A		
B		
C		
D		
E		



Выполняем  $a$ , а потом по политики  $\pi$

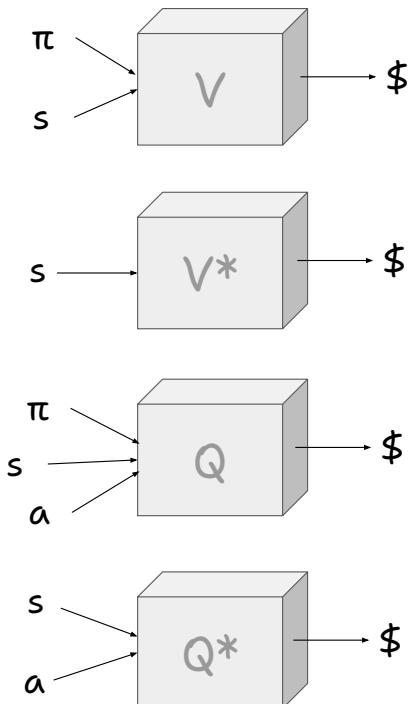
# Quality function



	A	B	C	D	E
V*			0	0	0

$Q^*$ :

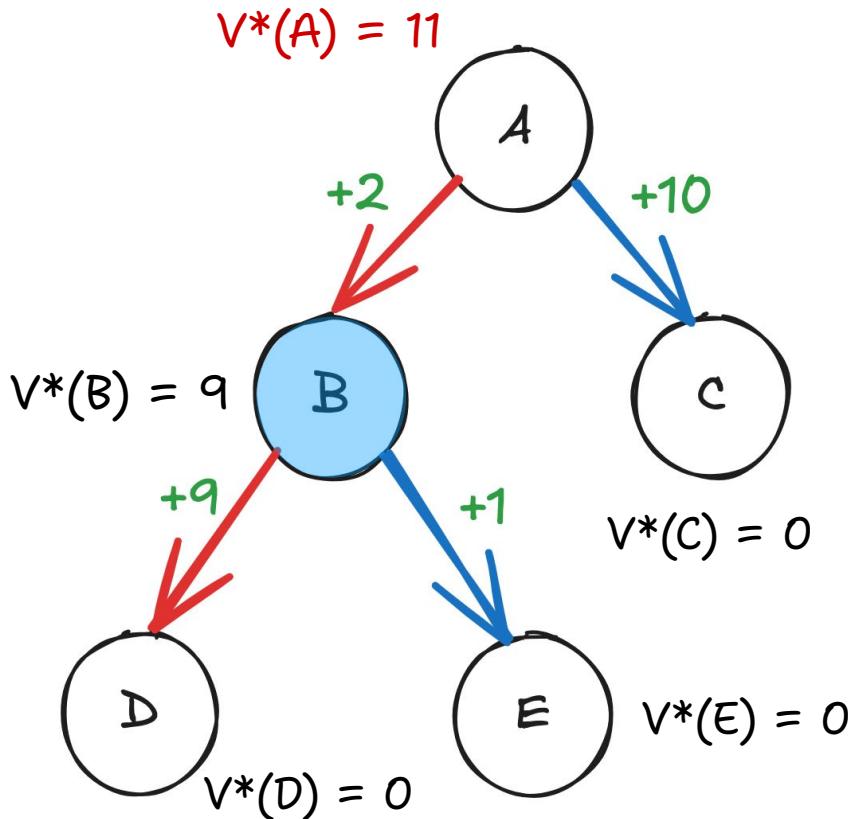
A		
B		
C	X	X
D	X	X
E	X	X



Выполняем  $a$ , а потом по политики  $\pi$

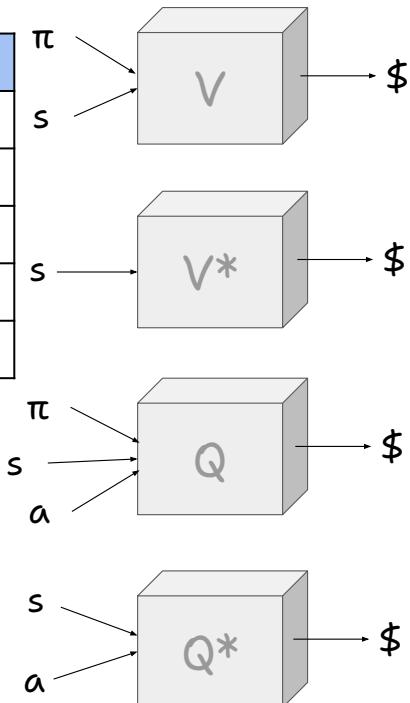
# Quality function

$V^*$ :	A	B	C	D	E
			0	0	0



$Q^*$ :

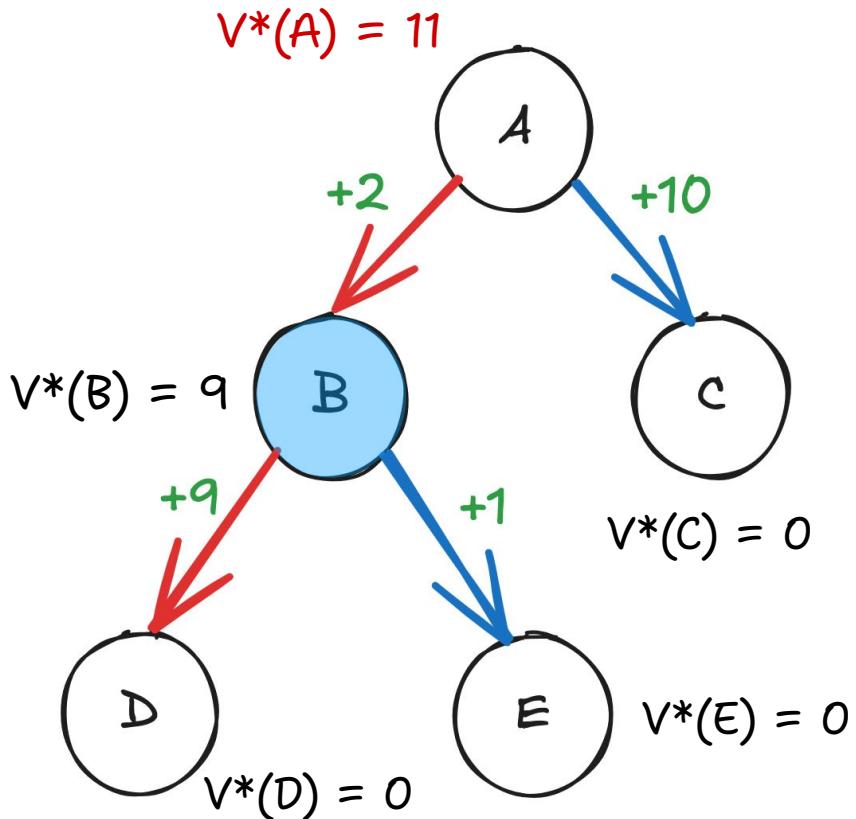
	$\pi$		$s$	
A				
B		$q + V(D)$	$1 + V(E)$	
C	X		X	
D	X		X	
E	X		X	



Выполняем  $a$ , а потом по политики  $\pi$

# Quality function

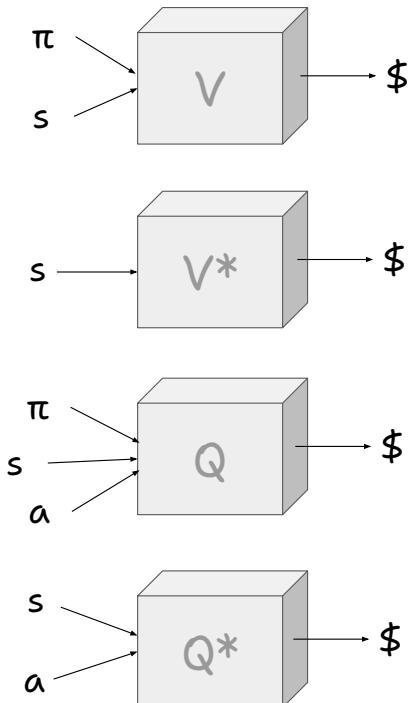
V*:	A	B	C	D	E
			0	0	0



Q\*:

A		
B	9	1
C	X	X
D	X	X
E	X	X

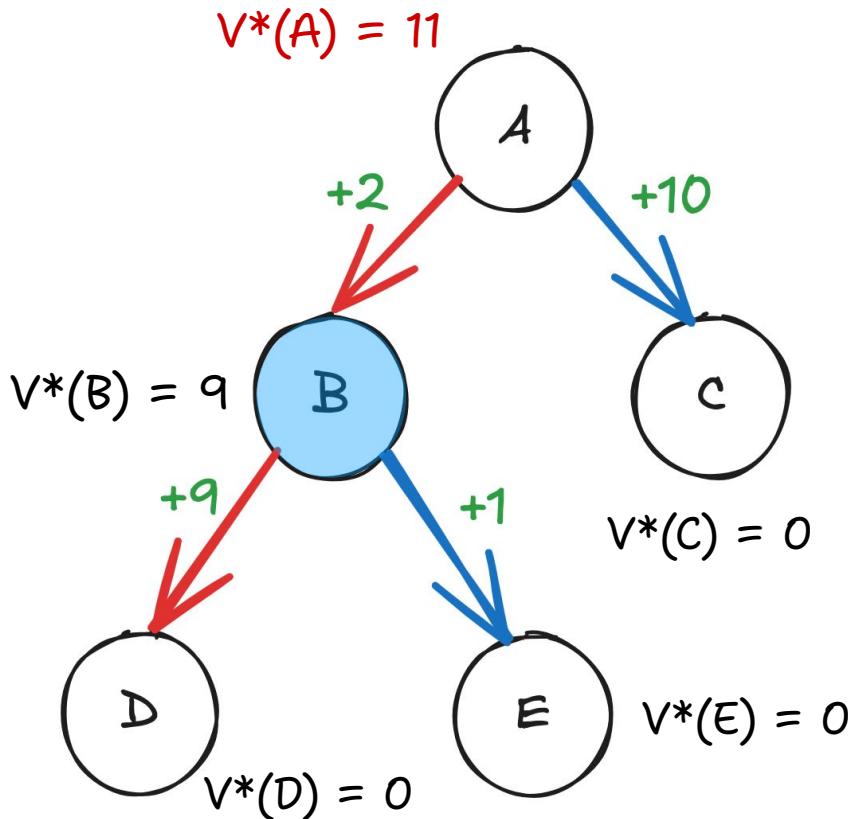
$$V^*(s) = \max_a Q^*(s, a)$$



Выполняем  $a$ , а потом по политики  $\pi$

# Quality function

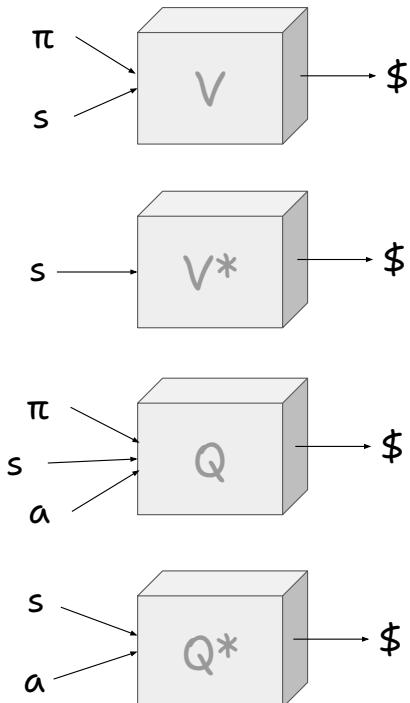
V*	A	B	C	D	E
	9	0	0	0	0



Q\*:

A		
B	9	1
C	X	X
D	X	X
E	X	X

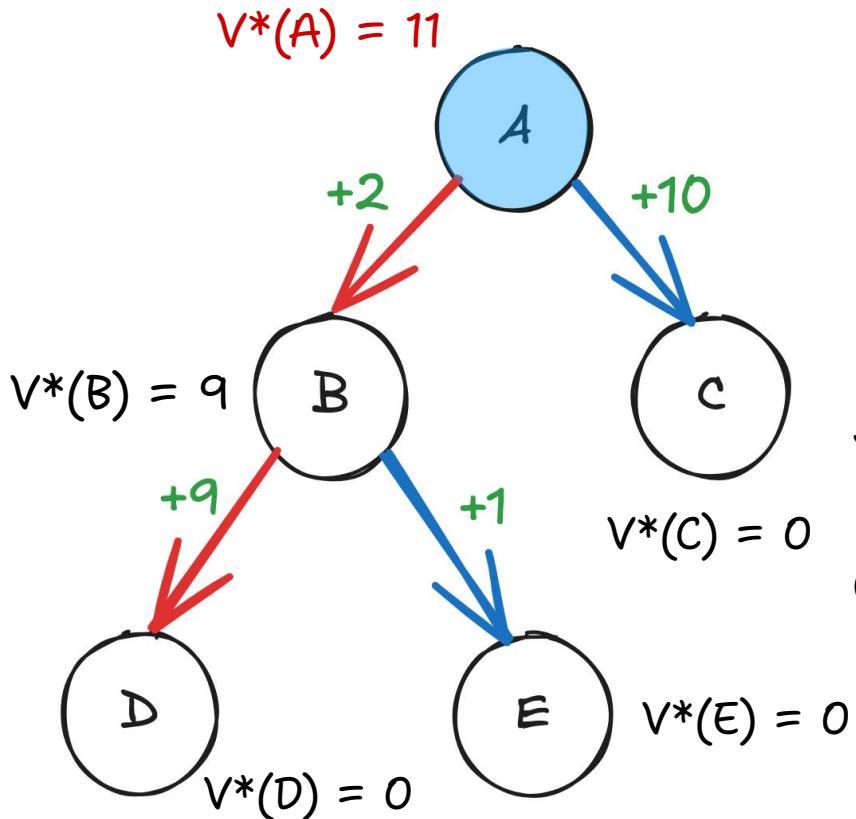
$$V^*(s) = \max_a Q^*(s, a)$$



Выполняем  $a$ , а потом по политики  $\pi$

# Quality function

V*	A	B	C	D	E
	9	0	0	0	0



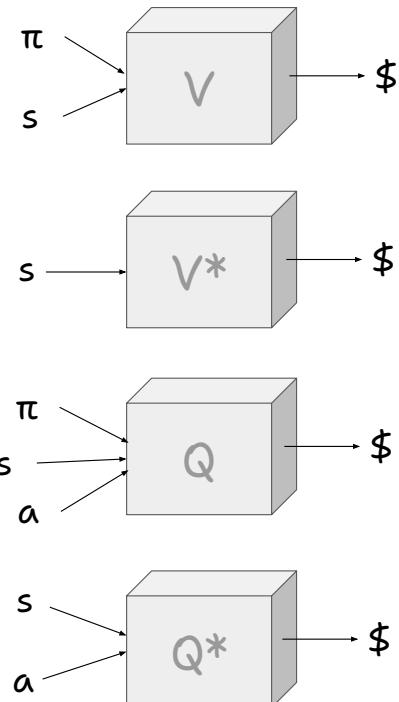
Q\*:

	A	B	C
A			
B		9	1
C	X	X	X
D	X	X	X
E	X	X	X

$$V^*(s) = \max_a Q^*(s, a)$$

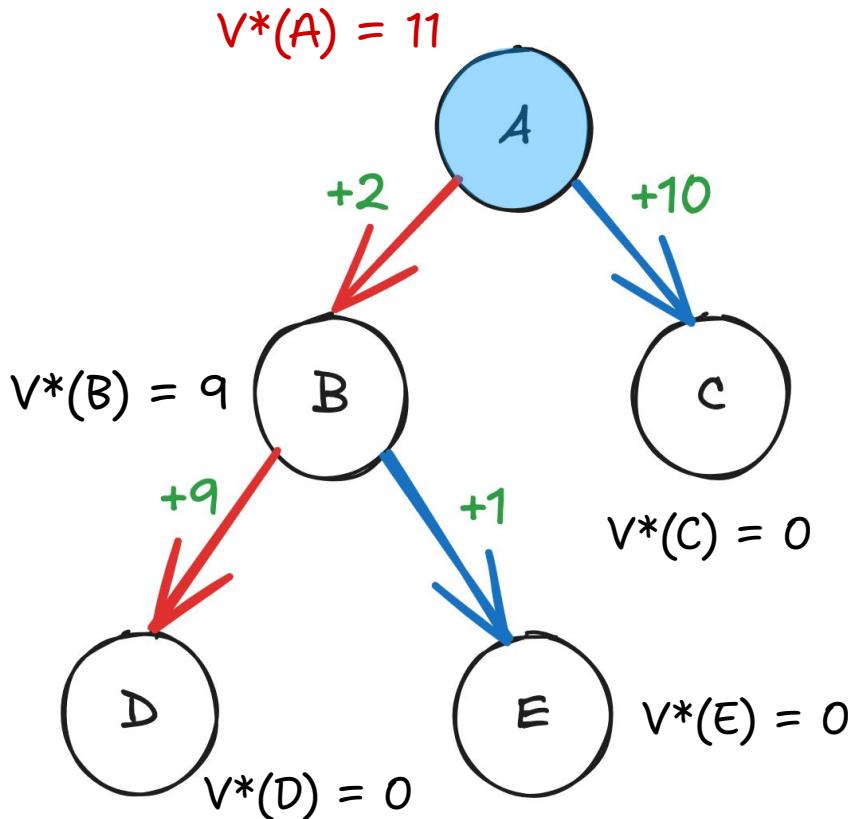
$$Q^*(s, a) = r(s, a) + V^*(s, a)$$

Выполняем  $a$ , а потом по политики  $\pi$



# Quality function

V*:	A	B	C	D	E
	9	0	0	0	0



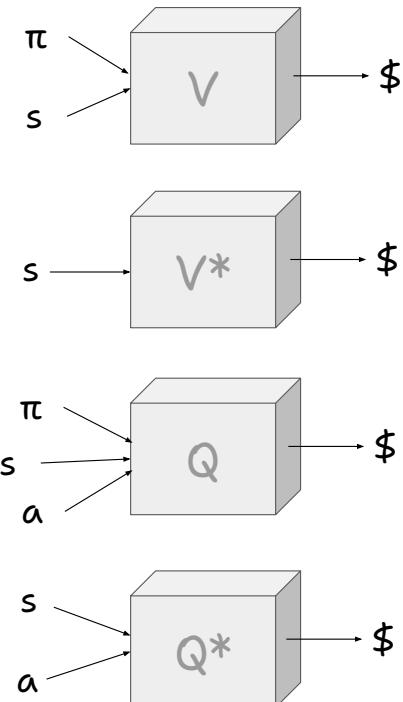
Q\*:

	A	B	C
A	11	10	X
B	9	1	X
C	X	X	X
D	X	X	X
E	X	X	X

$$V^*(s) = \max_a Q^*(s, a)$$

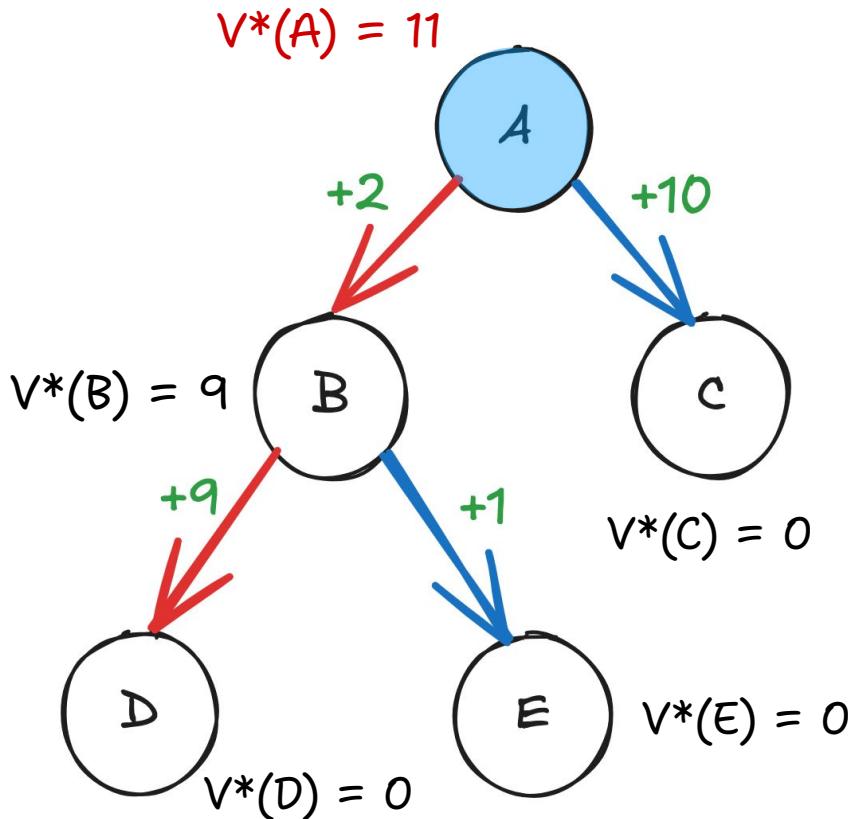
$$Q^*(s, a) = r(s, a) + V^*(s, a)$$

Выполняем  $a$ , а потом по политики  $\pi$



# Quality function

V*:	A	B	C	D	E
	11	9	0	0	0



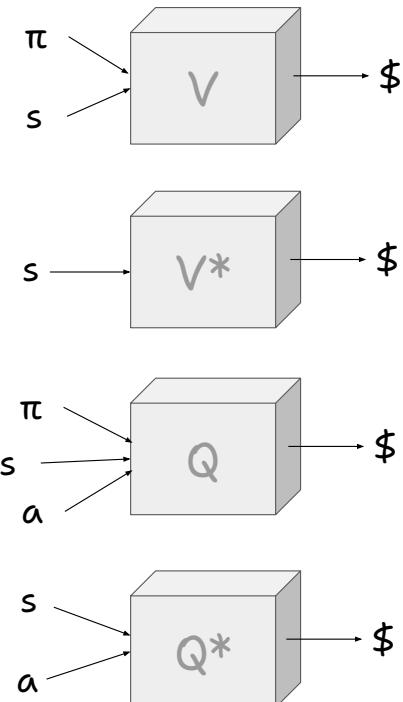
Q\*:

	A	B	C
A	11	10	X
B	9	1	X
C	X	X	X
D	X	X	X
E	X	X	X

$$V^*(s) = \max_a Q^*(s, a)$$

$$Q^*(s, a) = r(s, a) + V^*(s, a)$$

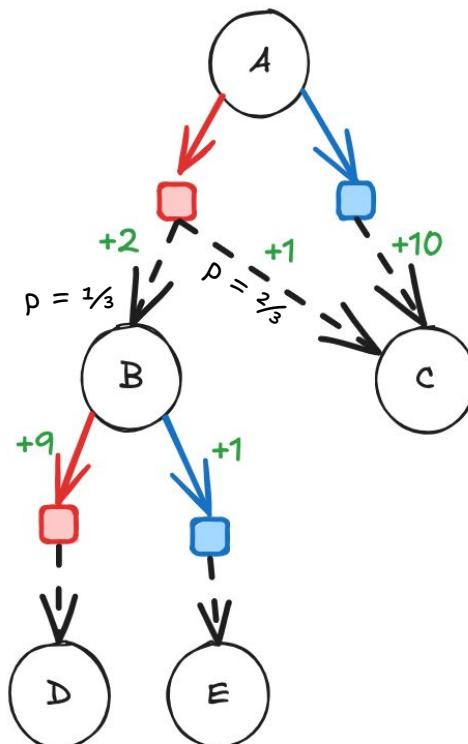
Выполняем  $a$ , а потом по политики  $\pi$



*Стохастический слугай*

# Стохастический случай

---

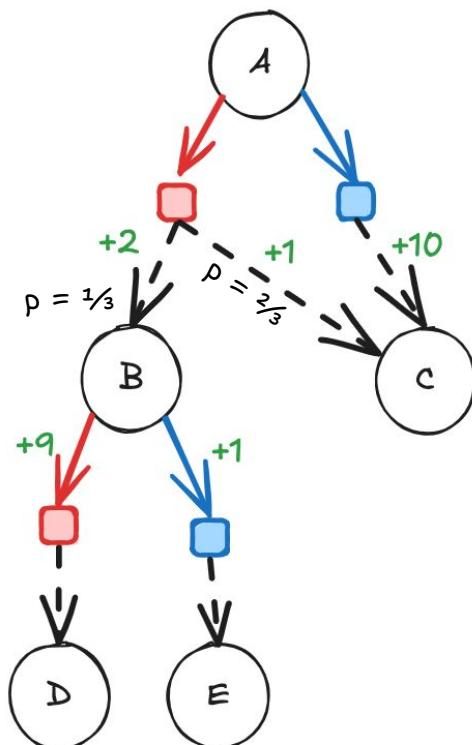


$$V^*(s) = \max_a Q^*(s, a)$$

$$Q^*(s, a) = r(s, a) + V^*(s, a)$$

# Стохастический случай

---



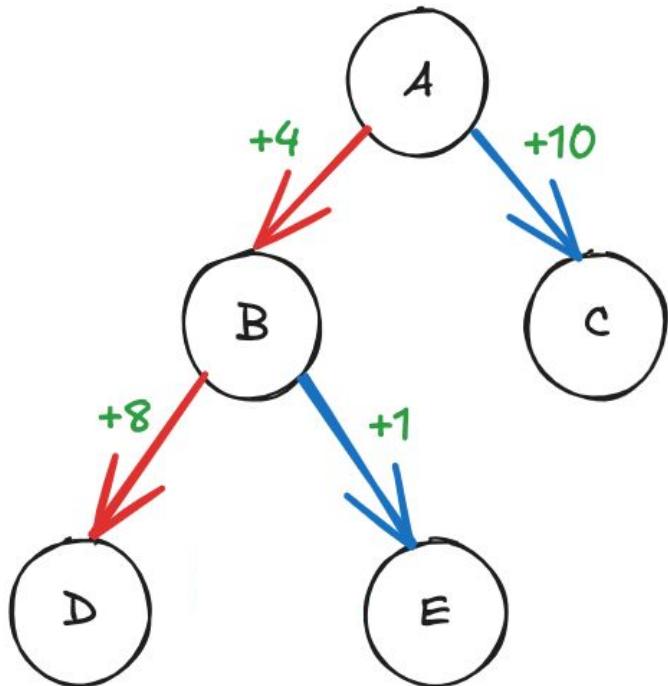
$$V^*(s) = \max_a Q^*(s, a)$$

$$Q^*(s, a) = \mathbf{E}(r(s, a) + V^*(s, a))$$

Более реалистично...

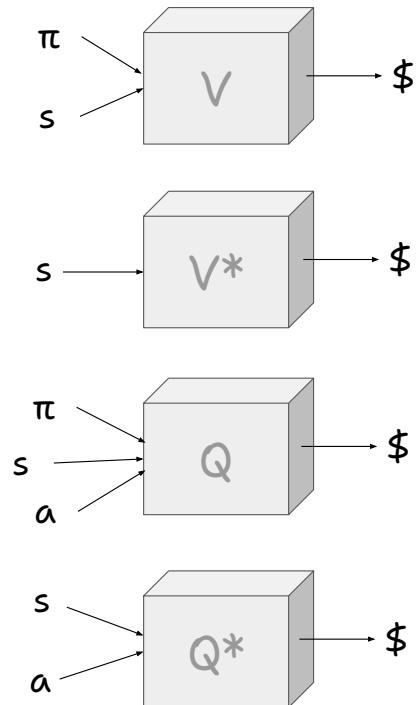
# Более реалистично?

A	B	C	D	E



Q\*:

	A	B	C
A			
B			
C	X	X	X
D	X	X	X
E	X	X	X

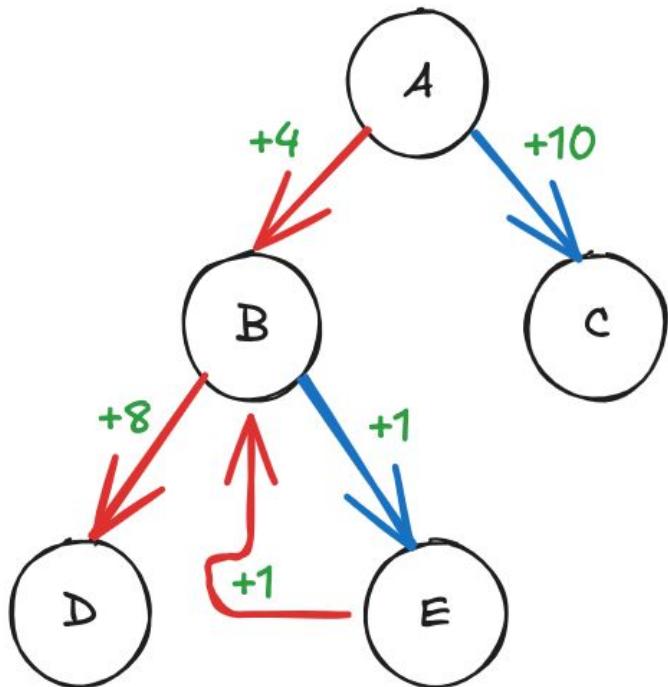


Выполняем  $a$ , а потом по политики  $\pi$

**Перерыв до 20:57**

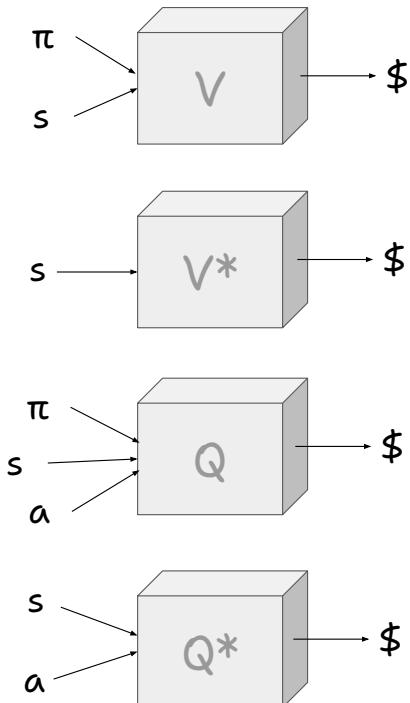
# Циклы

A	B	C	D	E



Q\*:

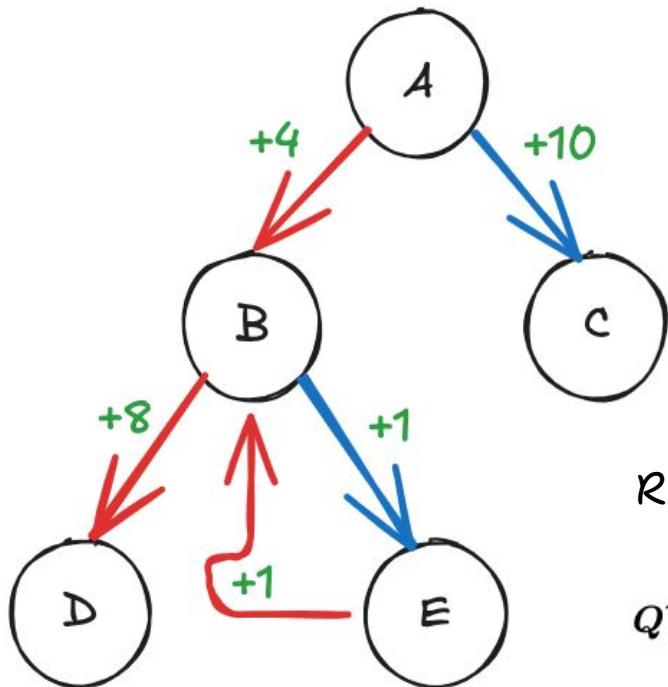
	A	B	C
A			
B			
C	X	X	X
D	X	X	X
E			X



Выполняем  $a$ , а потом по политики  $\pi$

# В чем проблема?

V*:	A	B	C	D	E

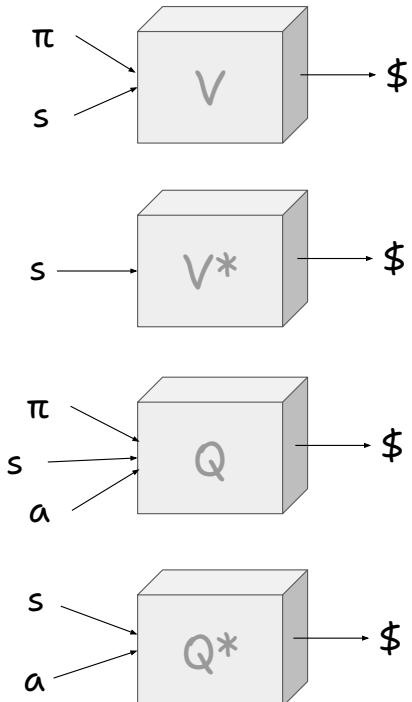


Q\*:

A		
B		
C	X	X
D	X	X
E		X

$$R(\pi) = \mathbb{E}_{T \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi},$$

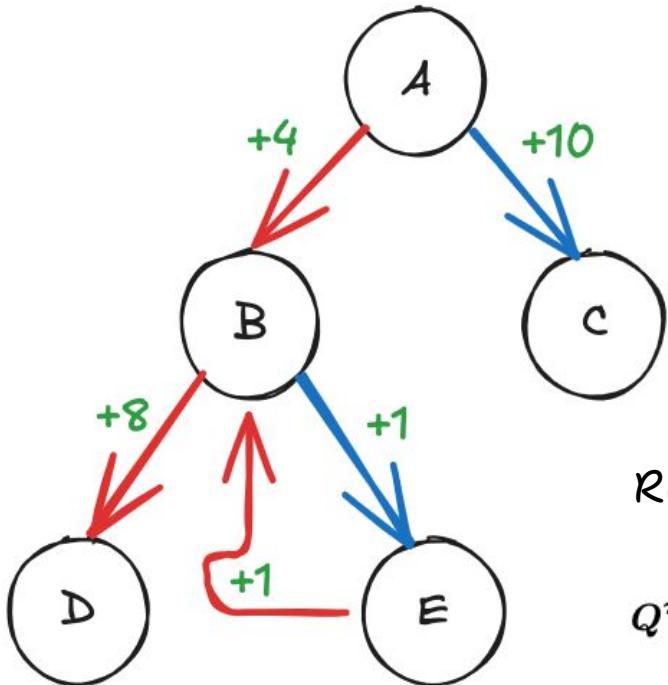
$$Q^\pi(s, a) := \mathbb{E}_{T \sim \pi | s_0=s, a_0=a} \sum_{t \geq 0} r_t$$



Выполняем  $a$ , а потом по политики  $\pi$

# Коэффициент дисконтирования

V*:	A	B	C	D	E

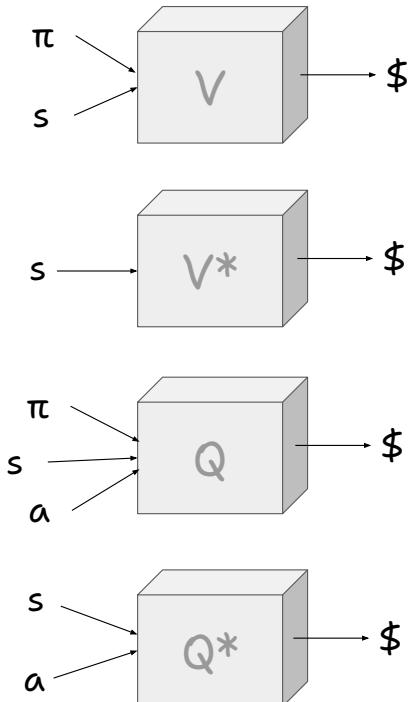


Q\*:

A		
B		
C	X	X
D	X	X
E		X

$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

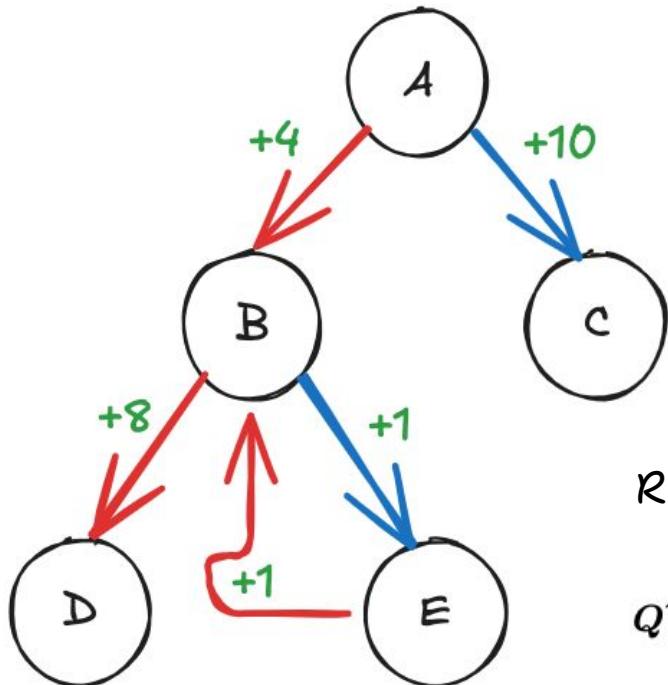
$$Q^\pi(s, a) := \mathbb{E}_{\tau \sim \pi | s_0=s, a_0=a} \sum_{t \geq 0} \gamma^t r_t$$



Выполняем  $a$ , а потом по политики  $\pi$

# Коэффициент дисконтирования

V*:	A	B	C	D	E



Q\*:

A		
B		
C	X	X
D	X	X
E		X

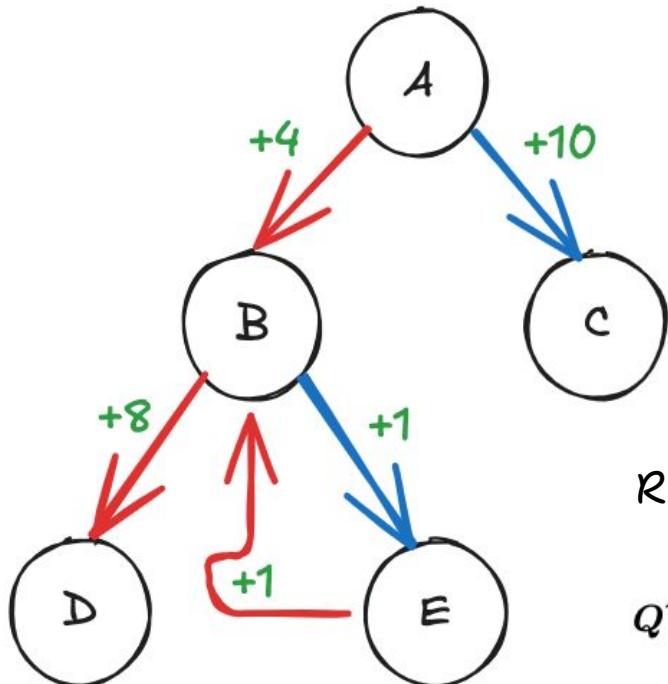
$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

$$Q^{\pi}(s, a) := \mathbb{E}_{\tau \sim \pi | s_0 = s, a_0 = a} \sum_{t \geq 0} \gamma^t r_t$$

Вероятность того,  
что эпизод сейчас  
завершится

# Коэффициент дисконтирования

V*:	A	B	C	D	E



Q\*:

A		
B		
C	X	X
D	X	X
E		X

$$R(\pi) = \mathbb{E}_{\tau \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

$$Q^{\pi}(s, a) := \mathbb{E}_{\tau \sim \pi | s_0 = s, a_0 = a} \sum_{t \geq 0} \gamma^t r_t$$

Вероятность того,  
что эпизод сейчас  
завершится

# Уравнения Белмана

# Уравнения Беллмана

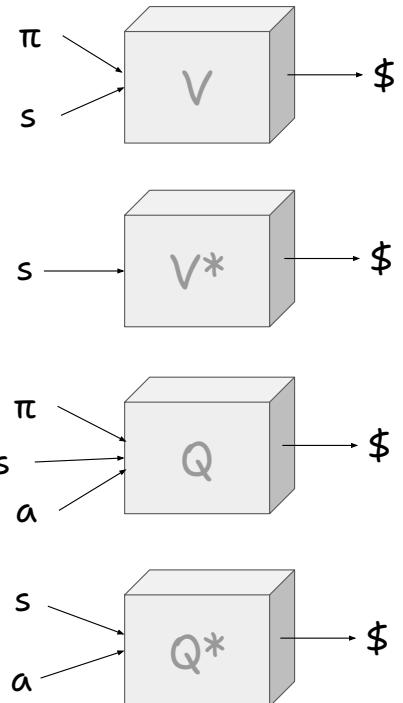
---

$$V^\pi(s) = \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s')]$$

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} \mathbb{E}_{a'} Q^\pi(s', a')$$

$$Q^*(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} \max_{a'} Q^*(s', a')$$

$$V^*(s) = \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V^*(s')]$$



**V-функция** (state value function) ~ сколько, в среднем набирает агент из данного состояния, действую по заданной политике.

$$V^\pi(s) := \mathbb{E}_{\mathcal{T} \sim \pi | s_0 = s} R(\mathcal{T})$$

**Q-функция** (action state value function) ~ сколько, в среднем набирает агент из данного состояния,

- Сначала выбирая действие **a**
- А потом действую по заданной политике **π**

$$Q^\pi(s, a) := \mathbb{E}_{\mathcal{T} \sim \pi | s_0 = s, a_0 = a} \sum_{t \geq 0} \gamma^t r_t$$

**V-функция** (state value function) ~ сколько, в среднем набирает агент из данного состояния, действую по заданной политике.

$$V^\pi(s) := \mathbb{E}_{\mathcal{T} \sim \pi|s_0=s} R(\mathcal{T})$$

**Q-функция** (action state value function) ~ сколько, в среднем набирает агент из данного состояния,

- Сначала выбирая действие **a**
- А потом действую по заданной политике **π**

$$Q^\pi(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} V^\pi(s')$$



# №4. ДП: Value-Iteration

	A	B	C	D
<b>Шаг 0. V:</b>	0	0	0	0
<b>Шаг 1. V:</b>				
<b>Шаг 2. V:</b>				
<b>Шаг 3. V:</b>				
<b>Шаг 4. V:</b>				

## Алгоритм 7: Value Iteration

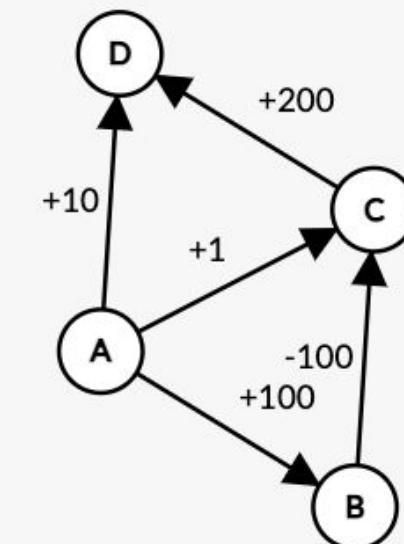
Вход:  $\epsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$





# №4. ДП: Value-Iteration

	A	B	C	D
Шаг 0. V:	0	0	0	0
Шаг 1. V:				
Шаг 2. V:				
Шаг 3. V:				
Шаг 4. V:				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

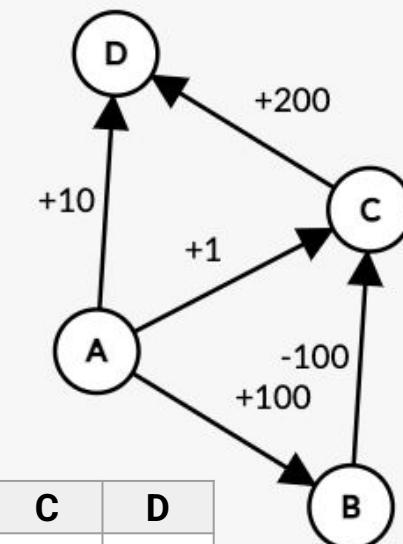
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X			
B	X	X		X
C	X	X	X	
D	X	X	X	X





# №4. ДП: Value-Iteration

	A	B	C	D
<b>Шаг 0. V:</b>	0	0	0	0
<b>Шаг 1. V:</b>				
<b>Шаг 2. V:</b>				
<b>Шаг 3. V:</b>				
<b>Шаг 4. V:</b>				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

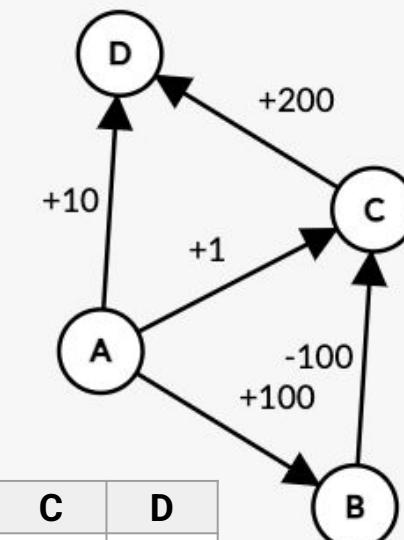
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X	100	1	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X





# №4. ДП: Value-Iteration

	A	B	C	D
Шаг 0. V:	0	0	0	0
Шаг 1. V:	100	-100	200	0
Шаг 2. V:				
Шаг 3. V:				
Шаг 4. V:				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

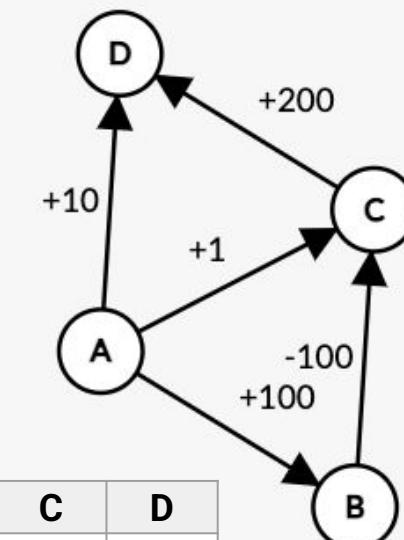
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X	100	1	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X





# №4. ДП: Value-Iteration

	A	B	C	D
<b>Шаг 0. V:</b>	0	0	0	0
<b>Шаг 1. V:</b>	100	-100	200	0
<b>Шаг 2. V:</b>				
<b>Шаг 3. V:</b>				
<b>Шаг 4. V:</b>				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

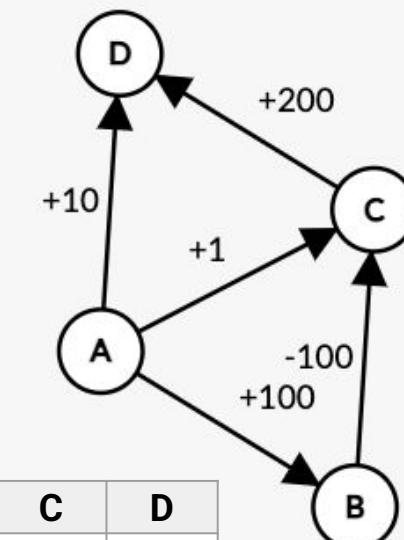
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X			
B	X	X		X
C	X	X	X	
D	X	X	X	X





# №4. ДП: Value-Iteration

	A	B	C	D
Шаг 0. V:	0	0	0	0
Шаг 1. V:	100	-100	200	0
Шаг 2. V:				
Шаг 3. V:				
Шаг 4. V:				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

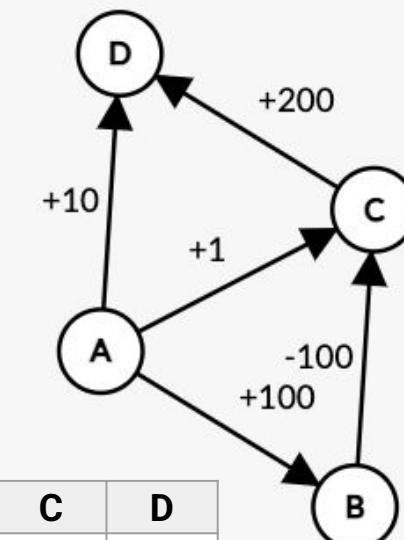
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X	0	201	0
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X





# №4. ДП: Value-Iteration

	A	B	C	D
Шаг 0. V:	0	0	0	0
Шаг 1. V:	100	-100	200	0
Шаг 2. V:	201	100	200	0
Шаг 3. V:				
Шаг 4. V:				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

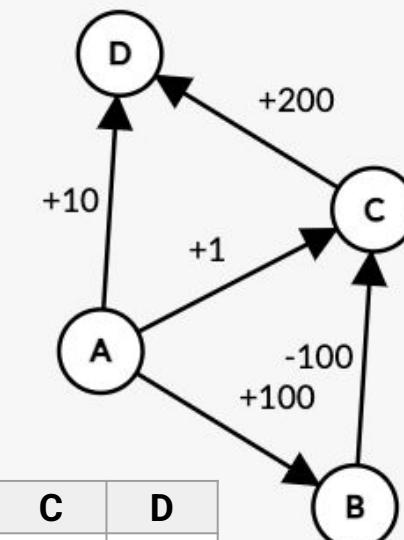
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X	0	201	0
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X





# №4. ДП: Value-Iteration

	A	B	C	D
Шаг 0. V:	0	0	0	0
Шаг 1. V:	100	-100	200	0
Шаг 2. V:	201	100	200	0
Шаг 3. V:				
Шаг 4. V:				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

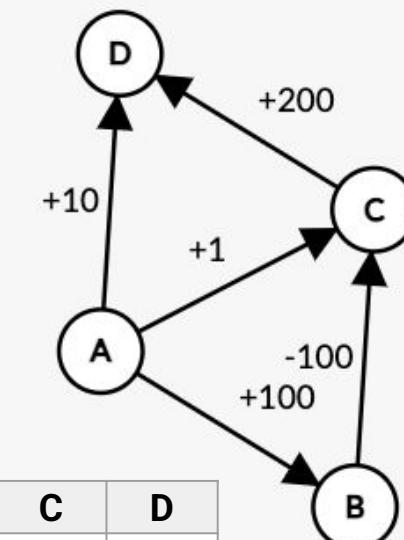
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X			
B	X	X		X
C	X	X	X	
D	X	X	X	X





# №4. ДП: Value-Iteration

	A	B	C	D
<b>Шаг 0. V:</b>	0	0	0	0
<b>Шаг 1. V:</b>	100	-100	200	0
<b>Шаг 2. V:</b>	201	100	200	0
<b>Шаг 3. V:</b>	201	100	200	0
<b>Шаг 4. V:</b>				

## Алгоритм 7: Value Iteration

Вход:  $\epsilon$  — критерий останова

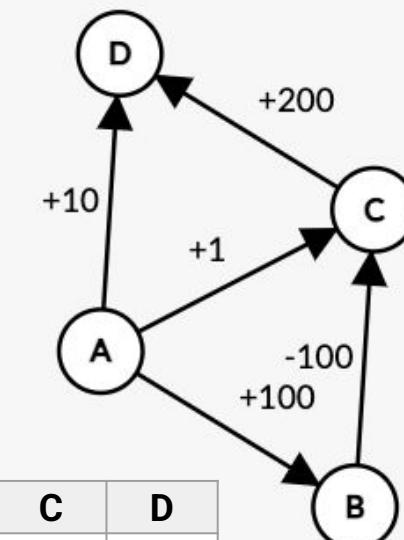
Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

- для всех  $s$ :  $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова:  $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход:  $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

	A	B	C	D
A	X	0	201	0
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X



# Policy Iteration

# Алгоритм Policy Iteration

## Алгоритм 8: Policy Iteration

Гиперпараметры:  $\epsilon$  — критерий останова для процедуры PolicyEvaluation

Инициализируем  $\pi_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

1.  $V^{\pi_k} := \text{PolicyEvaluation}(\pi_k, \epsilon)$
2.  $Q^{\pi_k}(s, a) := r(s, a) + \gamma \mathbb{E}_{s'} V^{\pi_k}(s')$
3.  $\pi_{k+1}(s) := \underset{a}{\operatorname{argmax}} Q^{\pi_k}(s, a)$
4. критерий останова:  $\pi_k \equiv \pi_{k+1}$

## Алгоритм 6: Policy Evaluation

Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\epsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \epsilon$

Выход:  $V_k(s)$



# №5. ДП: Policy-Iteration

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Политика:

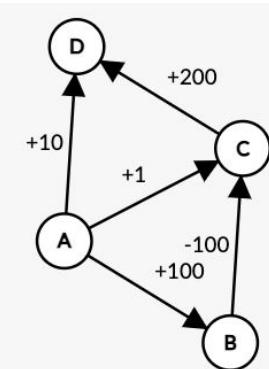
	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?





# №5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
A	0	0	0
B	0	0	0
C	0	0	0
D	0	0	0

Q:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X



Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
A	?
B	?
C	?
D	?



Q:

### Алгоритм 6: Policy Evaluation

Вход:  $\pi(a | s)$  — стратегия

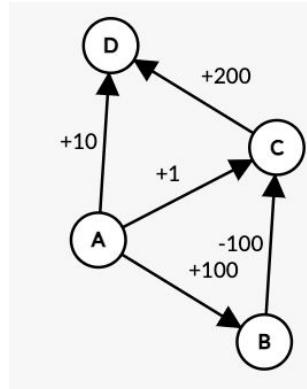
Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Очениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
100	-100	200	0

Q:

	A	B	C	D
A	X	100	200	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

#### Алгоритм 6: Policy Evaluation

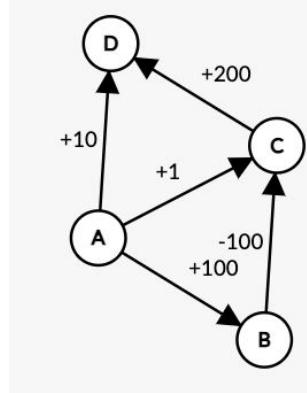
Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$   
На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Очениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
100	-100	200	0

Q:

	A	B	C	D
A	X			
B	X	X		X
C	X	X	X	
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

#### Алгоритм 6: Policy Evaluation

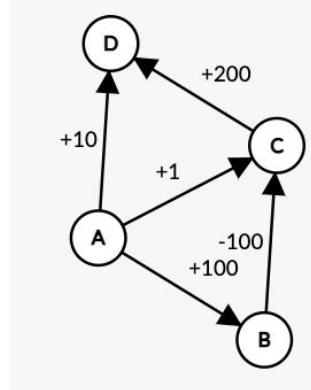
Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$   
На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Очениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
100	-100	200	0

Q:

	A	B	C	D
A	X	0	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

#### Алгоритм 6: Policy Evaluation

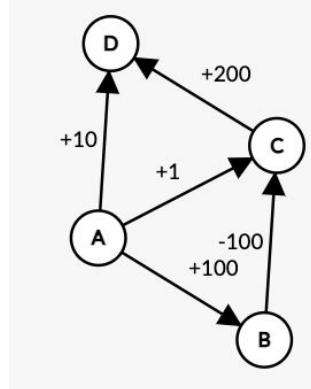
Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$   
На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Очениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	0	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X



Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

#### Алгоритм 6: Policy Evaluation

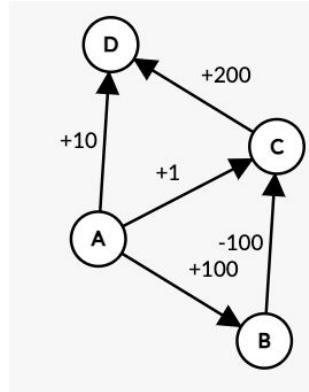
Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$   
На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X			
B	X	X		X
C	X	X	X	
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

#### Алгоритм 6: Policy Evaluation

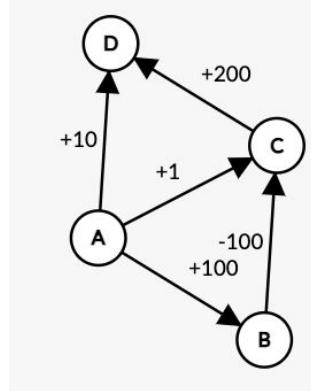
Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$   
На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X



Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

#### Алгоритм 6: Policy Evaluation

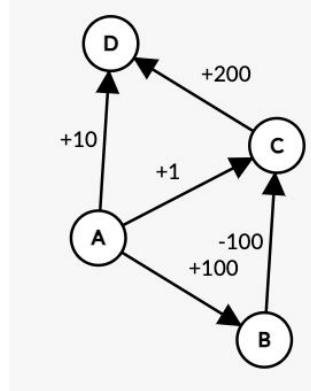
Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$   
На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X



Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?

Q:

#### Алгоритм 6: Policy Evaluation

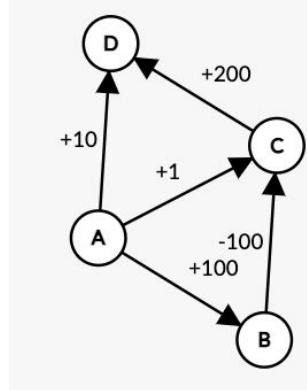
Вход:  $\pi(a | s)$  — стратегия

Гиперпараметры:  $\varepsilon$  — критерий останова

Инициализируем  $V_0(s)$  произвольно для всех  $s \in \mathcal{S}$   
На  $k$ -ом шаге:

1.  $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова:  $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход:  $V_k(s)$





# №5. ДП: Policy-Iteration

Улучшаем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

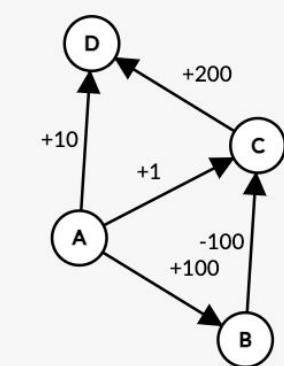
#### Алгоритм 8: Policy Iteration

Гиперпараметры:  $\epsilon$  — критерий останова для процедуры PolicyEvaluation

Инициализируем  $\pi_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

1.  $V^{\pi_k} := \text{PolicyEvaluation}(\pi_k, \epsilon)$
2.  $Q^{\pi_k}(s, a) := r(s, a) + \gamma \mathbb{E}_{s'} V^{\pi_k}(s')$
3.  $\pi_{k+1}(s) := \underset{a}{\operatorname{argmax}} Q^{\pi_k}(s, a)$
4. критерий останова:  $\pi_k \equiv \pi_{k+1}$





# №5. ДП: Policy-Iteration

Улучшаем политику

Политика:

	A	B	C	D
A	0.0	1.0	0.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	0.0	0.0	1.0	0.0
B	0.0	0.0	1.0	0.0
C	0.0	0.0	0.0	1.0
D	0.0	0.0	0.0	0.0

V:

A	B
?	?



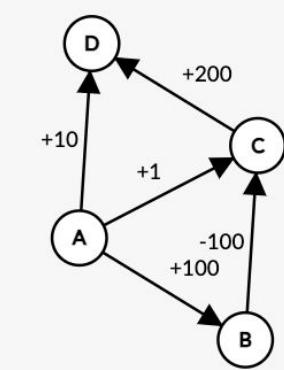
#### Алгоритм 8: Policy Iteration

Гиперпараметры:  $\epsilon$  — критерий останова для процедуры PolicyEvaluation

Инициализируем  $\pi_0(s)$  произвольно для всех  $s \in \mathcal{S}$

На  $k$ -ом шаге:

1.  $V^{\pi_k} := \text{PolicyEvaluation}(\pi_k, \epsilon)$
2.  $Q^{\pi_k}(s, a) := r(s, a) + \gamma \mathbb{E}_{s'} V^{\pi_k}(s')$
3.  $\pi_{k+1}(s) := \underset{a}{\operatorname{argmax}} Q^{\pi_k}(s, a)$
4. критерий останова:  $\pi_k \equiv \pi_{k+1}$

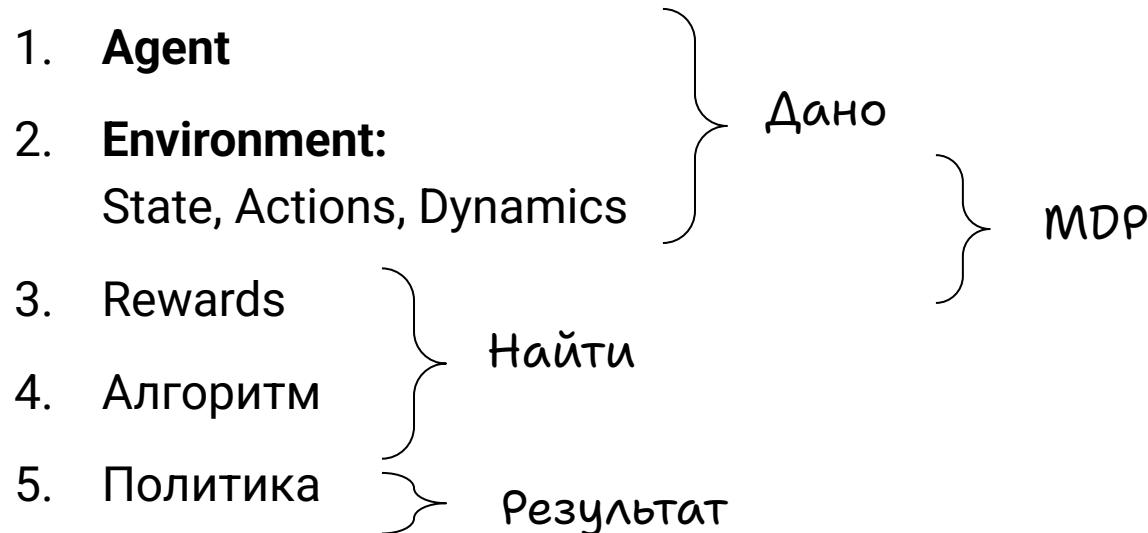


Резюме



# Итого

---



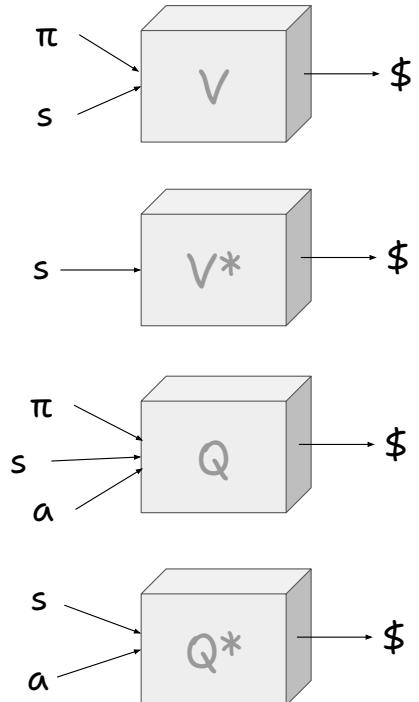
Опрос в конце: <https://otus.ru/polls/141246/>



# План

---

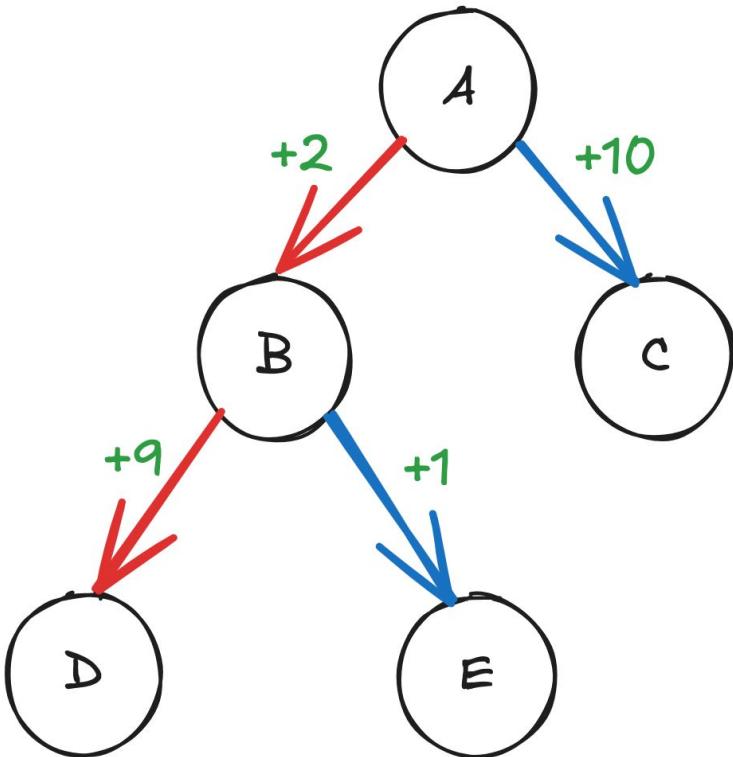
- Терминальные состояния
- Оптимальная политика
- Value-функция
- Q-функция
- Дисконтирование
- **Value iteration**
- Policy iteration



Опрос в конце: <https://otus.ru/polls/141247/>

# Вопрос

---



Какая цель?

$$\mathbb{E}_{\pi \sim \pi} \sum_{t \geq 0} r_t \rightarrow \max_{\pi}$$

Откуда может  
взяться  
случайность?

**Дисклаймер:** В презентации использованы личные  
материалы **@dmi3eva**.

Образовательная площадка **Otus** не несет за них  
ответственность.