

RL 1-04

Policy Iteration

Начнем в 20:01

Можно ли **осознанно**
разучиться ездить на
велосипеде?



Warmup

Можно ли **осознанно**
разучиться ездить на
велосипеде?

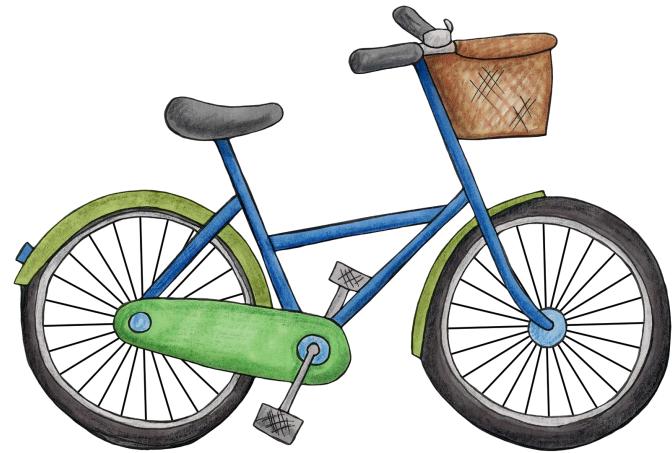
Model-free алгоритм – ...



Warmup

Можно ли **осознанно**
разучиться ездить на
велосипеде?

Model-free алгоритм не использует и не
пытается выучить модель динамики
среды $p(s'| s, a)$.



Warmup

“Обратный велосипед”

<https://www.youtube.com/watch?v=MFzDaBzBIL0>



Классификация

Классификация №1

1. Model free
2. Model based

Классификация №3

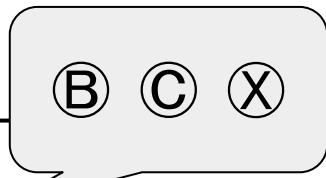
1. On-policy
2. Off-policy

Классификация №2

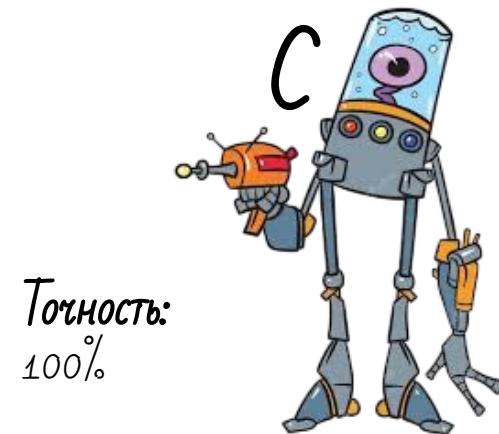
1. Value based
2. Policy based

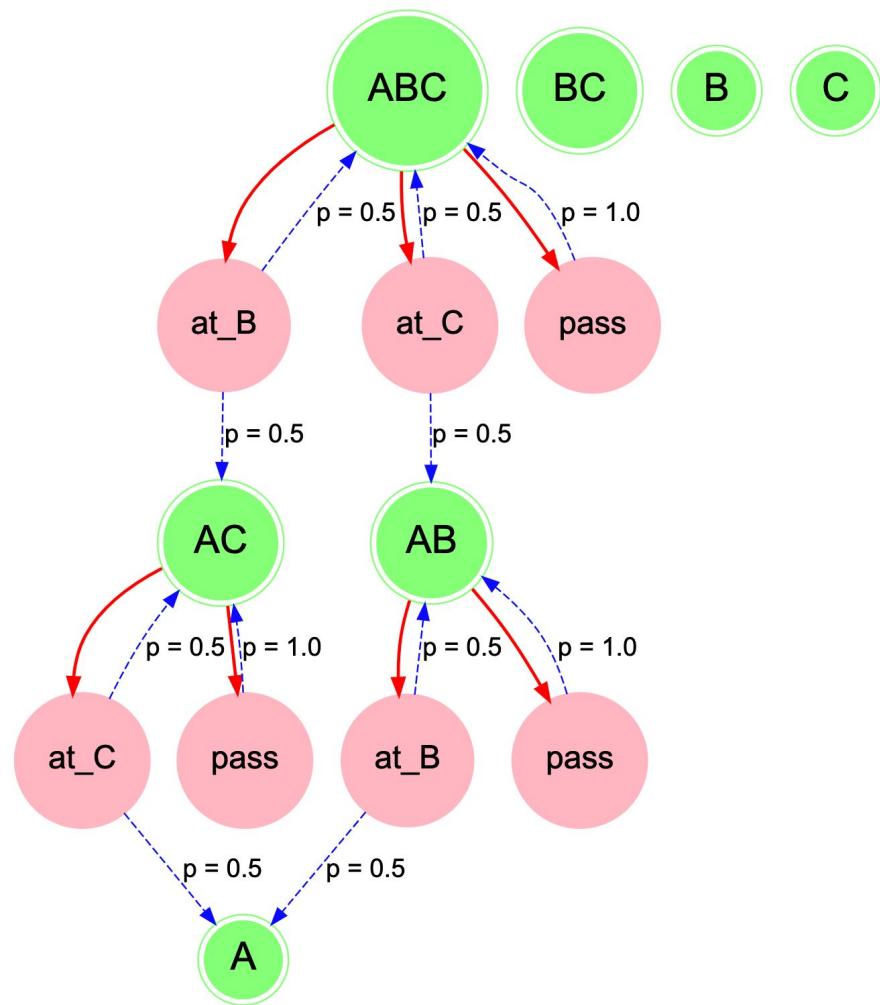
Zagara

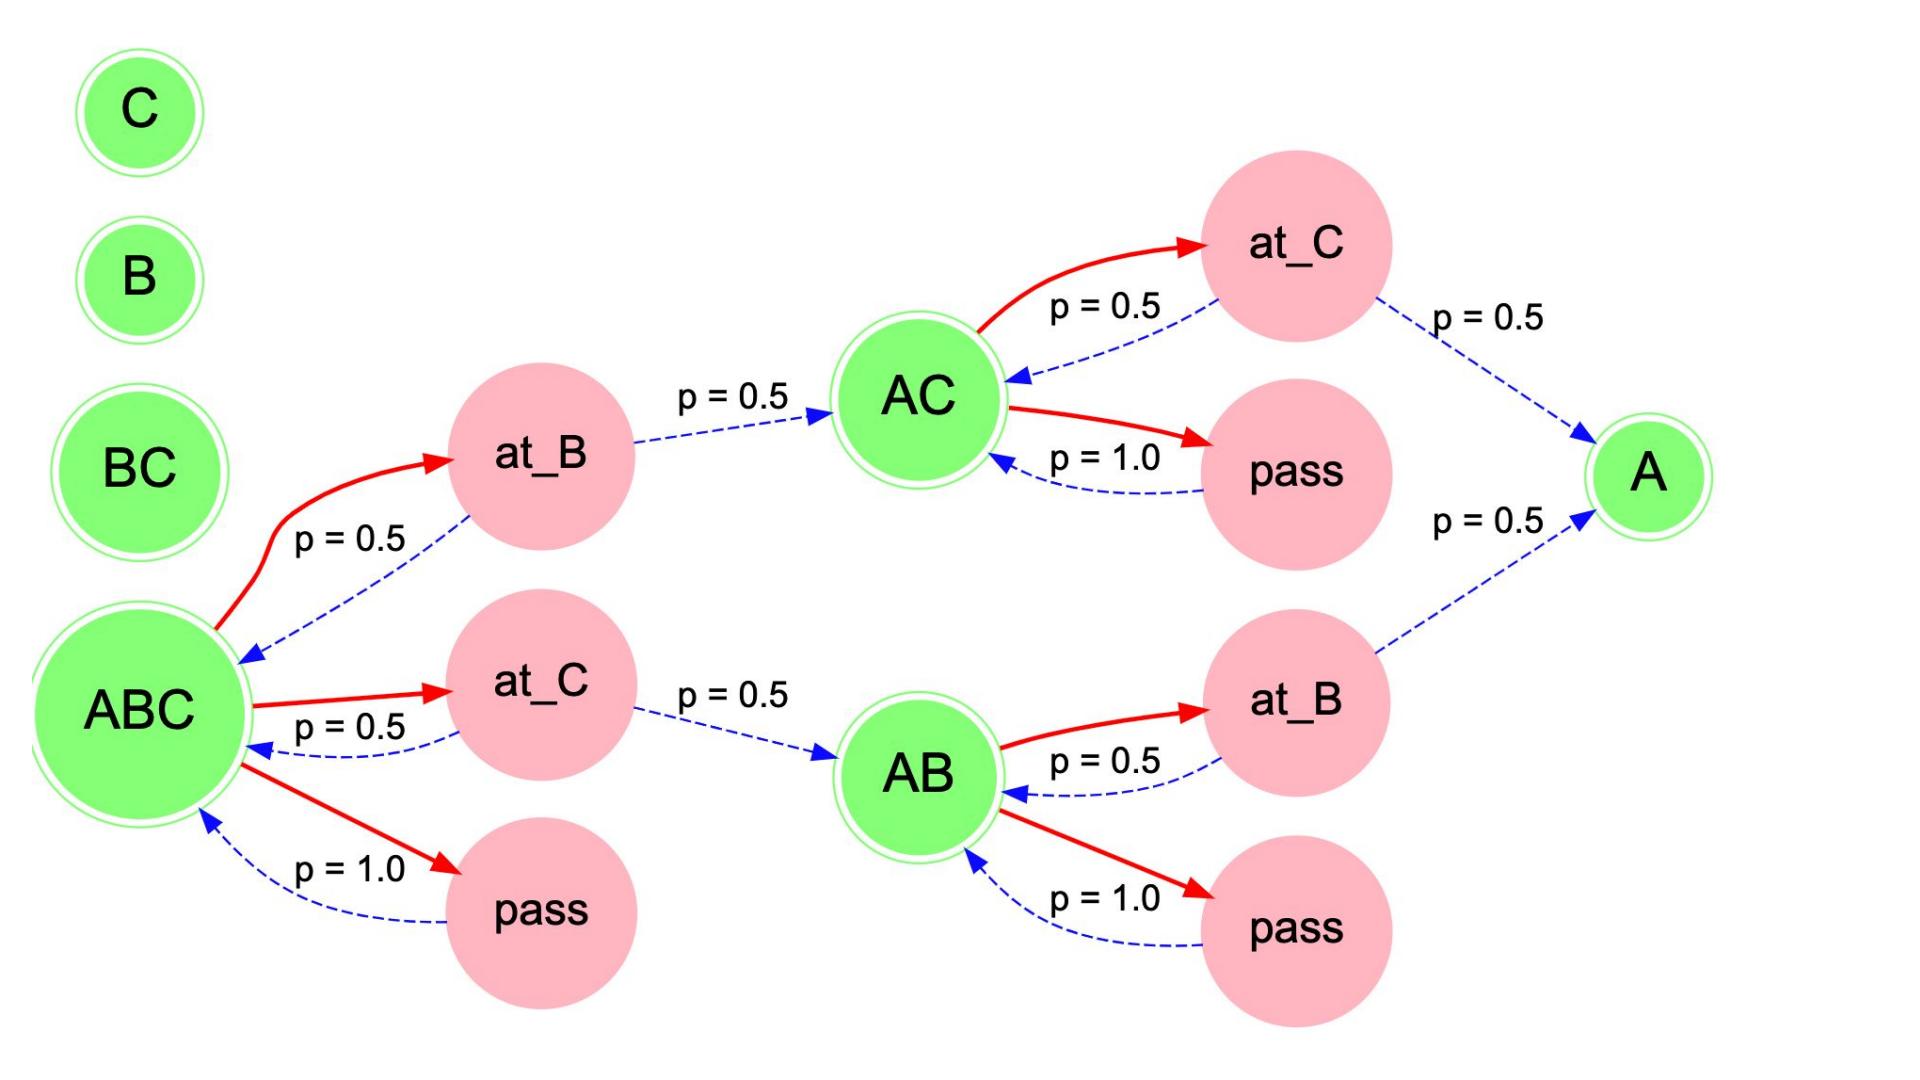
Что будем делать?

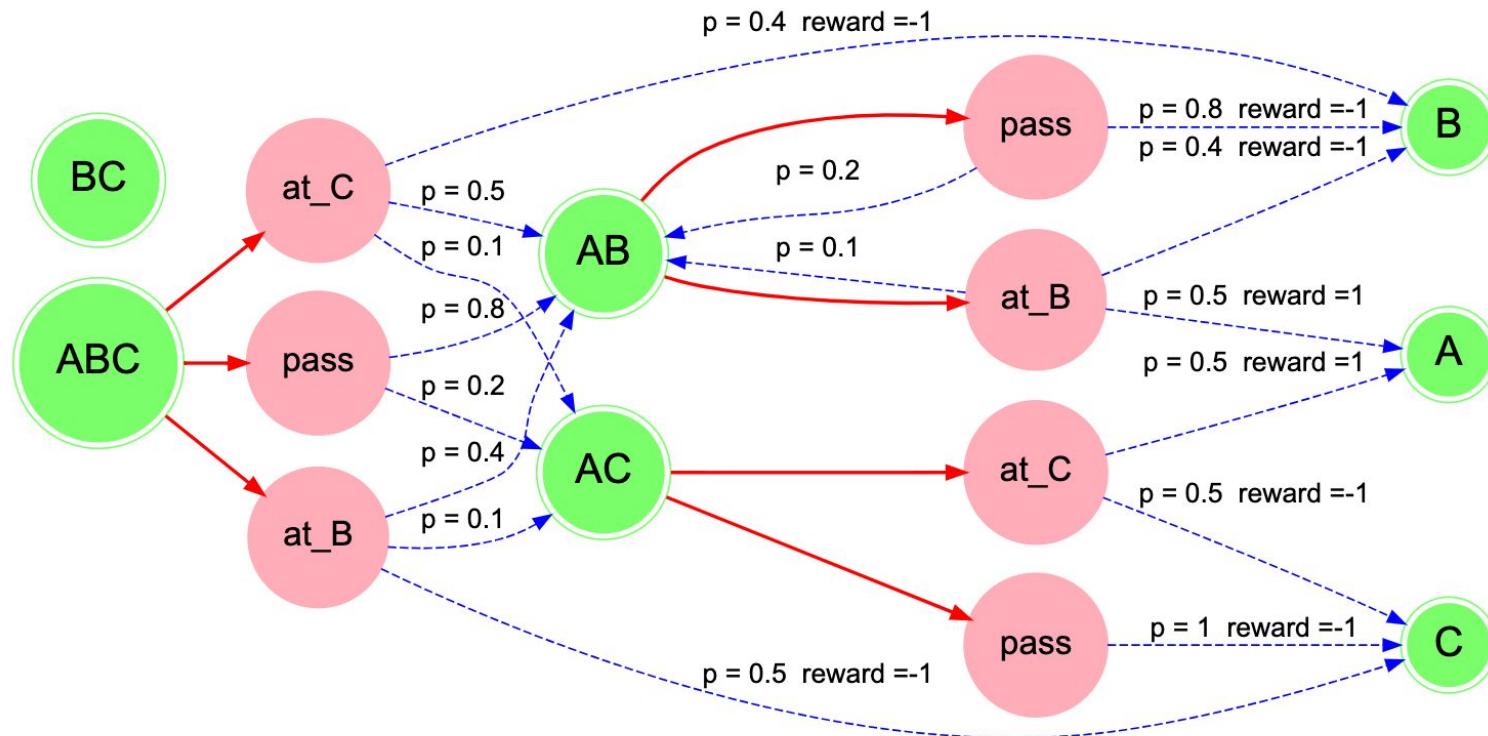


Точность: 50%









Практика



Модификация

Что мы делали?

- Меняли $Q \rightarrow V$
- По Q определяли π

V-функция:

	ABC	AB	AC	BC	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0	0.0
A							

Политика:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Модификация

Что мы делали?

- Меняли $Q \rightarrow V$
- По Q определяли π

V-функция:

	A	B	C	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0
A	NaN	NaN	NaN	NaN	NaN	NaN
AB	0.1	NaN	-0.8	NaN	NaN	NaN
ABC	-0.5	-0.4	0.0	NaN	NaN	NaN
AC	NaN	0.0	-1.0	NaN	NaN	NaN
B	NaN	NaN	NaN	NaN	NaN	NaN
BC	NaN	NaN	NaN	NaN	NaN	NaN
C	NaN	NaN	NaN	NaN	NaN	NaN

Политика:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Модификация

Что мы делали?

- Меняли $Q \rightarrow V$
- По Q определяли π

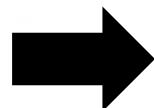
V-функция:

	A	B	C	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0
A	NaN	NaN	NaN	NaN	NaN	NaN
AB	NaN	NaN	NaN	NaN	NaN	NaN
ABC	NaN	NaN	NaN	NaN	NaN	NaN
AC	NaN	NaN	NaN	NaN	NaN	NaN
B	NaN	NaN	NaN	NaN	NaN	NaN
BC	NaN	NaN	NaN	NaN	NaN	NaN
C	NaN	NaN	NaN	NaN	NaN	NaN

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Политика:



	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Модификация

Что мы делали?

- Меняли $Q \rightarrow V$
- По Q определяли π

V-функция:

	A	B	C	A	B	C	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Политика:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Модификация

Что мы делали?

- Меняли $Q \rightarrow V$
- По Q определяли π

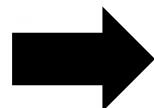
V-функция:

	A	B	C	A	B	C	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0	0.0	0.0	0.0
A	NaN								
AB	NaN								
ABC	NaN								
AC	NaN								
B	NaN								
BC	NaN								
C	NaN								

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Политика:



	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

А так можем?

Что мы делали?

- Меняли $Q \rightarrow V$
- По Q определяли π

V-функция:

	ABC	AB	AC	BC	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0	0.0
A							
AB							
AC							
BC							
C							

Политика:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN



А так можем?

Другой вариант

- Менять π
- По π определять $Q \rightarrow V$

V-функция:

	A	B	C	A	B	C	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0	0.0	0.0	0.0

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Политика:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN



А так можем?

Другой вариант

- Менять π
- По π определять $Q \rightarrow V$
- По Q обновить π

V-функция:

	A B C	A B	A C	B C	A	B	C
0	0.0	0.1	0.0	0.0	0.0	0.0	0.0
A							

Политика:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	1.0	NaN	0.0
ABC	0.0	0.0	1.0
AC	NaN	1.0	0.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN

Q-функция:

	at_B	at_C	pass
A	NaN	NaN	NaN
AB	0.1	NaN	-0.8
ABC	-0.5	-0.4	0.0
AC	NaN	0.0	-1.0
B	NaN	NaN	NaN
BC	NaN	NaN	NaN
C	NaN	NaN	NaN



№5. ДП: Policy-Iteration

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
A	?	?	?
B	?	?	?
C	?	?	?
D	?	?	?

Q:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Политика:

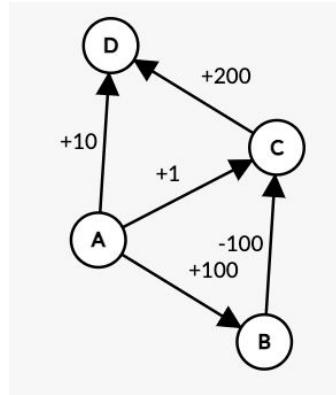
	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B	C	D
A	?	?	?
B	?	?	?
C	?	?	?
D	?	?	?

Q:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
A	0	0	0
B	0	0	0
C	0	0	0
D	0	0	0

Q:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
A	?
B	?



Q:

Алгоритм 6: Policy Evaluation

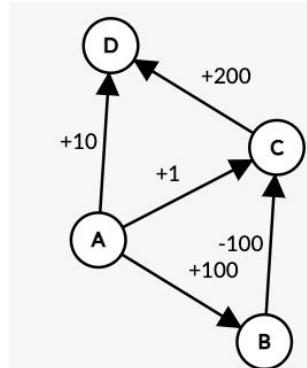
Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$



№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
A	0	0	0
B	0	0	0
C	0	0	0
D	0	0	0

Q:

	A	B	C	D
A	X	100	200	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
A	?
B	?



Q:

Алгоритм 6: Policy Evaluation

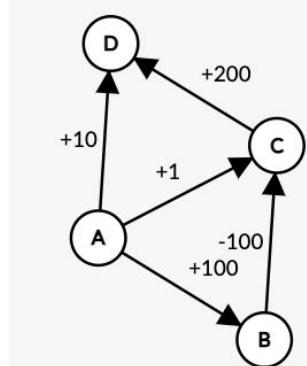
Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$



№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D	
A	100	-100	200	0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

Q:

	A	B	C	D
A	X	100	200	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B	
A	?	?
B	?	?
C	?	?
D	?	?



Q:

Алгоритм 6: Policy Evaluation

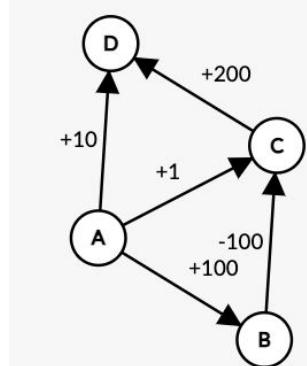
Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$



№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
100	-100	200	0

Q:

	A	B	C	D
A	X			
B	X	X		X
C	X	X	X	X
D	X	X	X	X

Политика:

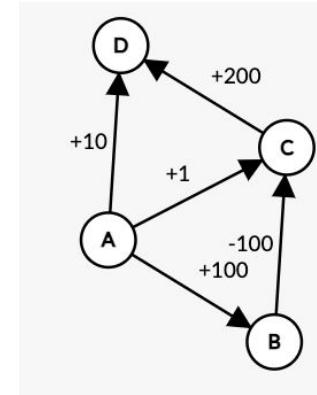
	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:



Алгоритм 6: Policy Evaluation

Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$

№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D	
A	100	-100	200	0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

Q:

	A	B	C	D
A	X	0	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B	
A	?	?
B	X	X
C	X	X
D	X	X



Q:

Алгоритм 6: Policy Evaluation

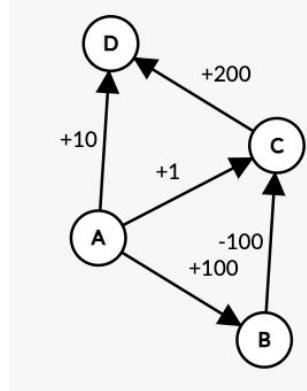
Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$



№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	0	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?

Q:

Алгоритм 6: Policy Evaluation

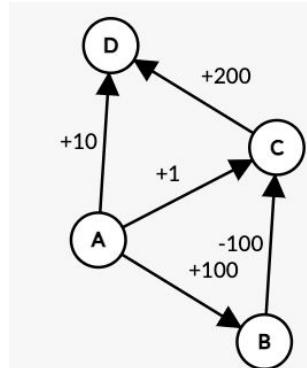
Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$



№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X			
B	X	X		X
C	X	X	X	X
D	X	X	X	X

Политика:

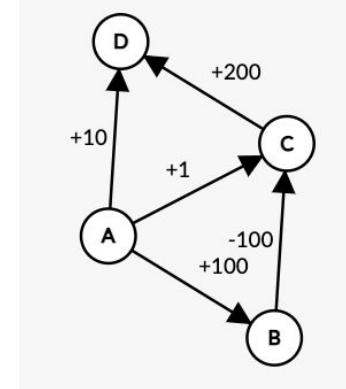
	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:



Алгоритм 6: Policy Evaluation

Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$

№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?

Q:

Алгоритм 6: Policy Evaluation

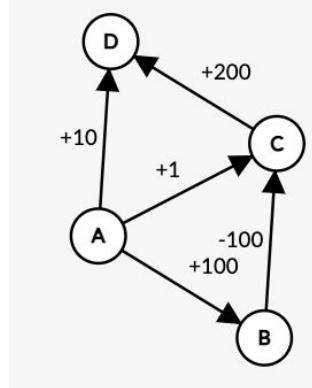
Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$



№5. ДП: Policy-Iteration

Осениваем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?

Q:

Алгоритм 6: Policy Evaluation

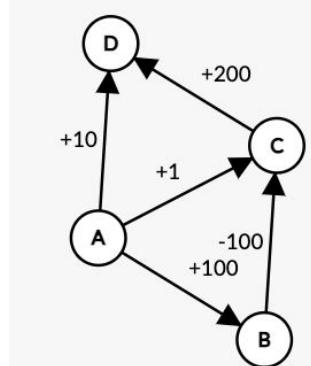
Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ε — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$
На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \varepsilon$

Выход: $V_k(s)$



№5. ДП: Policy-Iteration

Улучшаем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

V:

A	B
?	?



Q:

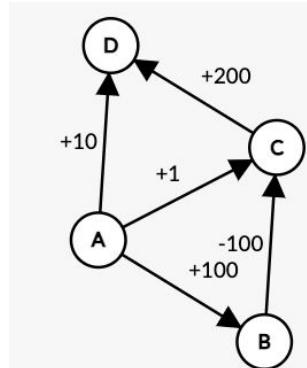
Алгоритм 8: Policy Iteration

Гиперпараметры: ϵ — критерий останова для процедуры PolicyEvaluation

Инициализируем $\pi_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

1. $V^{\pi_k} := \text{PolicyEvaluation}(\pi_k, \epsilon)$
2. $Q^{\pi_k}(s, a) := r(s, a) + \gamma \mathbb{E}_{s'} V^{\pi_k}(s')$
3. $\pi_{k+1}(s) := \underset{a}{\operatorname{argmax}} Q^{\pi_k}(s, a)$
4. критерий останова: $\pi_k \equiv \pi_{k+1}$



№5. ДП: Policy-Iteration

Улучшаем политику

Политика:

	A	B	C	D
A	X	1.0	0.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B	C	D
201	100	200	0

Q:

	A	B	C	D
A	X	200	201	10
B	X	X	100	X
C	X	X	X	200
D	X	X	X	X

Политика:

	A	B	C	D
A	X	1.0	1.0	0.0
B	X	X	1.0	X
C	X	X	X	1.0
D	X	X	X	X

V:

A	B
?	?



Q:

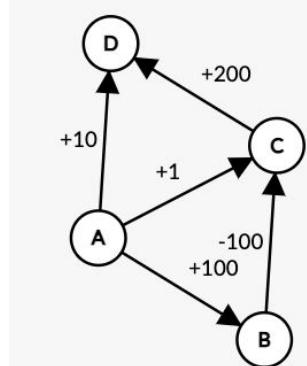
Алгоритм 8: Policy Iteration

Гиперпараметры: ϵ — критерий останова для процедуры PolicyEvaluation

Инициализируем $\pi_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

1. $V^{\pi_k} := \text{PolicyEvaluation}(\pi_k, \epsilon)$
2. $Q^{\pi_k}(s, a) := r(s, a) + \gamma \mathbb{E}_{s'} V^{\pi_k}(s')$
3. $\pi_{k+1}(s) := \underset{a}{\operatorname{argmax}} Q^{\pi_k}(s, a)$
4. критерий останова: $\pi_k \equiv \pi_{k+1}$



Алгоритм Policy Iteration

Алгоритм 8: Policy Iteration

Гиперпараметры: ϵ — критерий останова для процедуры PolicyEvaluation

Инициализируем $\pi_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

1. $V^{\pi_k} := \text{PolicyEvaluation}(\pi_k, \epsilon)$
2. $Q^{\pi_k}(s, a) := r(s, a) + \gamma \mathbb{E}_{s'} V^{\pi_k}(s')$
3. $\pi_{k+1}(s) := \underset{a}{\operatorname{argmax}} Q^{\pi_k}(s, a)$
4. критерий останова: $\pi_k \equiv \pi_{k+1}$

Алгоритм 6: Policy Evaluation

Вход: $\pi(a | s)$ — стратегия

Гиперпараметры: ϵ — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

1. $\forall s: V_{k+1}(s) := \mathbb{E}_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
2. критерий останова: $\max_s |V_k(s) - V_{k+1}(s)| < \epsilon$

Выход: $V_k(s)$

Model-free

Проблема

- А если мы не знаем **динамику среды?**
- ... Или нам ее сложно описать

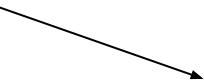
Не знаем меткость
игроков

$$p(s' \mid s, a)$$

```
dynamics = {
    'ABC': {
        'at_B': {
            'C': 0.5, # Попали, убили В. С гарантированно убил нас.
            'AC': 0.5 * 0.2, # Не попали. В промахнулся. С убил В.
            'AB': 0.5 * 0.8 # Не попали. В попал.
        },
        'at_C': {
            'B': 0.5 * 0.8, # Мы попали. В стрелял в нас и попал
            'AB': 0.5 * 0.2 + 0.5 * 0.8, # Мы попали. В стрелял в нас и промах
            'AC': 0.5 * 0.2, # Мы промахнулись. В стрелял в С и не попал. С уби
        },
        'pass': {
            'AB': 0.8, # В попал в С
            'AC': 0.2 # В не попал в С
        }
    },
}
```

В каком месте проблема?

- А если мы не знаем **динамику среды**?
- ... Или нам ее сложно описать



$$p(s' \mid s, a)$$

Алгоритм 7: Value Iteration

Вход: ϵ — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

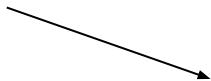
1. для всех s : $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$

2. критерий останова: $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход: $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

В каком месте проблема?

- А если мы не знаем **динамику среды**?
- ... Или нам ее сложно описать



$$p(s' \mid s, a)$$

Алгоритм 7: Value Iteration

Вход: ϵ — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

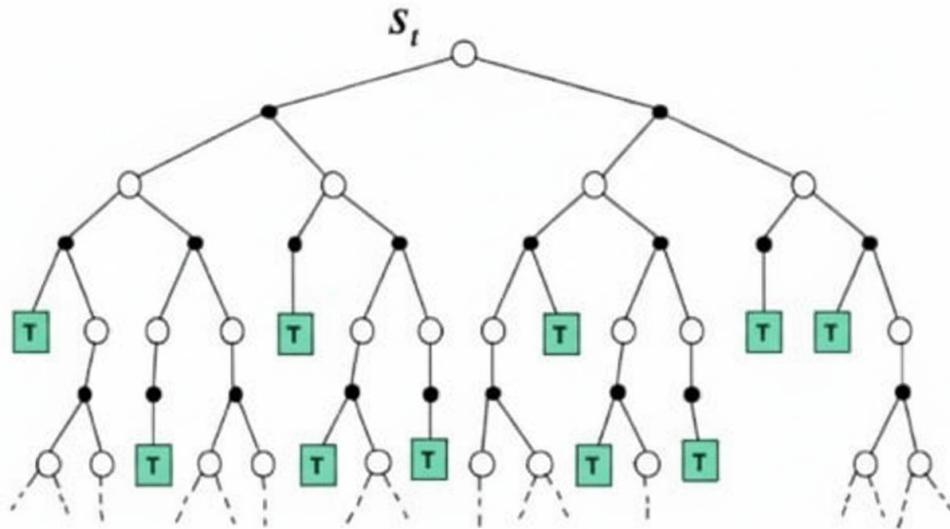
1. для всех s : $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$

Не сможем посчитать мат.
ожидание по всем
переходам

2. критерий останова: $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход: $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

Сейчас:



Алгоритм 7: Value Iteration

Вход: ϵ — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

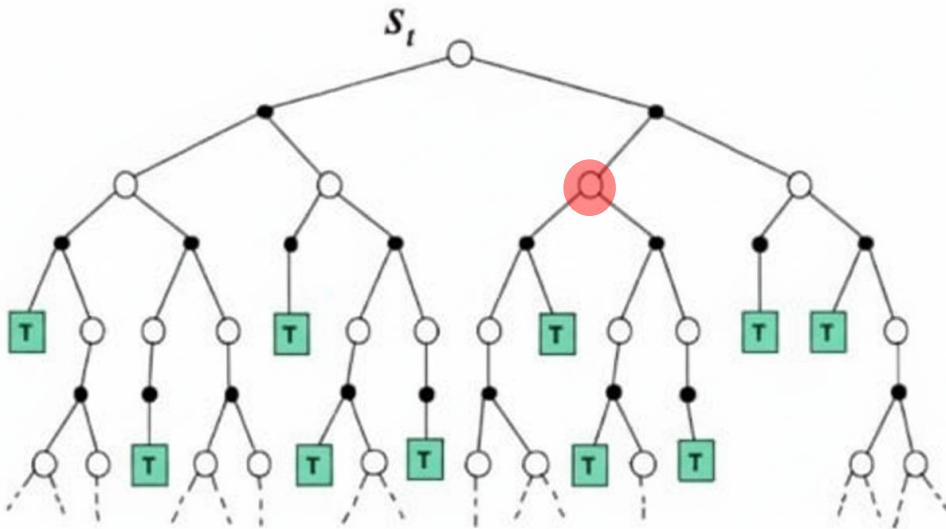
- для всех s : $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$

- критерий останова: $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход: $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

Не сможем посчитать мат.
ожидание по всем
переходам

Сейчас:



Алгоритм 7: Value Iteration

Вход: ϵ — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$

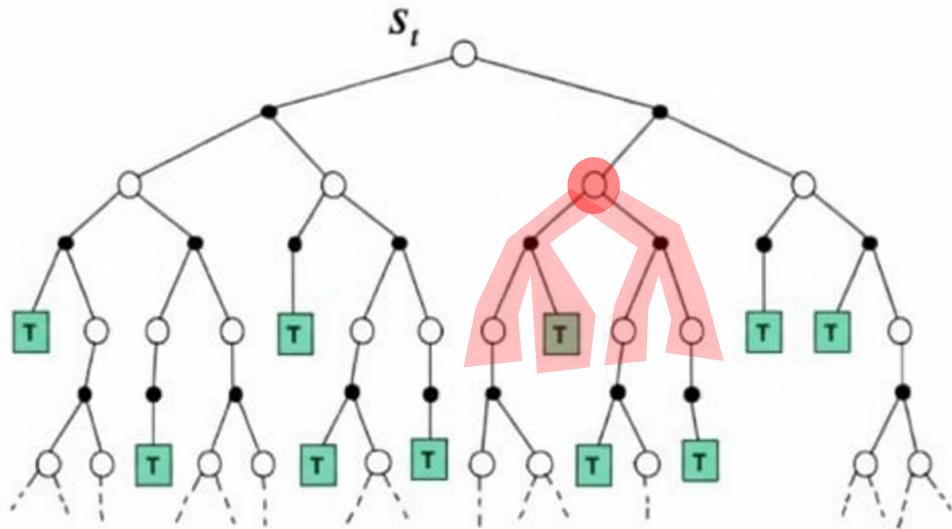
На k -ом шаге:

- для всех s : $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова: $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход: $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

Не сможем посчитать мат.
ожидание по всем
переходам

Сейчас:



Алгоритм 7: Value Iteration

Вход: ϵ — критерий останова

Инициализируем $V_0(s)$ произвольно для всех $s \in \mathcal{S}$

На k -ом шаге:

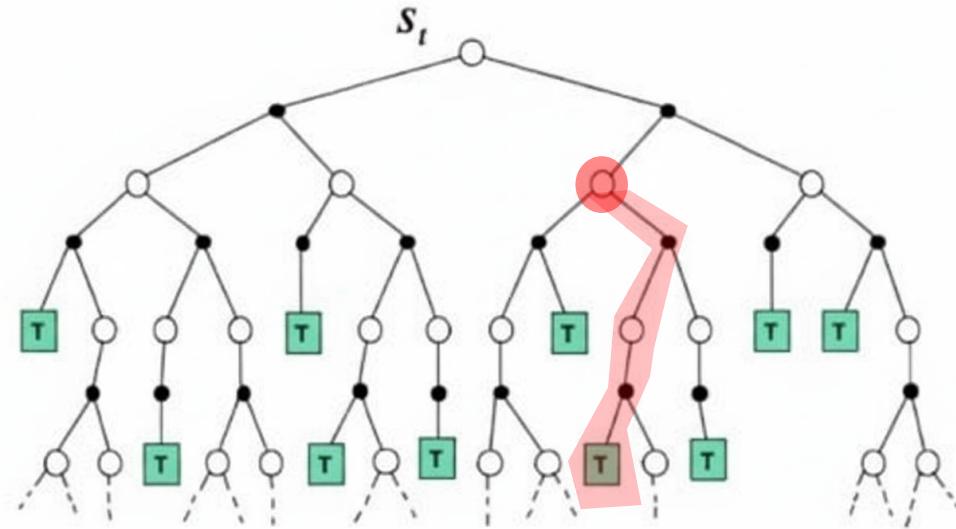
- для всех s : $V_{k+1}(s) := \max_a [r(s, a) + \gamma \mathbb{E}_{s'} V_k(s')]$
- критерий останова: $\max_s |V_{k+1}(s) - V_k(s)| < \epsilon$

Выход: $\pi(s) := \operatorname{argmax}_a [r(s, a) + \gamma \mathbb{E}_{s'} V(s')]$

Не сможем посчитать мат.
ожидание по всем
переходам

Идея:

Играть до конца и
усреднять!



Монте-Карло

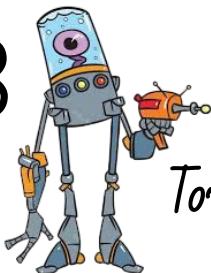
Метод Монте-Карло

A



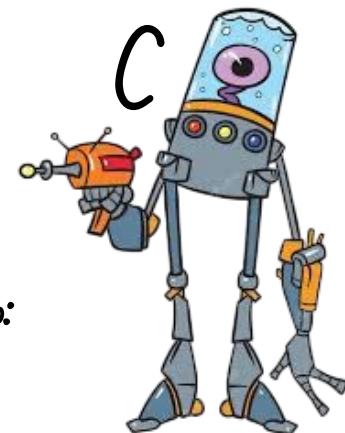
Точность: 50%

B



Точность: 80%

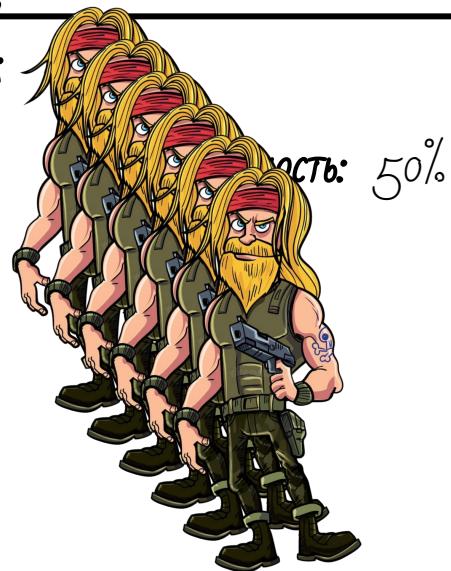
C



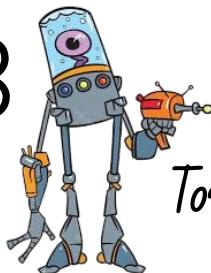
Точность:
100%

Шаг 1: Запасаемся агентами

A

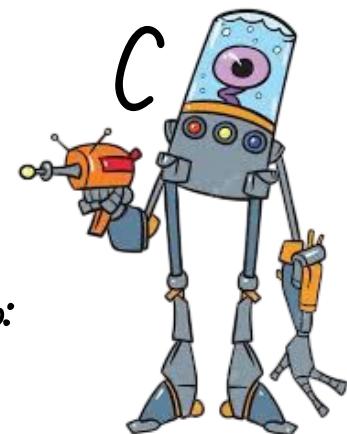


B



Точность: 80%

C

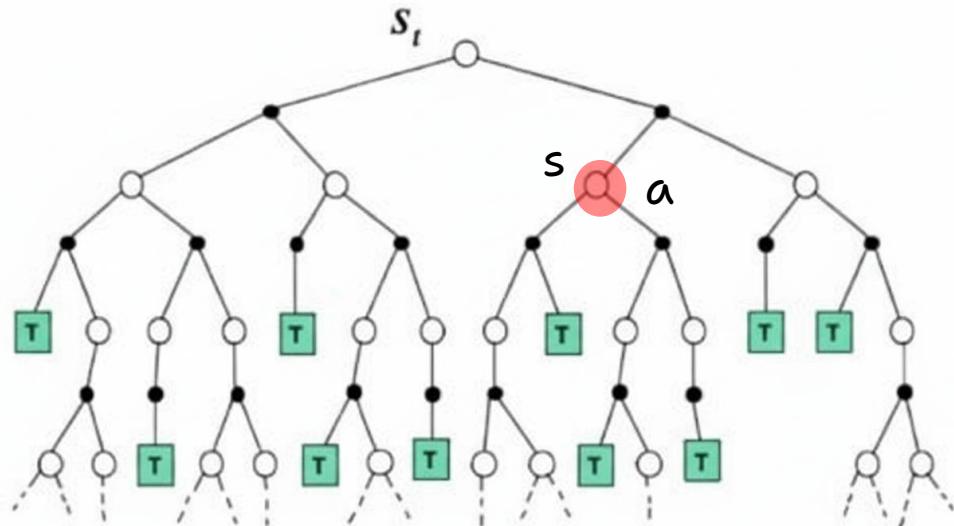


Точность:
100%

Шаг 2: Можем оценить Q средним

$Q^{\pi_k}(s, a) \approx$

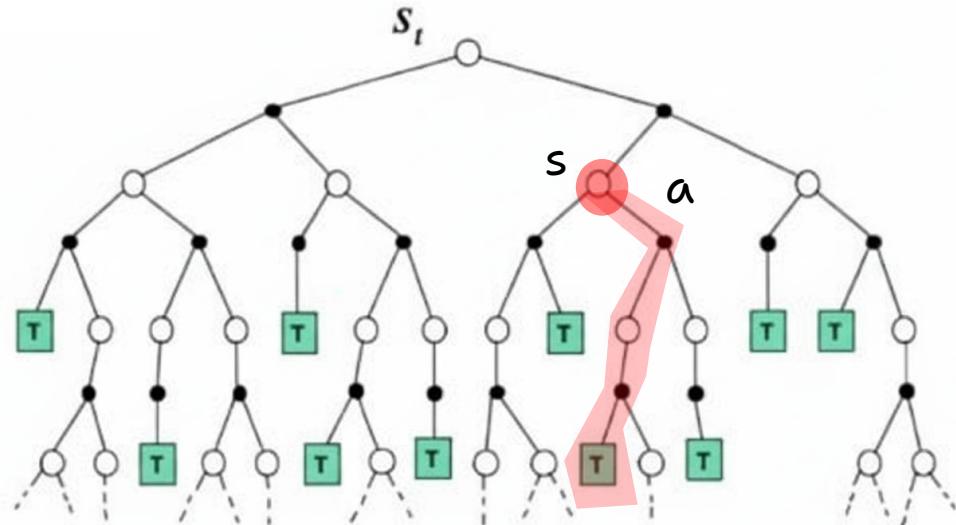
Для фиксированной
политики



Шаг 2: Можем оценить Q средним

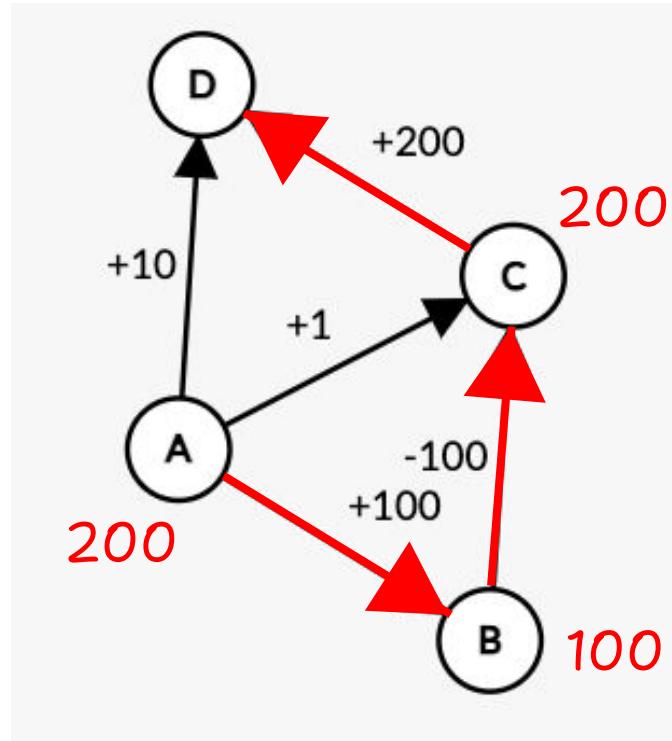
$$Q^{\pi_k}(s, a) \approx \frac{1}{N} \sum_{i=0}^N R(\mathcal{T}_i), \quad \mathcal{T}_i \sim \pi_k \mid s_0 = s, a_0 = a$$

Для фиксированной
политики



Модификация 1

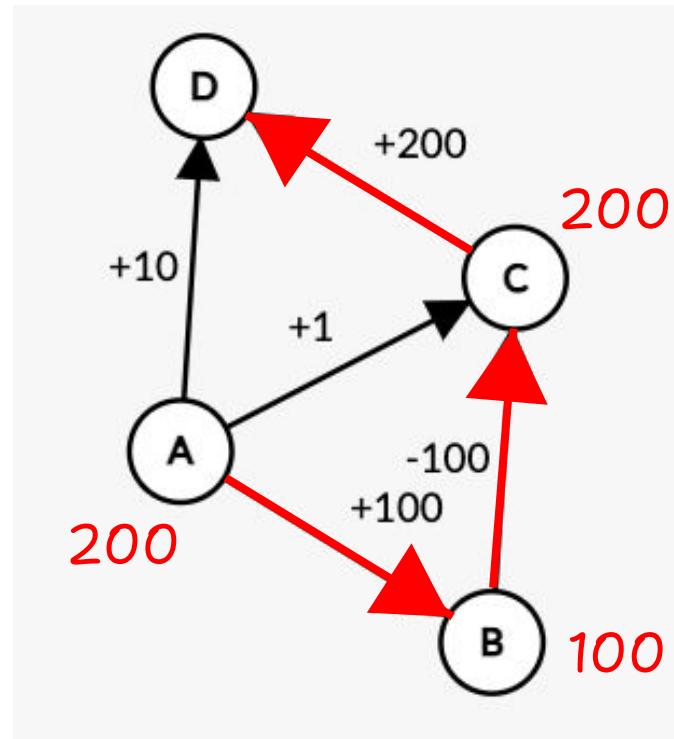
$(s, a): [(r, s'), ...]$



Модификация 1

$(s, a): [(r, s'), \dots]$

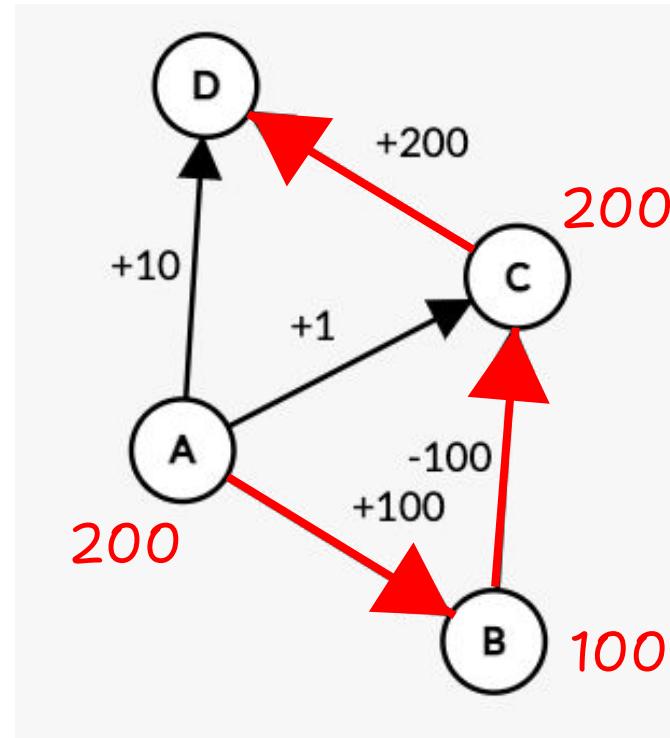
Первый **off-policy** алгоритм!



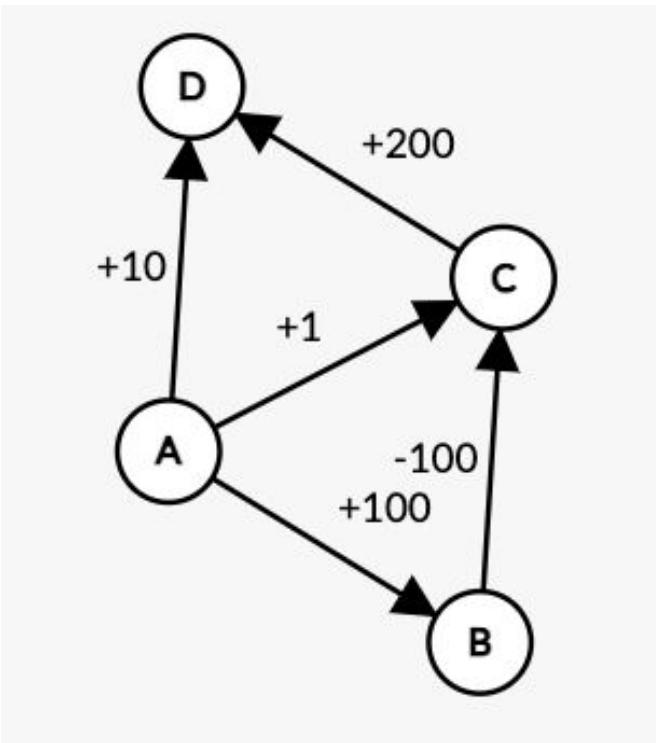
Off-policy

- **Target-policy** – стратегия, стремящаяся максимизировать суммарную награду
- **Behavior policy** – стратегия сбора данных

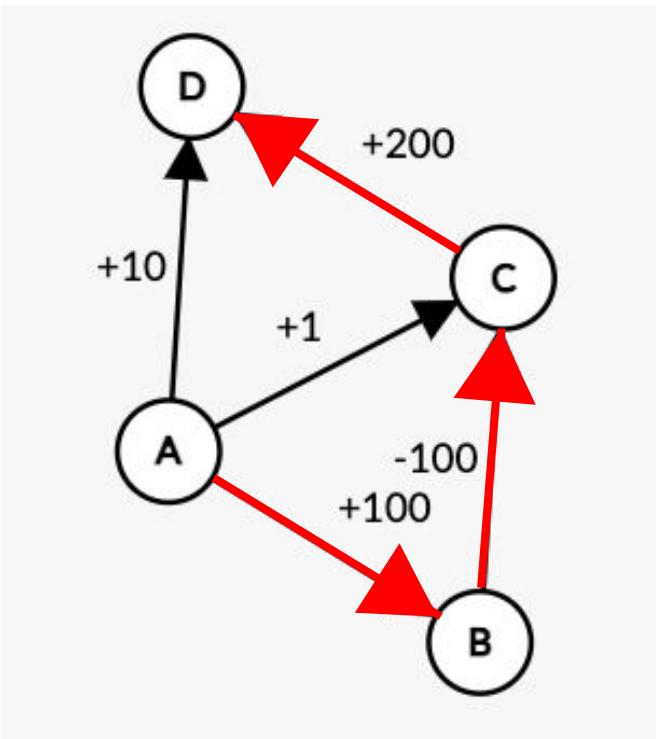
Off-policy алгоритм может обучаться на данных от произвольной *behavior policy*



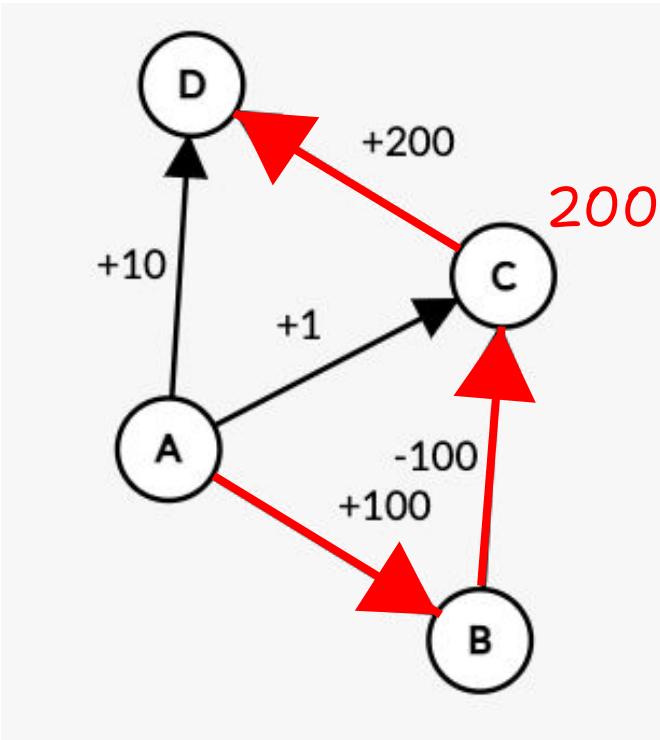
Пример



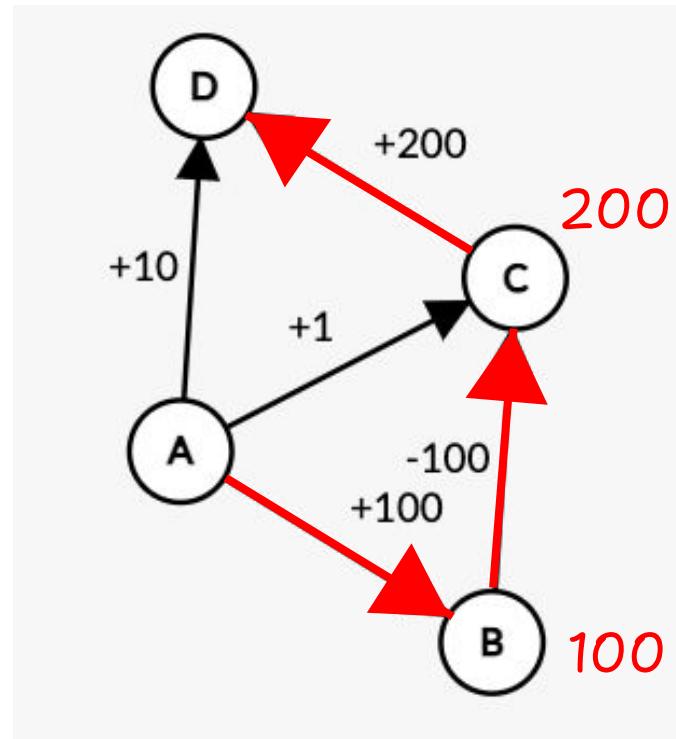
Пример



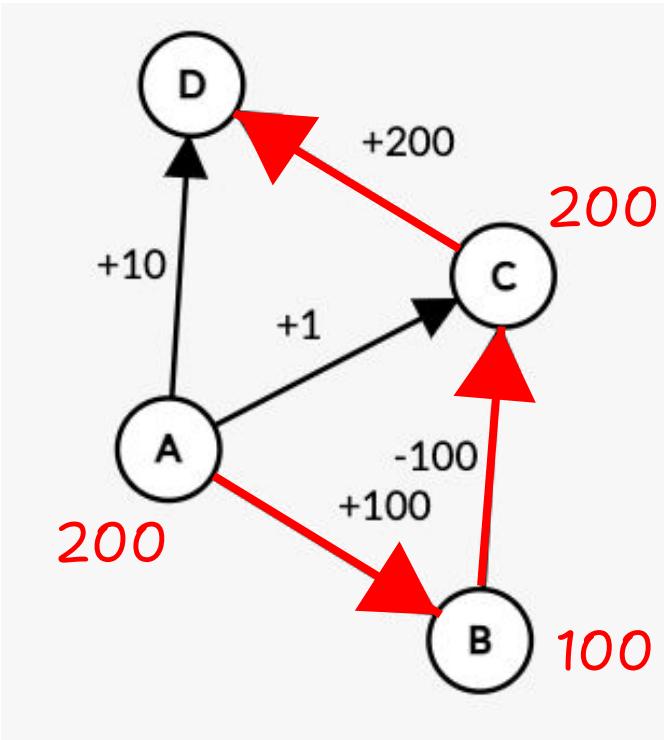
Пример



Пример

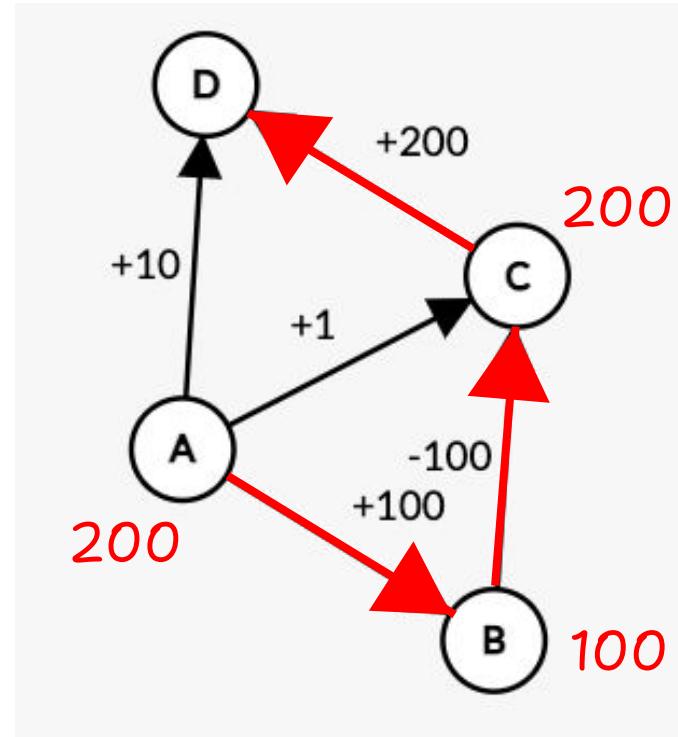


Пример



reward-to-go

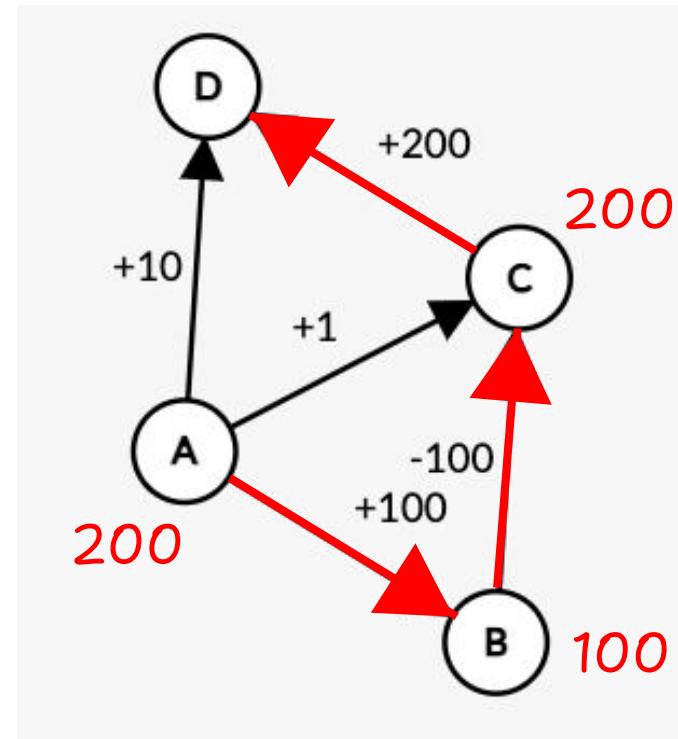
$$R_t := R(\mathcal{T}_{t:}) = \sum_{\hat{t} \geq t} \gamma^{\hat{t}-t} r_{\hat{t}}$$



reward-to-go

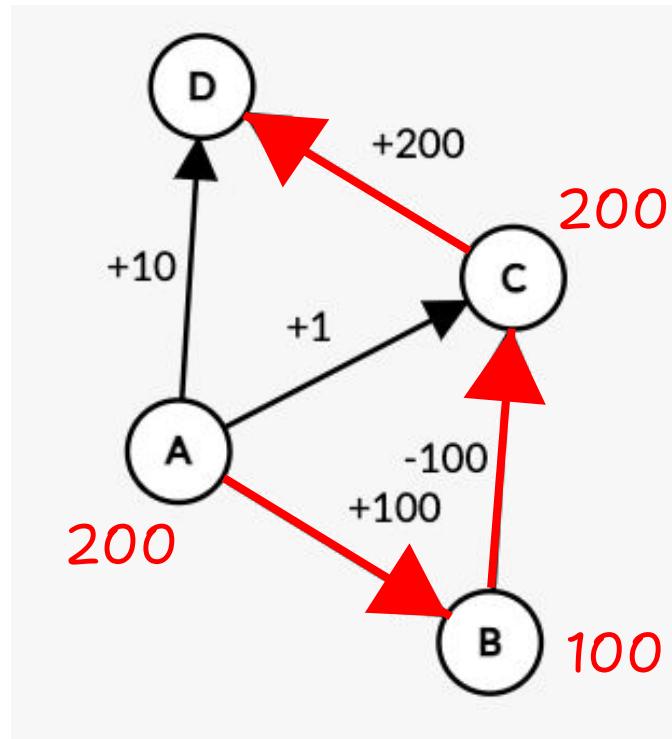
$$R_t := R(\mathcal{T}_{t:}) = \sum_{\hat{t} \geq t} \gamma^{\hat{t}-t} r_{\hat{t}}$$

$$Q^{\pi_k}(s, a) \approx \frac{1}{N} \sum_{i=0}^N R(\mathcal{T}_i), \quad \mathcal{T}_i \sim \pi_k \mid s_0 = s, a_0 = a$$



Проблемы

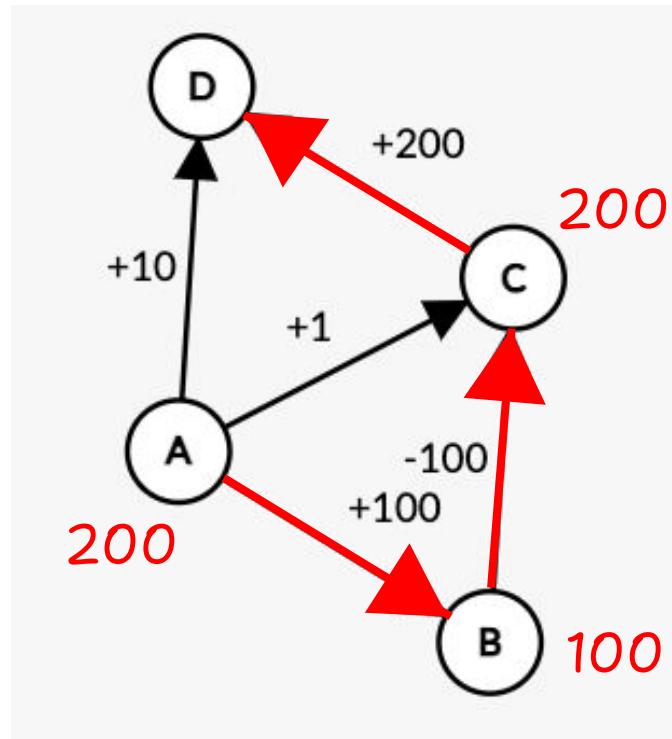
1. На этом мы закончили ...



Проблемы

1. На этом мы закончили ...

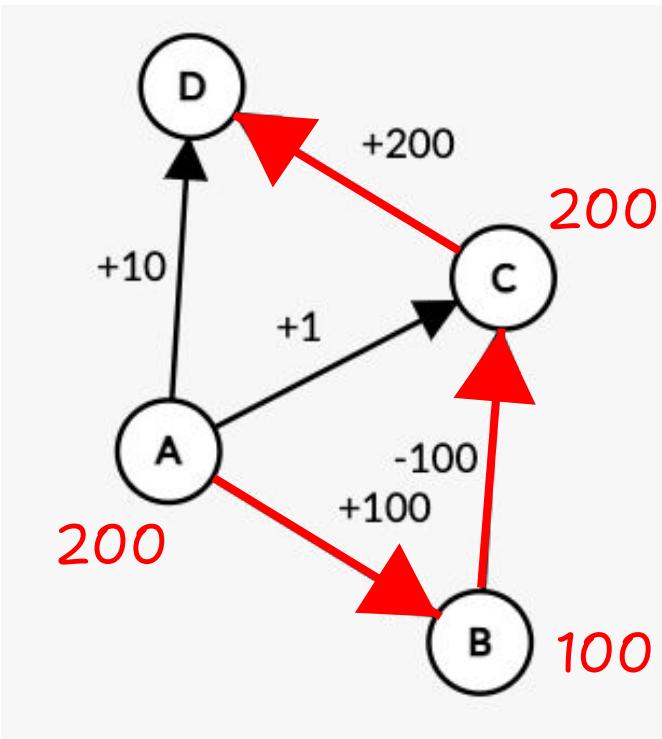
Наша политика не включала ребро AC, поэтому мы не скорректировали политику



Модификация 1

epsilon-жадная стратегия

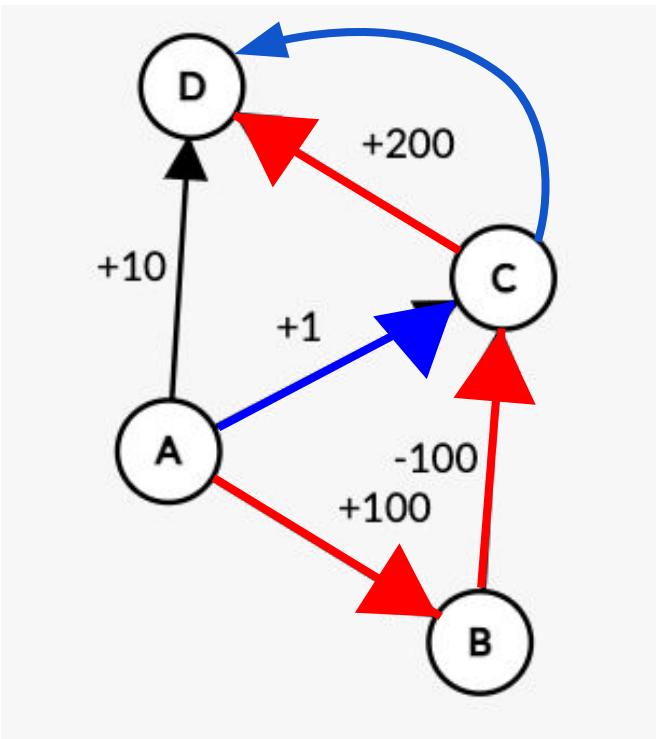
с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$



Модификация 1

epsilon-жадная стратегия

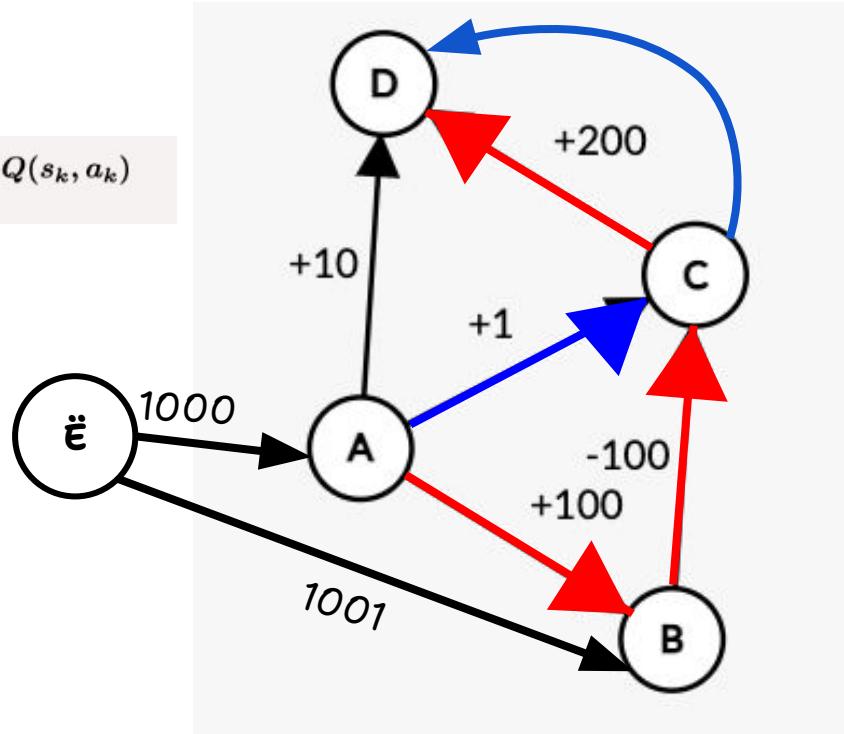
с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$



Модификация 1

epsilon-жадная стратегия

с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

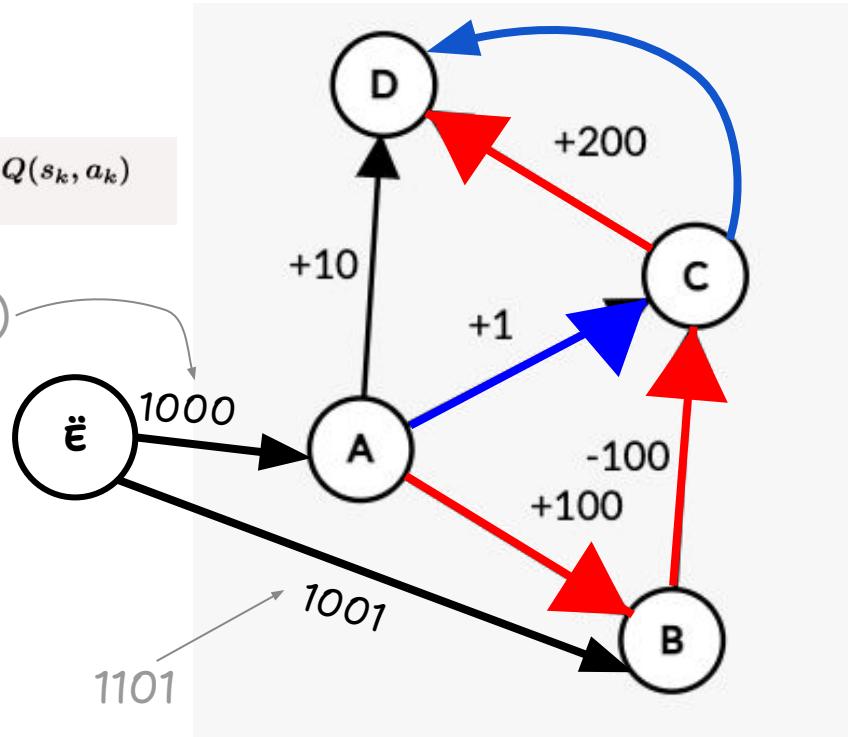


Модификация 1

epsilon-жадная стратегия

с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

$\frac{1}{2} (1201 + 1200)$

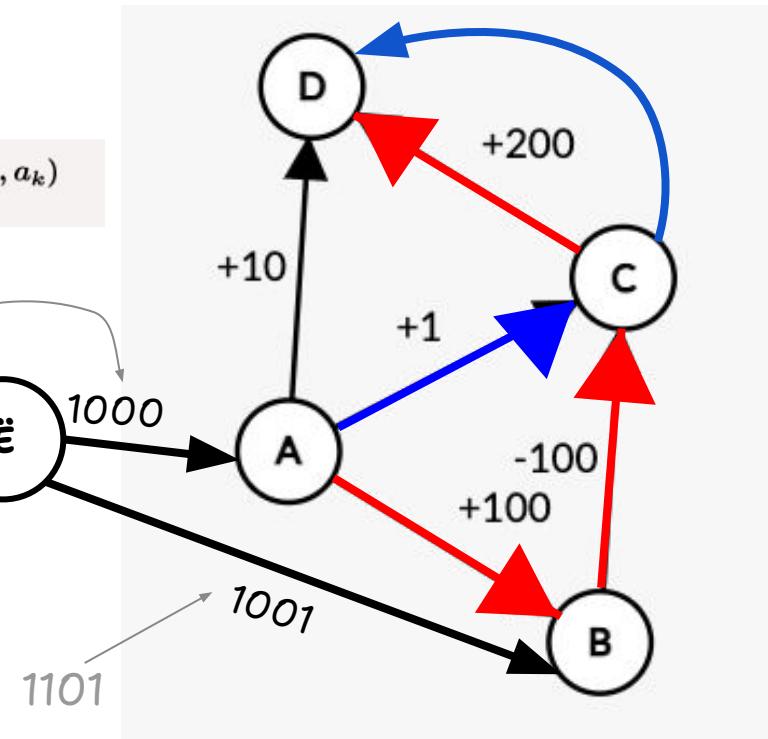


Модификация 1

epsilon-жадная стратегия

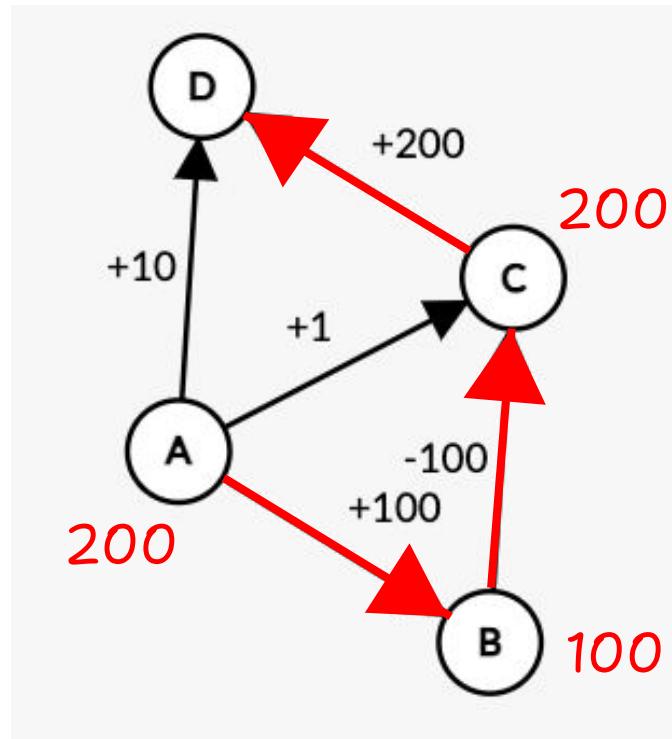
с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

$$\frac{1}{9} * 1201 + \frac{8}{9} * 1200$$



Проблемы

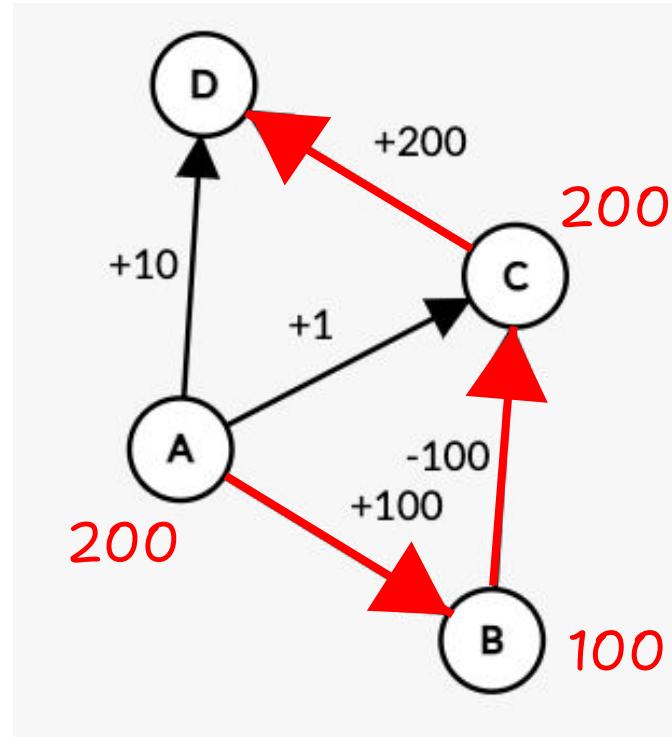
1. Если политика не включала ребро, то нет шансов включить его в **target policy**.



Проблемы

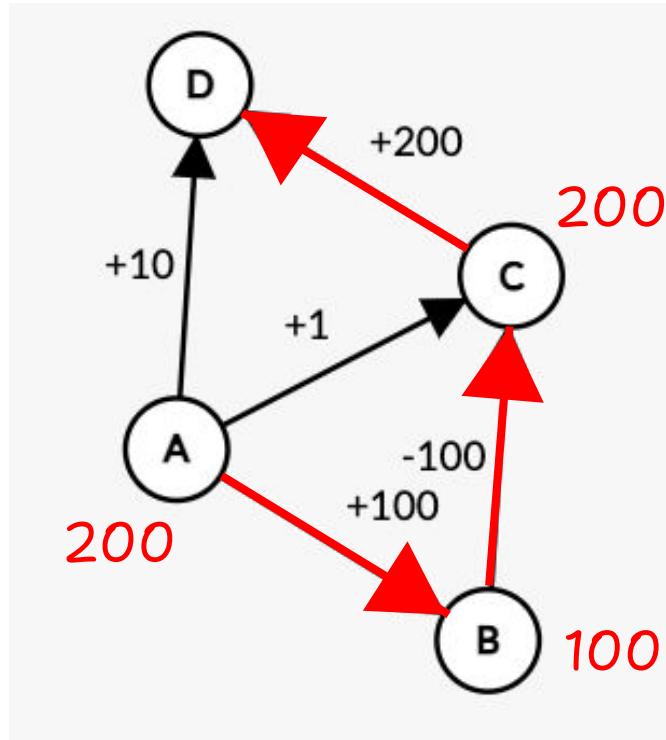
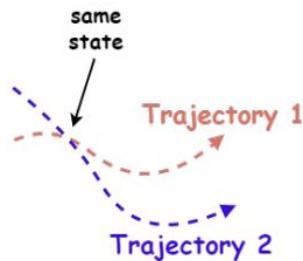
1. Если политика не включала ребро, то нет шансов включить его в **target policy**.
2. Нужно доигрывать эпизоды до конца

Когда обновлять политику?



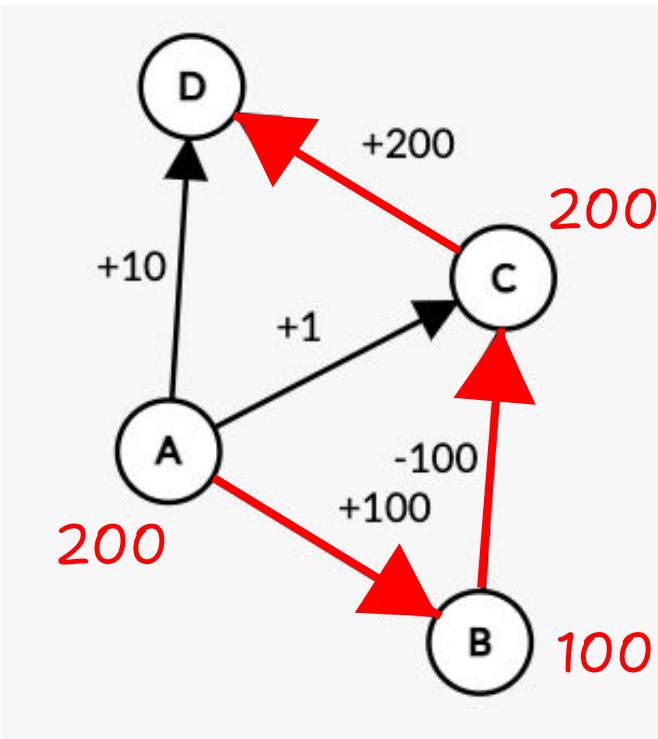
Проблемы

1. Если политика не включала ребро, то нет шансов включить его в **target policy**.
2. Нужно доигрывать эпизоды до конца
3. Теряем кучу информации на пересечениях



Модификация 2

Давайте сразу менять Q!



Модификация 2

Давайте сразу менять Q!

1. Устанавливаем количество эпизодов N .
2. Внутри эпизода начинаем проходить по шагам траектории t и на каждом шаге:
 - Выполняем выбранное действие и получаем следующее состояние, вознаграждение и флаг завершения
 - Получаем следующее действие с использованием ϵ -жадной стратегии
 - Обновляем Q-функцию с использованием следующего состояния и следующего действия **согласно политики**
 - Добавляем полученное вознаграждение к общему вознаграждению текущего эпизода
3. Завершаем эпизод, обновляем ϵ и переходим к следующему эпизоду.



SARSA

Давайте сразу менять Q!

1. Устанавливаем количество эпизодов N .
2. Внутри эпизода начинаем проходить по шагам траектории t и на каждом шаге:
 - Выполняем выбранное действие и получаем следующее состояние, вознаграждение и флаг завершения
 - Получаем следующее действие с использованием ϵ -жадной стратегии
 - Обновляем Q-функцию с использованием следующего состояния и следующего действия **согласно политики**
 - Добавляем полученное вознаграждение к общему вознаграждению текущего эпизода
3. Завершаем эпизод, обновляем ϵ и переходим к следующему эпизоду.



Q-learning

Давайте сразу менять Q!

1. Устанавливаем количество эпизодов N .
2. Внутри эпизода начинаем проходить по шагам траектории t и на каждом шаге:
 - Выполняем выбранное действие и получаем следующее состояние, вознаграждение и флаг завершения
 - Получаем следующее действие с использованием epsilon-жадной стратегии
 - Обновляем Q-функцию с использованием следующего состояния и следующего действия ~~согласно политики~~ **ЖАДНО**
 - Добавляем полученное вознаграждение к общему вознаграждению текущего эпизода
3. Завершаем эпизод, обновляем ϵ и переходим к следующему эпизоду.



Алгоритм Q-learning

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального сглаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$
2. наблюдаем r_k, s_{k+1}
3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

Задание 7. $\epsilon = 0$ $\gamma = 1.0$ $a = 1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

s_0	a_0	r_0	s_1
A	?	?	?

s_1	a_1	r_1	s_2
?	?	?	?

s_2	a_2	r_2	s_3
?	?	?	?

s_3	a_3	r_3	s_4
?	?	?	?

s_4	a_4	r_4	s_5
?	?	?	?

Q0:

	A	B	C	D
A	0	0	0	0
B	0	0	0	0
C	0	0	0	0
D	0	0	0	0

Q1:

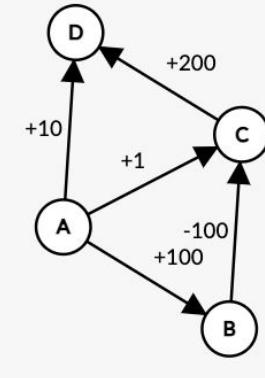
	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q2:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут



Задание 7. $\epsilon = 0$ $\gamma = 1.0$ $\alpha = 1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

s_0	a_0	r_0	s_1
A	?	?	?

s_1	a_1	r_1	s_2
?	?	?	?

s_2	a_2	r_2	s_3
?	?	?	?

s_3	a_3	r_3	s_4
?	?	?	?

s_4	a_4	r_4	s_5
?	?	?	?

Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

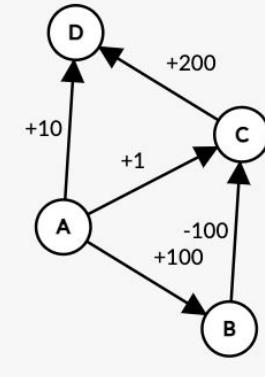
	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q2:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут



Задание 7. $\epsilon = 0$ $\gamma = 1.0$ $\alpha = 1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

$$3. \text{ обновляем } Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$$



s_0	a_0	r_0	s_1
A	AD	?	?

Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

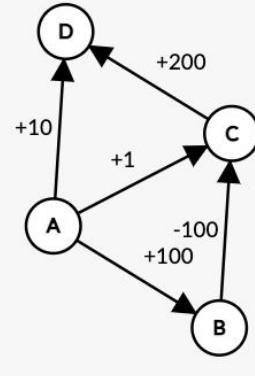
Q2:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q3-....:

s_3	a_3	r_3	s_4
?	?	?	?

s_4	a_4	r_4	s_5
?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon = 0$ $\gamma = 1.0$ $\alpha = 1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

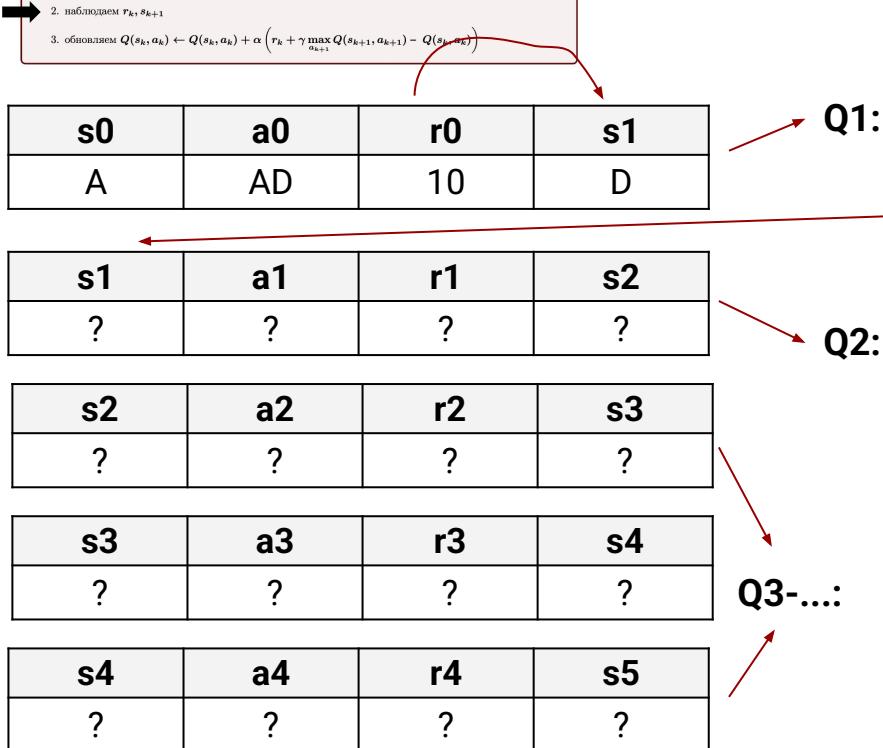
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

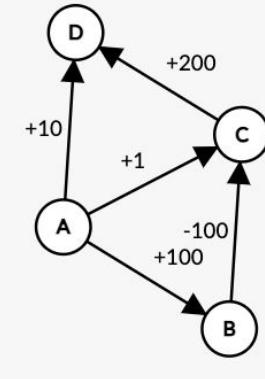
	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q2:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon = 0$ $\gamma = 1.0$ $\alpha = 1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

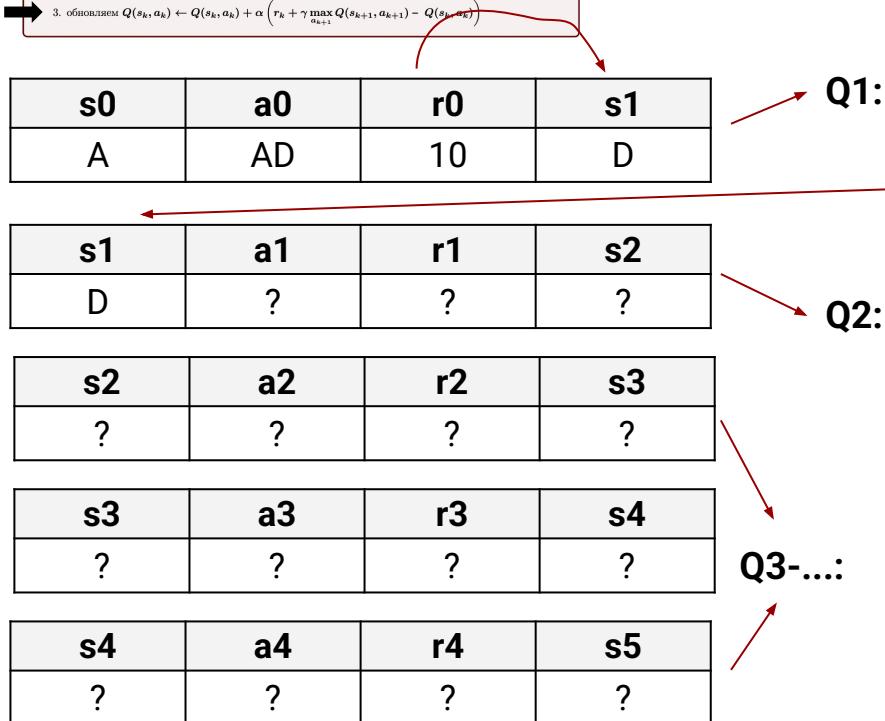
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

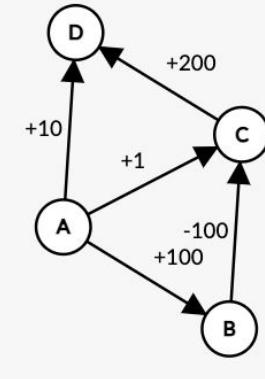
	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q2:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon = 0$ - $\gamma = 1.0$ $\alpha = 1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

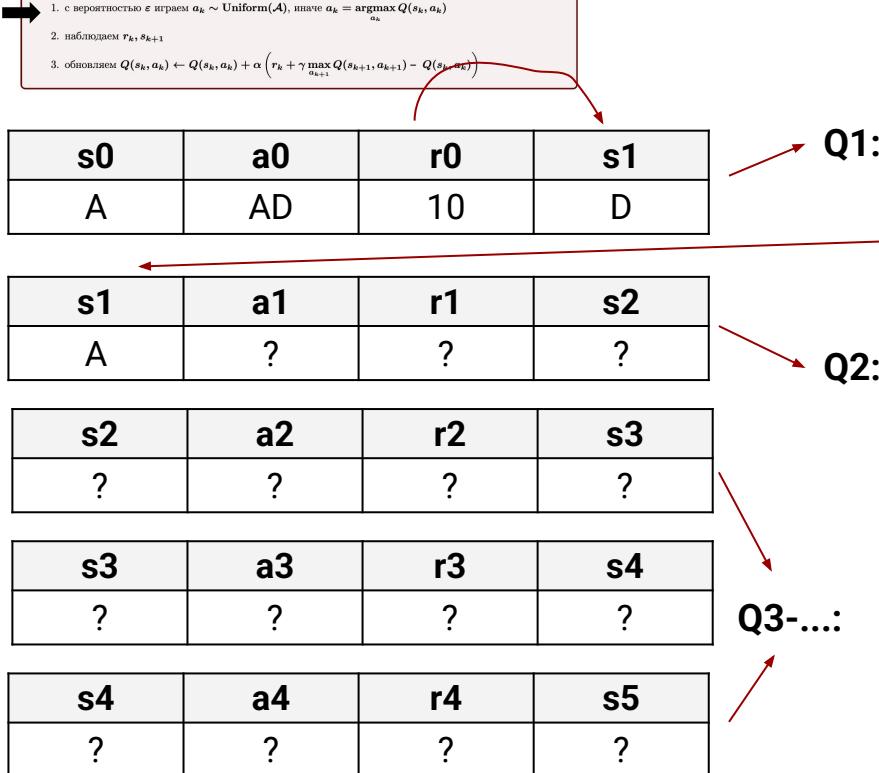
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



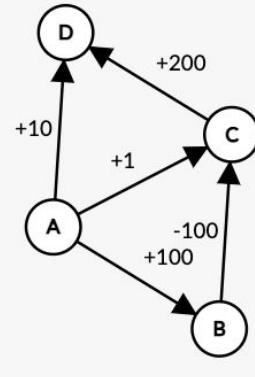
Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

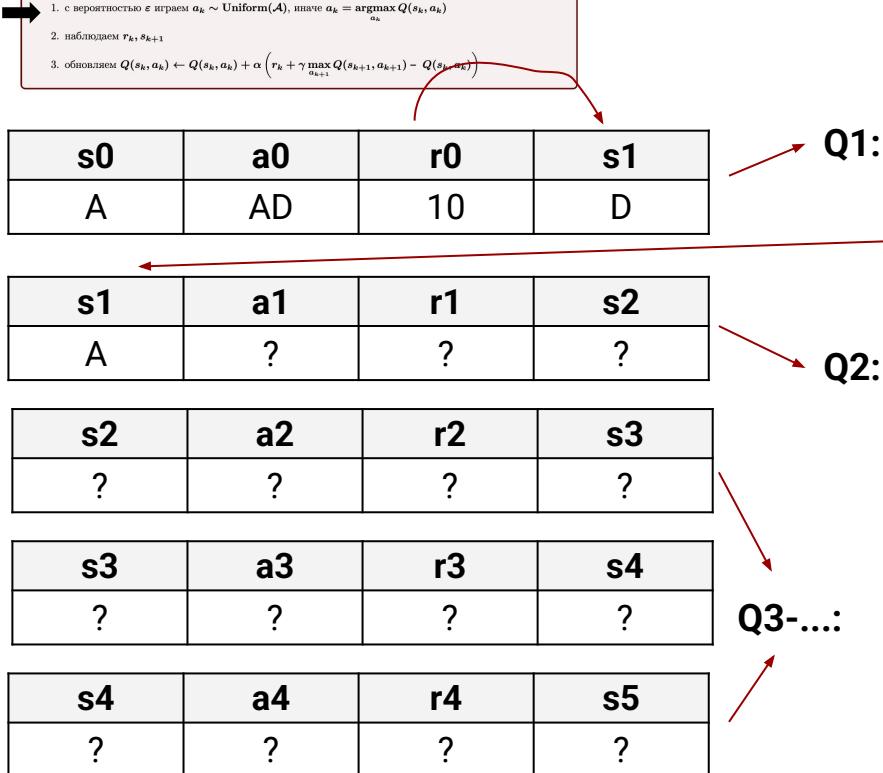
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



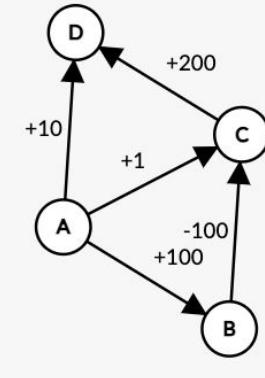
Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

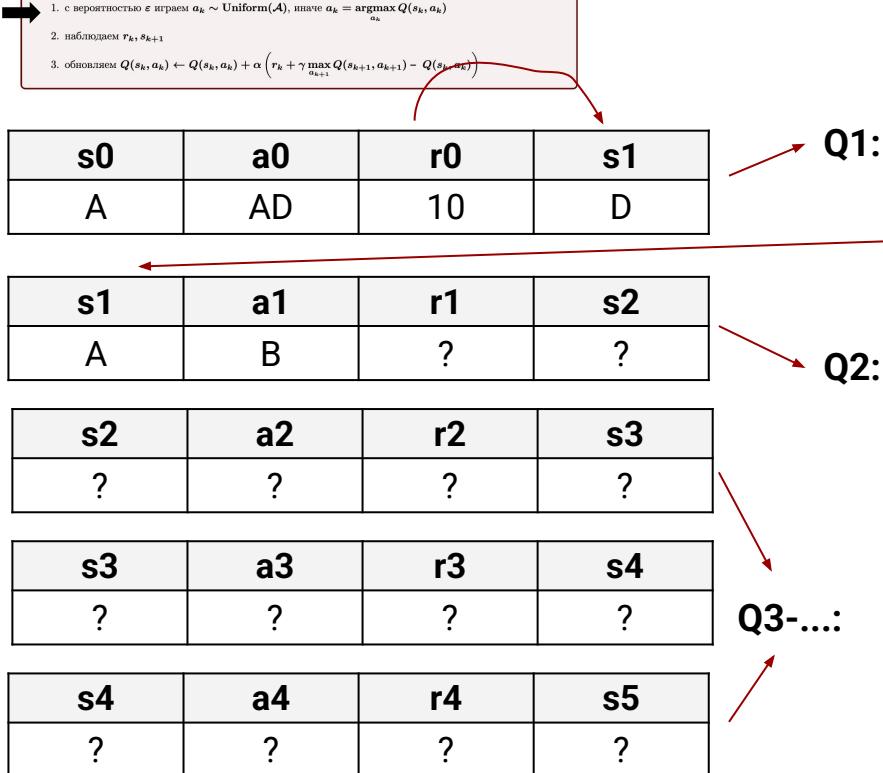
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

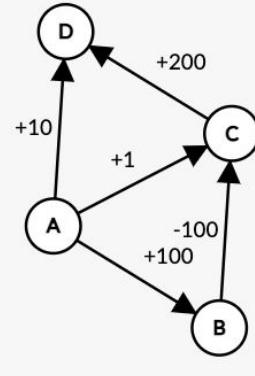
	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q2:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

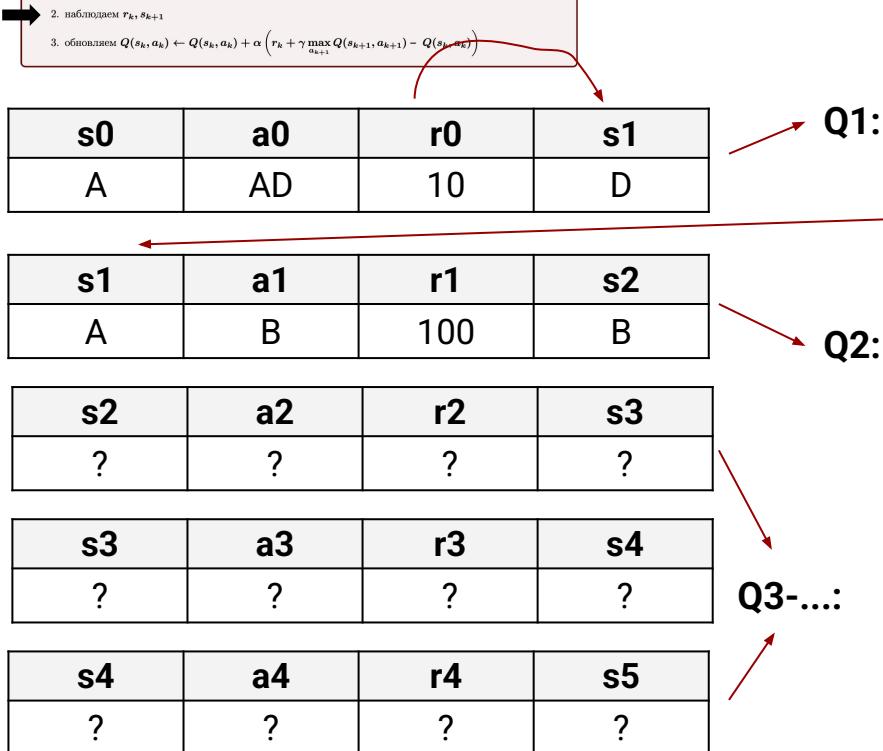
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

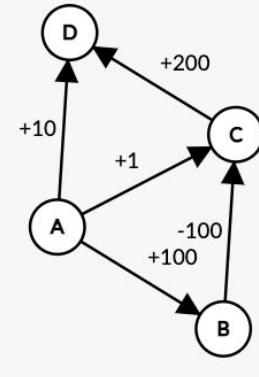
	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q2:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

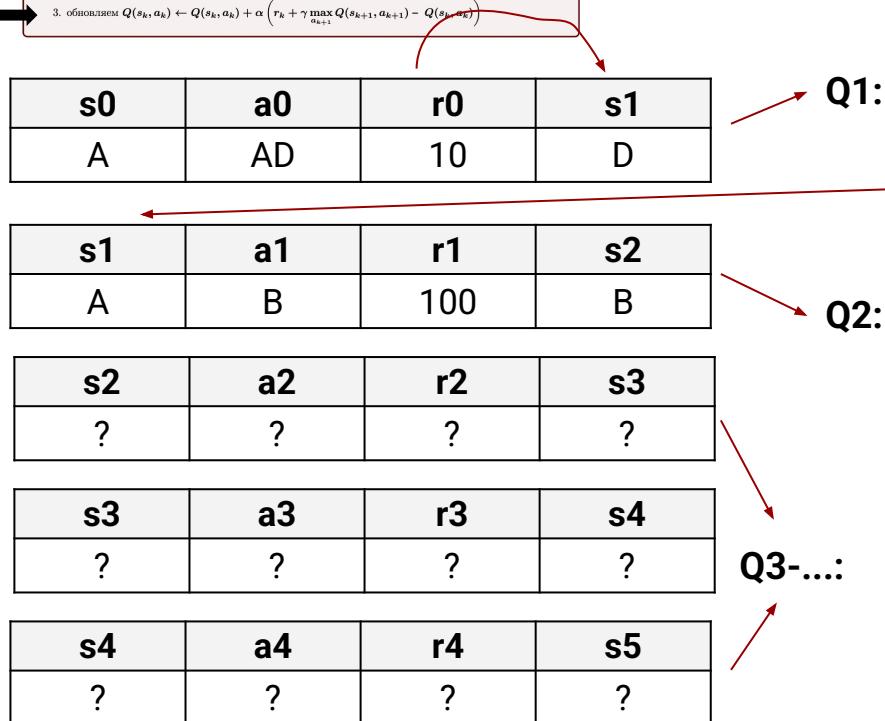
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

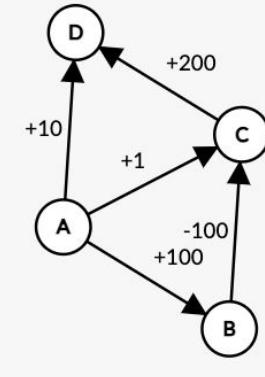


	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

	A	B	C	D
A	✗	100	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

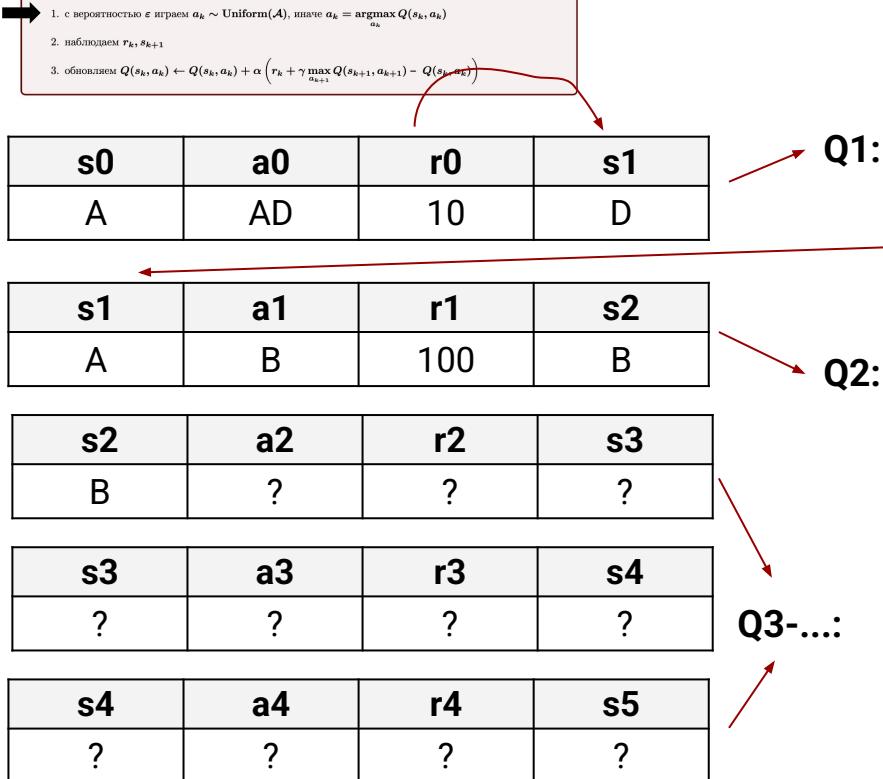
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q1:

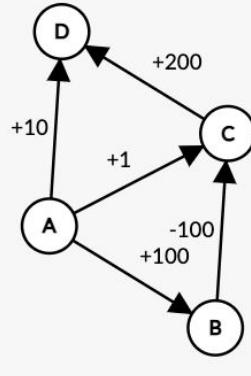
	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q2:

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

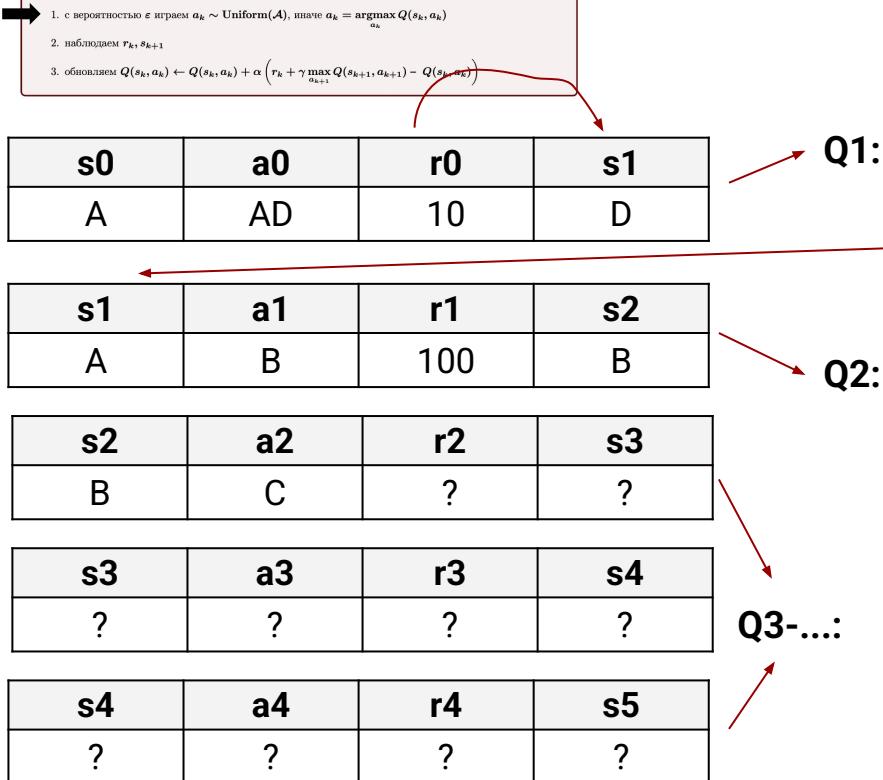
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q1:

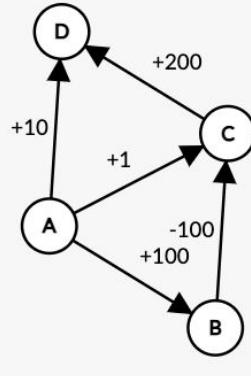
	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q2:

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q3-....:

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

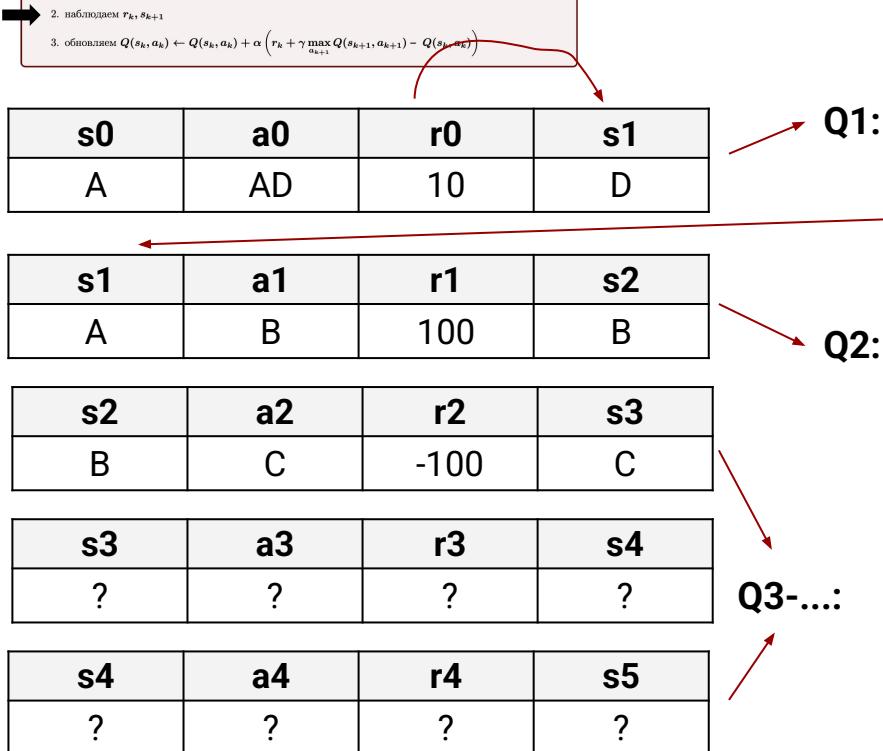
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



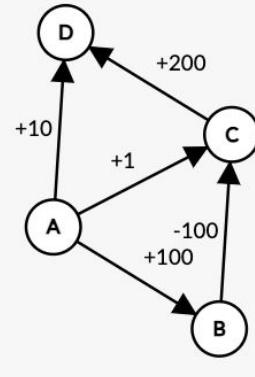
Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	?	?	?	?
B	?	?	?	?
C	?	?	?	?
D	?	?	?	?



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

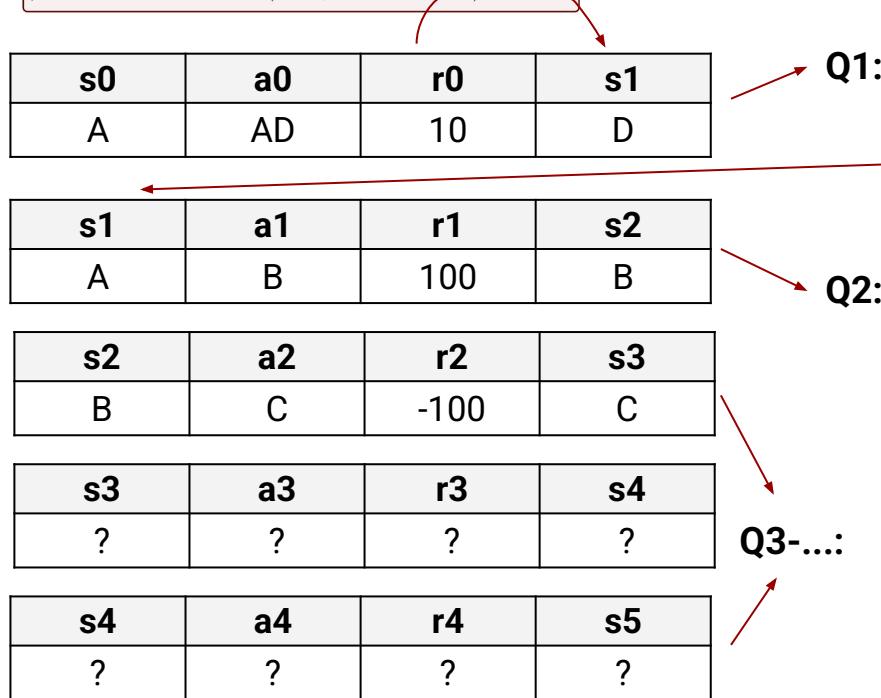
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



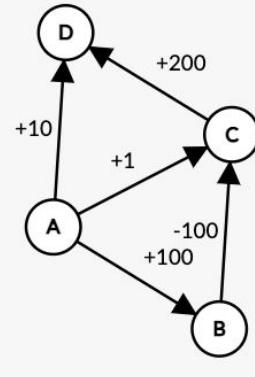
Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	-100	X
C	X	X	X	0
D	X	X	X	X



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

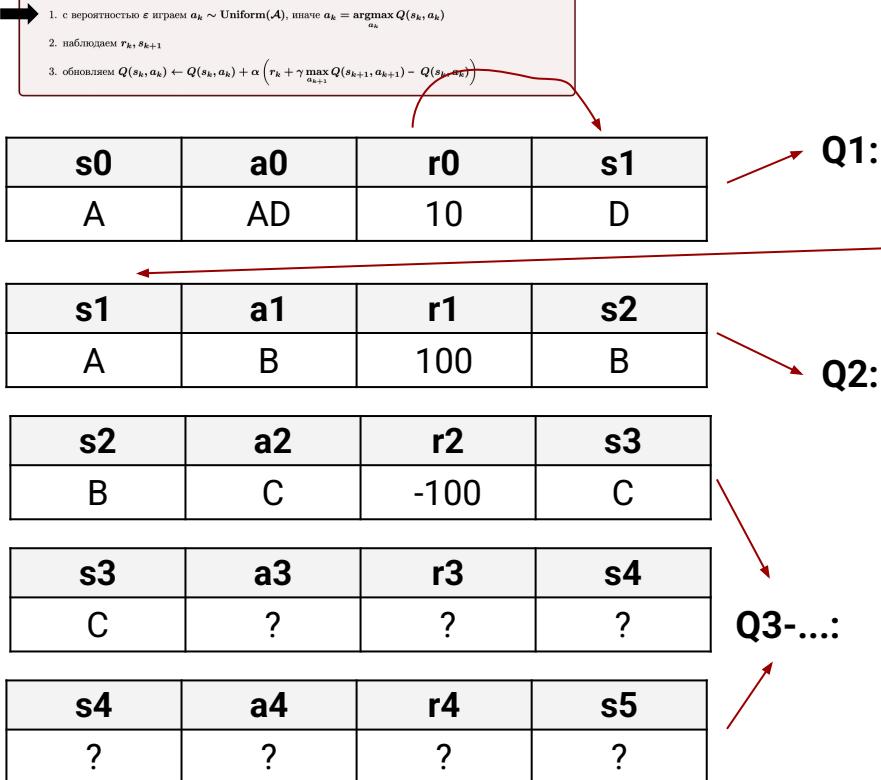
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

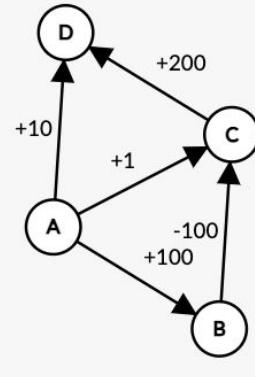
	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q2:

	A	B	C	D
A	✗	100	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q3-....:

	A	B	C	D
A	✗	100	0	10
B	✗	✗	-100	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

s_0	a_0	r_0	s_1
A	AD	10	D

s_1	a_1	r_1	s_2
A	B	100	B

s_2	a_2	r_2	s_3
B	C	-100	C

s_3	a_3	r_3	s_4
C	D	?	?

s_4	a_4	r_4	s_5
?	?	?	?

Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

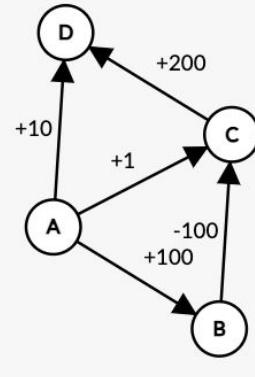
	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q2:

	A	B	C	D
A	✗	100	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q3-....:

	A	B	C	D
A	✗	100	0	10
B	✗	✗	-100	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

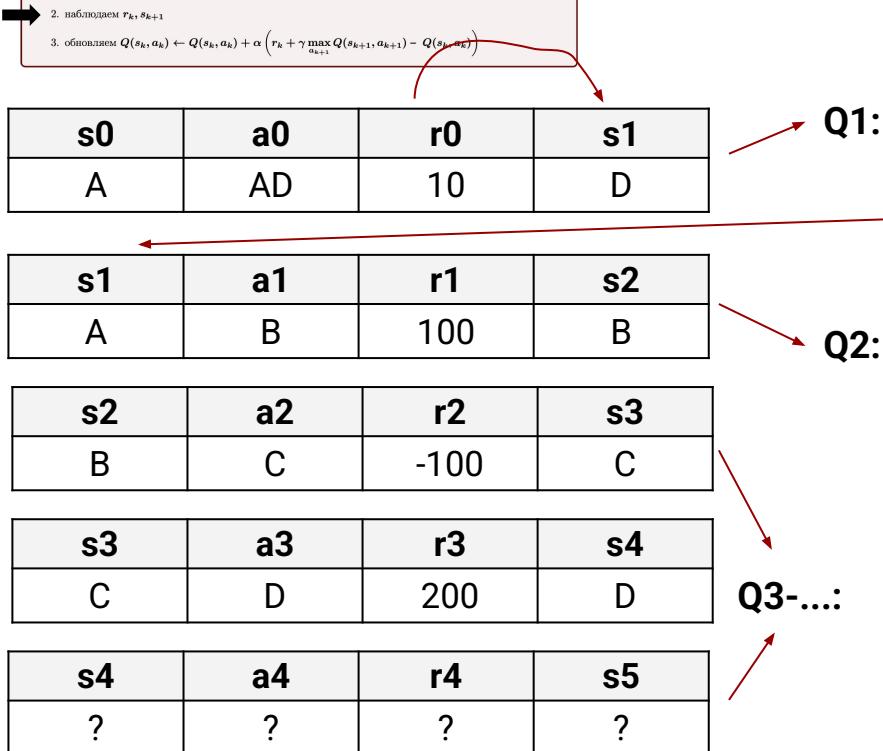
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



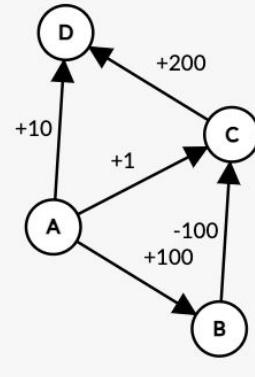
Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	-100	X
C	X	X	X	0
D	X	X	X	X



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

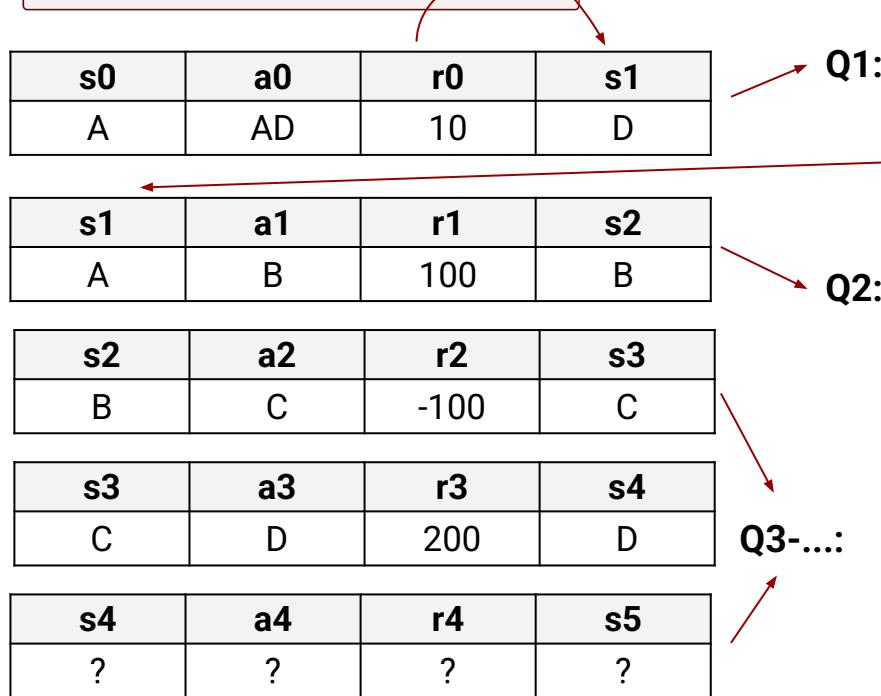
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



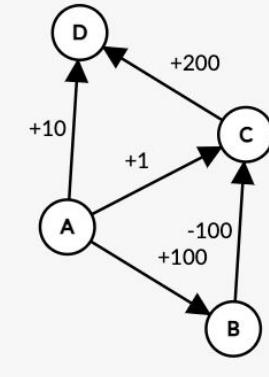
Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X



Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

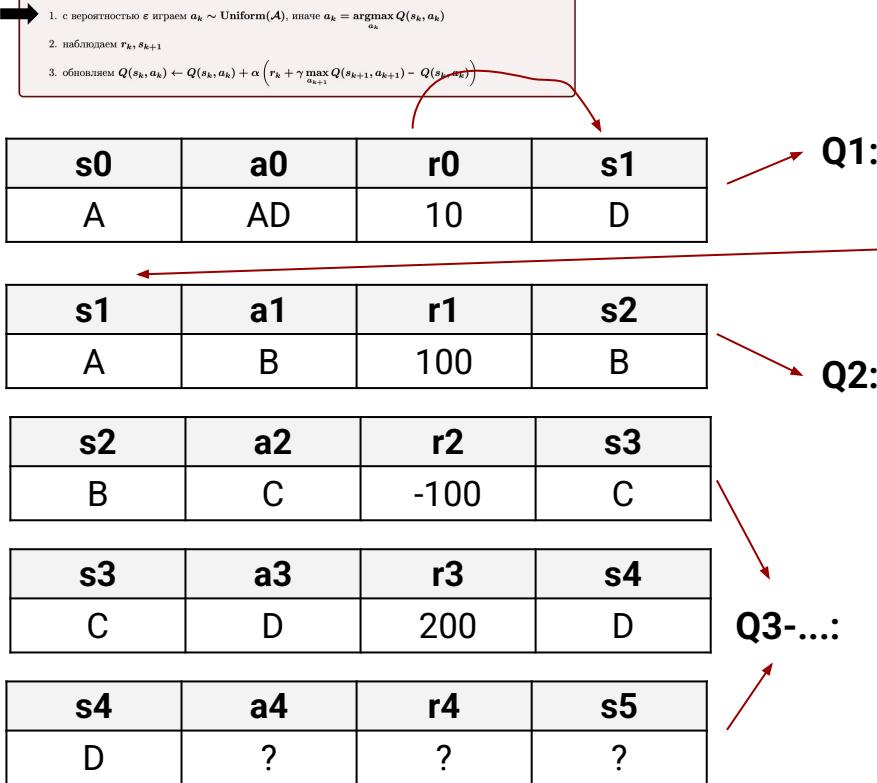
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

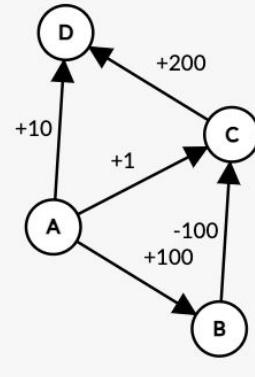


	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

	A	B	C	D
A	X	100	0	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

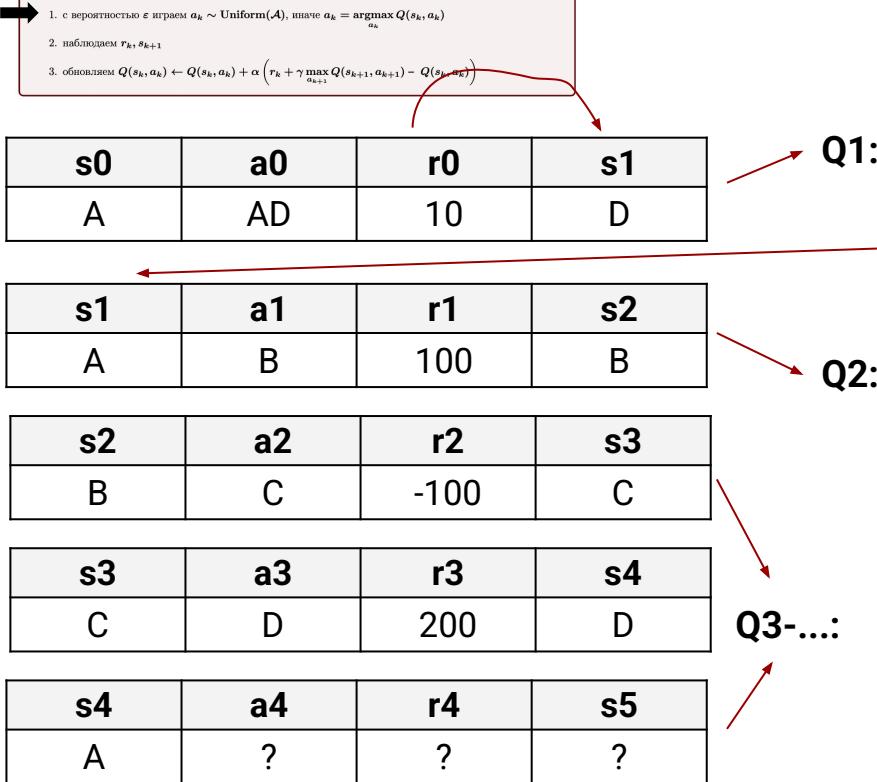
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

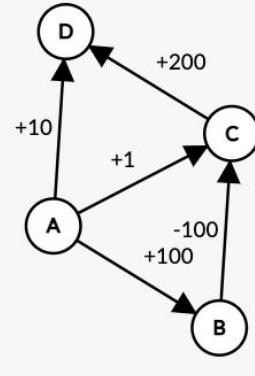


	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

	A	B	C	D
A	✗	100	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

	A	B	C	D
A	✗	100	0	10
B	✗	✗	-100	✗
C	✗	✗	✗	200
D	✗	✗	✗	✗



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



s_0	a_0	r_0	s_1
A	AD	10	D

Q0:

	A	B	C	D
A	X	0	0	0
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q1:

	A	B	C	D
A	X	0	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

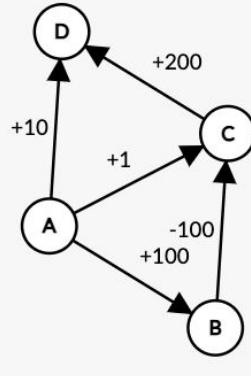
Q2:

	A	B	C	D
A	X	100	0	10
B	X	X	0	X
C	X	X	X	0
D	X	X	X	X

Q3-....:

s_3	a_3	r_3	s_4
C	D	200	D

s_4	a_4	r_4	s_5
A	B	?	?



	A	B	C	D
A	X	100	0	10
B	X	X	-100	X
C	X	X	X	200
D	X	X	X	X

Остальное будем менять
прямо тут



Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

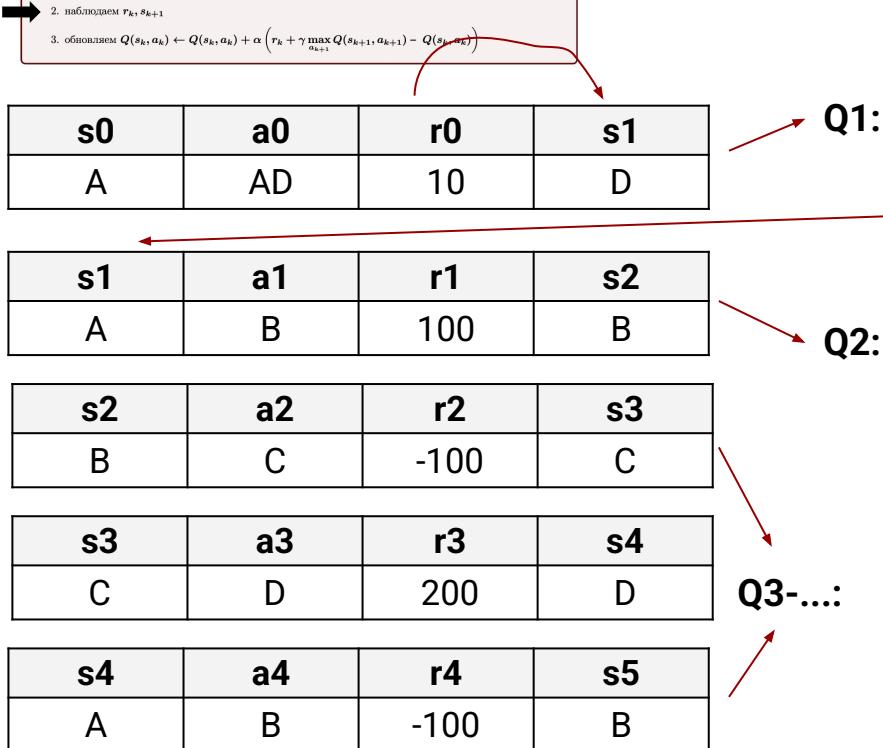
Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$



Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

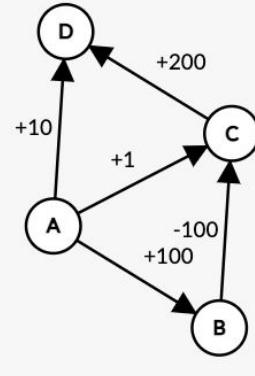
	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q2:

	A	B	C	D
A	✗	100	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q3-....:

	A	B	C	D
A	✗	100	0	10
B	✗	✗	-100	✗
C	✗	✗	✗	200
D	✗	✗	✗	✗



Остальное будем менять
прямо тут

Задание 7. $\epsilon=0$ $\gamma=1.0$ $\alpha=1$

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального слаживания, ϵ — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ϵ играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

s_0	a_0	r_0	s_1
A	AD	10	D

s_1	a_1	r_1	s_2
A	B	100	B

s_2	a_2	r_2	s_3
B	C	-100	C

s_3	a_3	r_3	s_4
C	D	200	D

s_4	a_4	r_4	s_5
A	B	-100	B

Q0:

	A	B	C	D
A	✗	0	0	0
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q1:

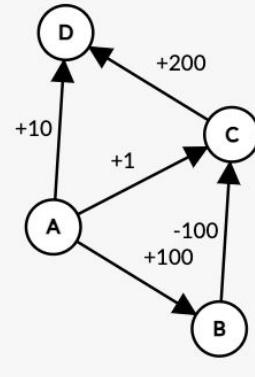
	A	B	C	D
A	✗	0	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

Q2:

	A	B	C	D
A	✗	100	0	10
B	✗	✗	0	✗
C	✗	✗	✗	0
D	✗	✗	✗	✗

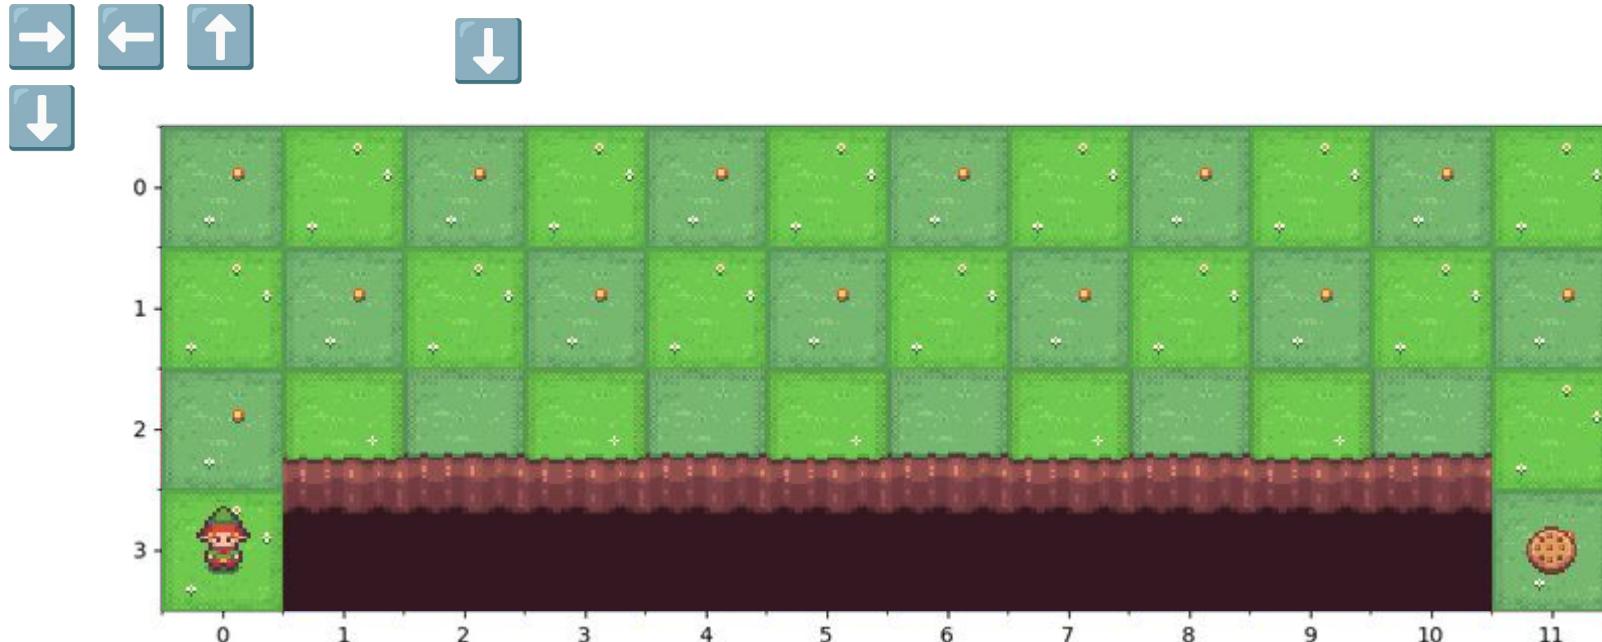
Q3-....:

	A	B	C	D
A	✗	0	0	10
B	✗	✗	-100	✗
C	✗	✗	✗	200
D	✗	✗	✗	✗

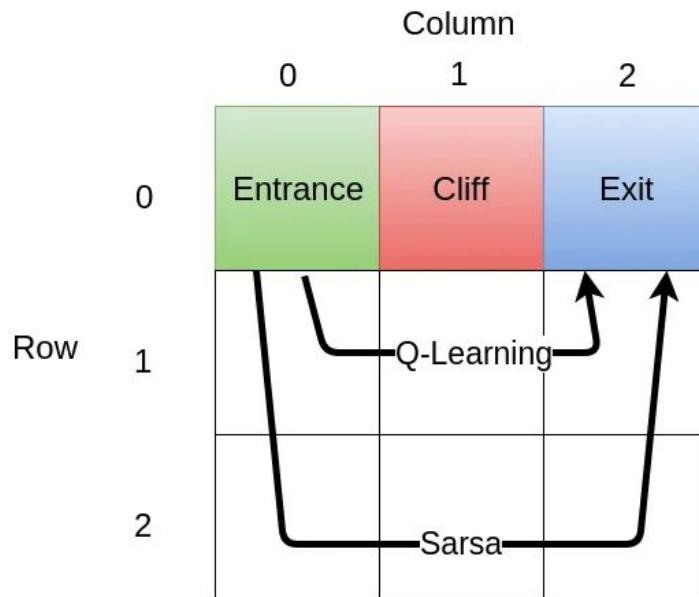


Остальное будем менять
прямо тут

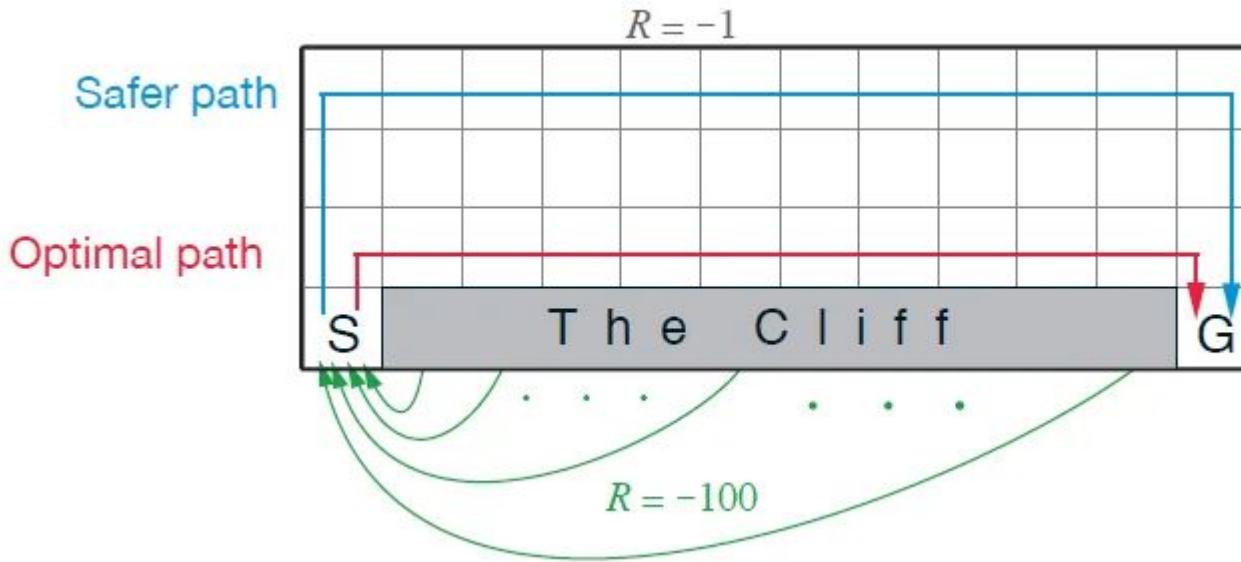
Cliff World



Cliff World



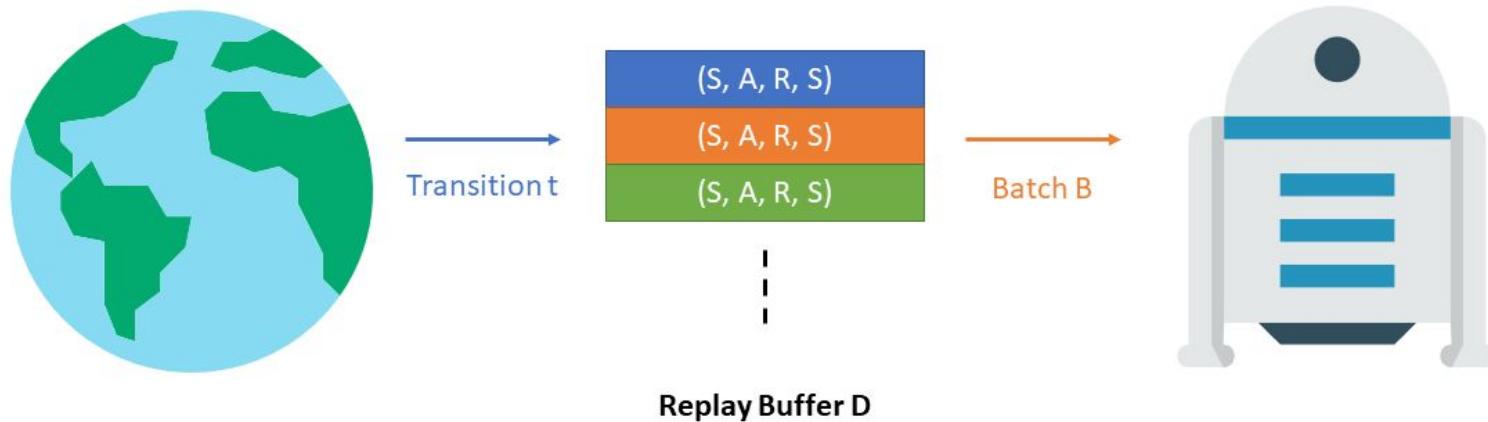
Cliff World



<https://awjuliani.github.io/web-rl-playground>

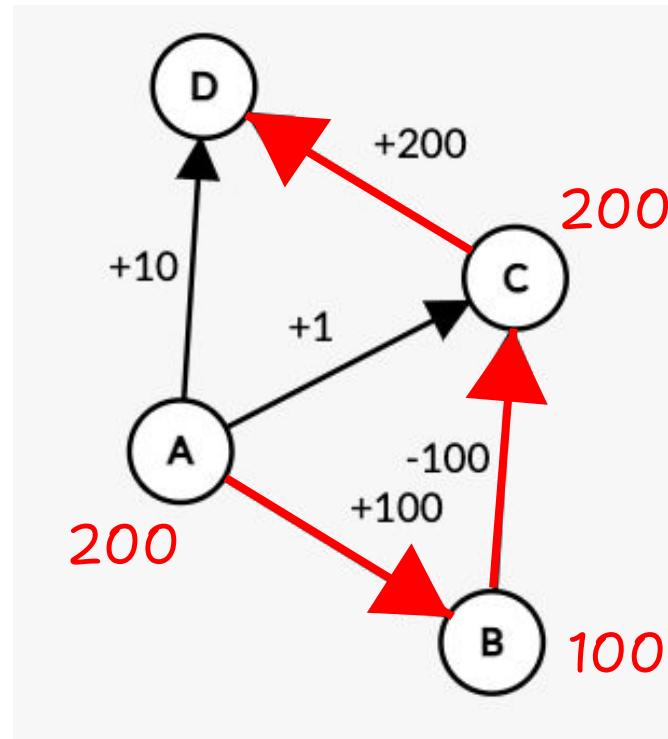
Реплей буфер

Replay buffer, experience replay – это память со всеми собранными агентом переходами ($s, a, r, s_0, \text{done}$)

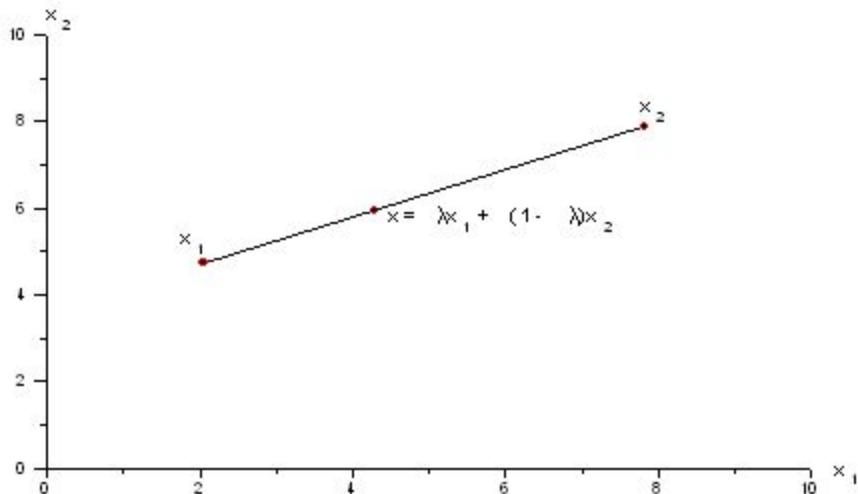


Проблемы

1. Если политика не включала ребро, то нет шансов включить его в **target policy**.
2. Нужно доигрывать эпизоды до конца
3. Теряем кучу информации на пересечениях
4. В текущем значении Q уже содержится много информации. Жалко ее терять



Выпуклая комбинация

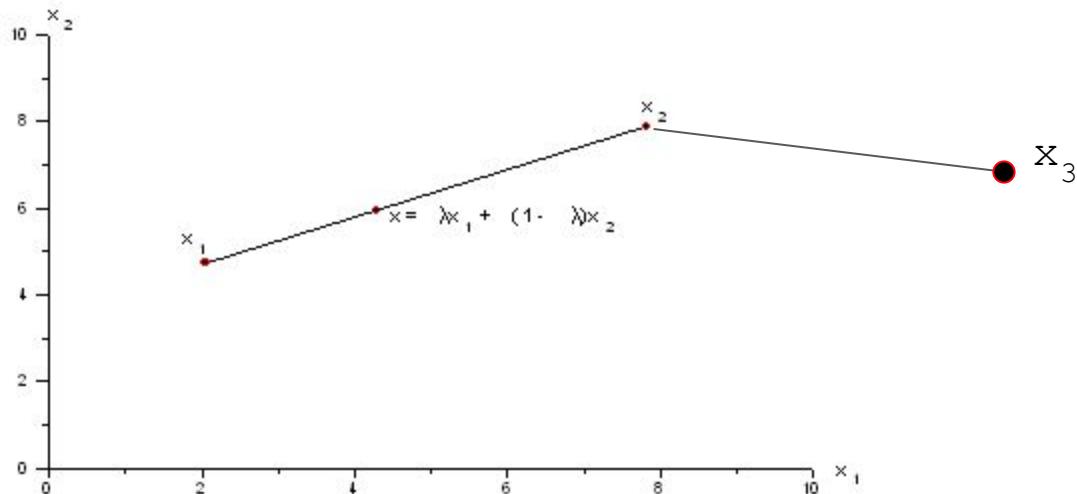


<https://www.geogebra.org/m/WBU57uED>

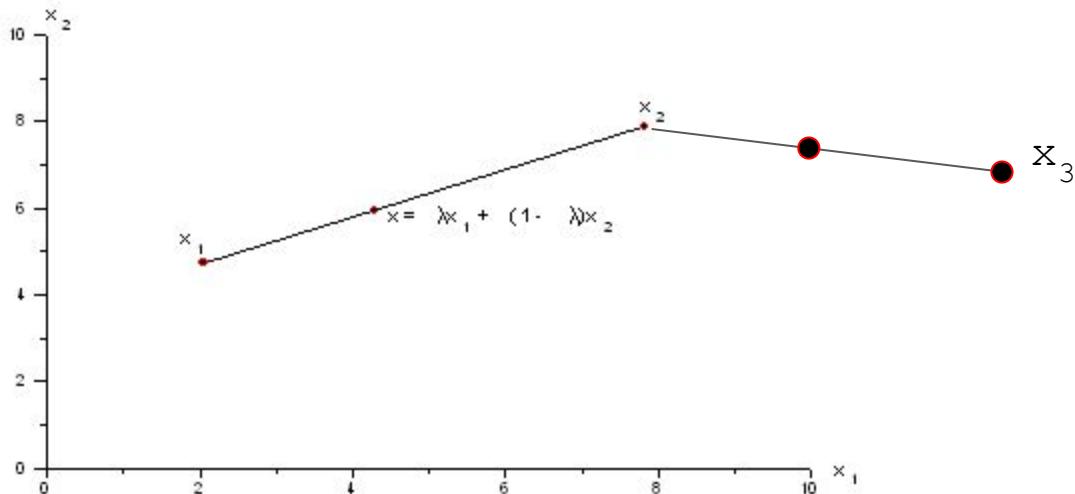
<https://www.geogebra.org/m/rtrqmkyq>



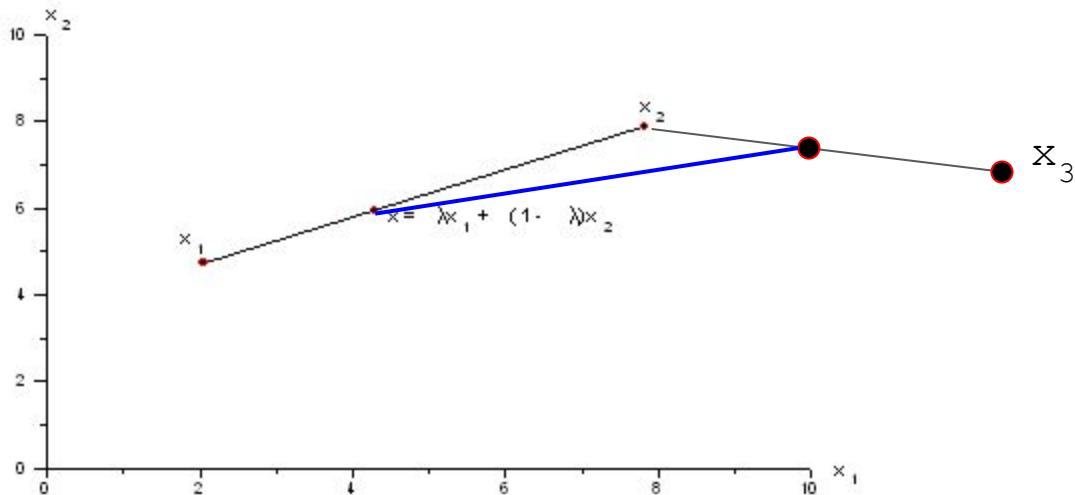
Выпуклая комбинация



Выпуклая комбинация

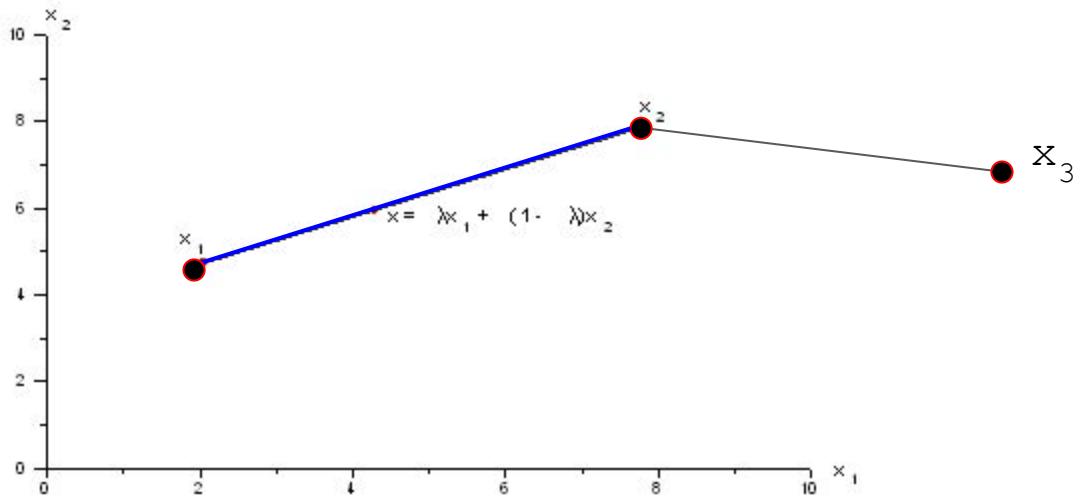


Выпуклая комбинация



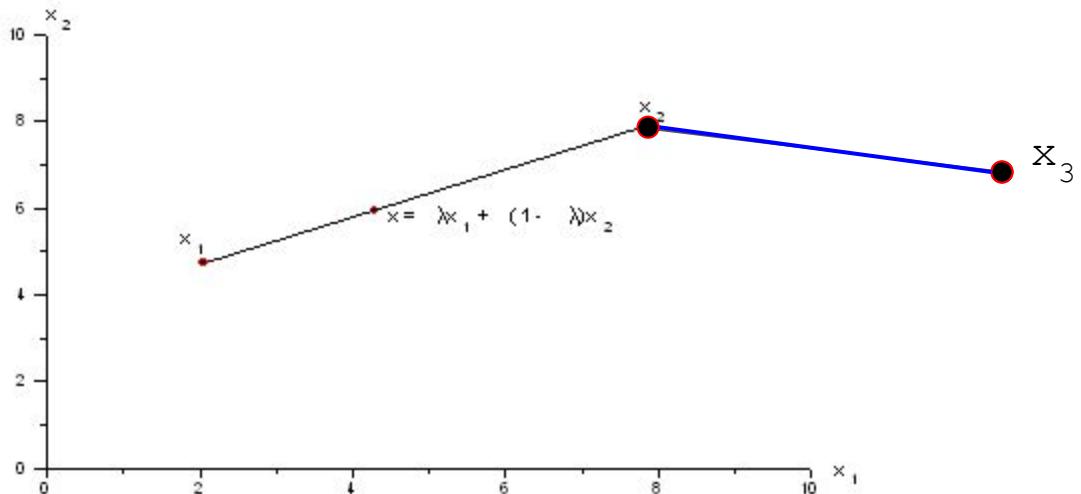
Выпуклая комбинация

$\lambda = 1$

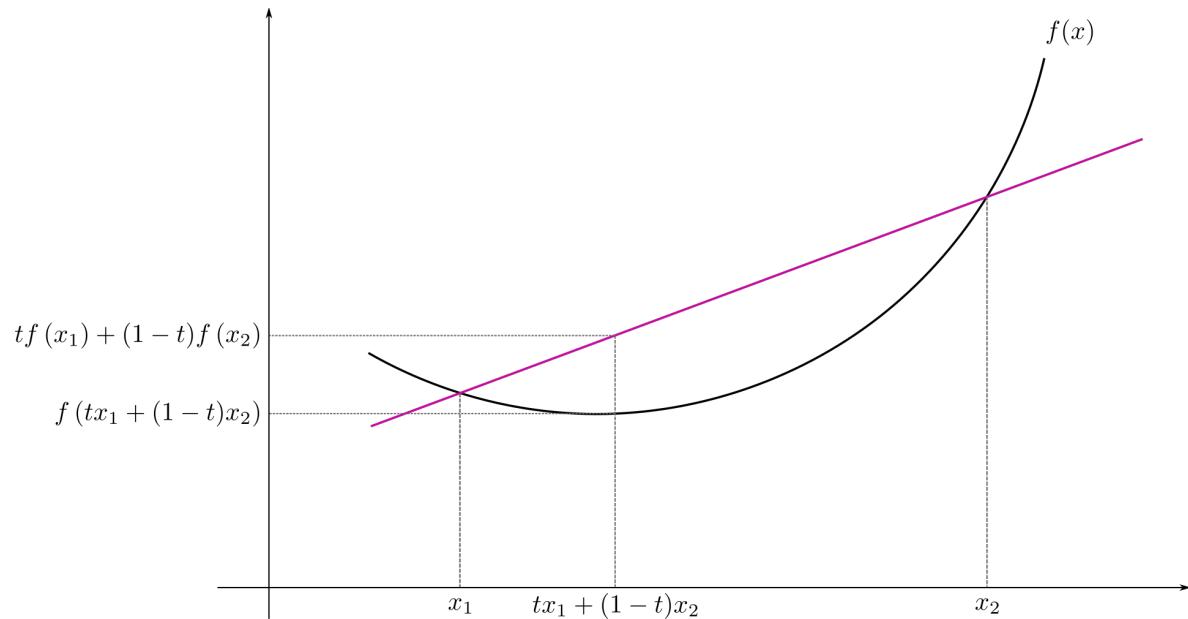


Выпуклая комбинация

$$\lambda = 0$$

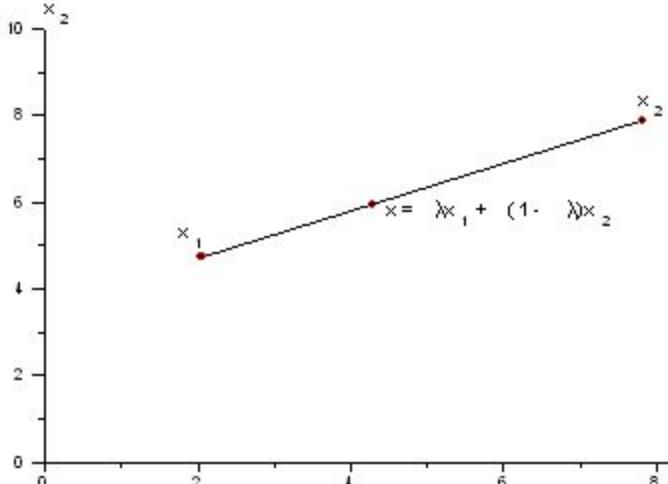


Выпуклая комбинация



Экспоненциальное сглаживание

в



<https://www.geogebra.org/>

Рис. 12

α_k

$$\frac{k-1}{k}m_{k-1} + \frac{1}{k}x_k$$

$$\alpha_k := \frac{1}{k}$$

$$m_{k-1} + \alpha_k x_k$$





Q-learning

$$Q_{k+1}(s, a) \leftarrow Q_k(s, a) + \alpha_k \underbrace{\left(\overbrace{r + \gamma Q_k(s', a')}^{\text{target}} - Q_k(s, a) \right)}_{\text{временная разность}}$$



Q-learning

$$Q_{k+1}(s, a) \leftarrow Q_k(s, a) + \alpha_k \left(\overbrace{r + \gamma Q_k(s', a')}^{\text{target}} - Q_k(s, a) \right)$$

временная разность
temporal difference

learning rate

The diagram illustrates the Q-learning update rule. The equation is $Q_{k+1}(s, a) \leftarrow Q_k(s, a) + \alpha_k \left(\overbrace{r + \gamma Q_k(s', a')}^{\text{target}} - Q_k(s, a) \right)$. A brace under the equation groups the terms $r + \gamma Q_k(s', a')$ and $-Q_k(s, a)$ as "temporal difference". A dashed arrow points from the word "learning rate" to the coefficient α_k .



Q-learning

Алгоритм 10: Q-learning

Гиперпараметры: α — параметр экспоненциального сглаживания, ε — параметр исследований

Инициализируем $Q(s, a)$ произвольно для всех $s \in \mathcal{S}, a \in \mathcal{A}$

Наблюдаем s_0

На k -ом шаге:

1. с вероятностью ε играем $a_k \sim \text{Uniform}(\mathcal{A})$, иначе $a_k = \underset{a_k}{\operatorname{argmax}} Q(s_k, a_k)$

2. наблюдаем r_k, s_{k+1}

3. обновляем $Q(s_k, a_k) \leftarrow Q(s_k, a_k) + \alpha \left(r_k + \gamma \max_{a_{k+1}} Q(s_{k+1}, a_{k+1}) - Q(s_k, a_k) \right)$

$$Q_{k+1}(s, a) \leftarrow Q_k(s, a) + \alpha_k \underbrace{\left(\overbrace{r + \gamma Q_k(s', a')}^{\text{таргет}} - Q_k(s, a) \right)}_{\text{временная разность}}$$

Резюме

Классификация

Классификация №1

1. Model free
2. Model based

Классификация №3

1. On-policy
2. Off-policy

Классификация №2

1. Value based
2. Policy based

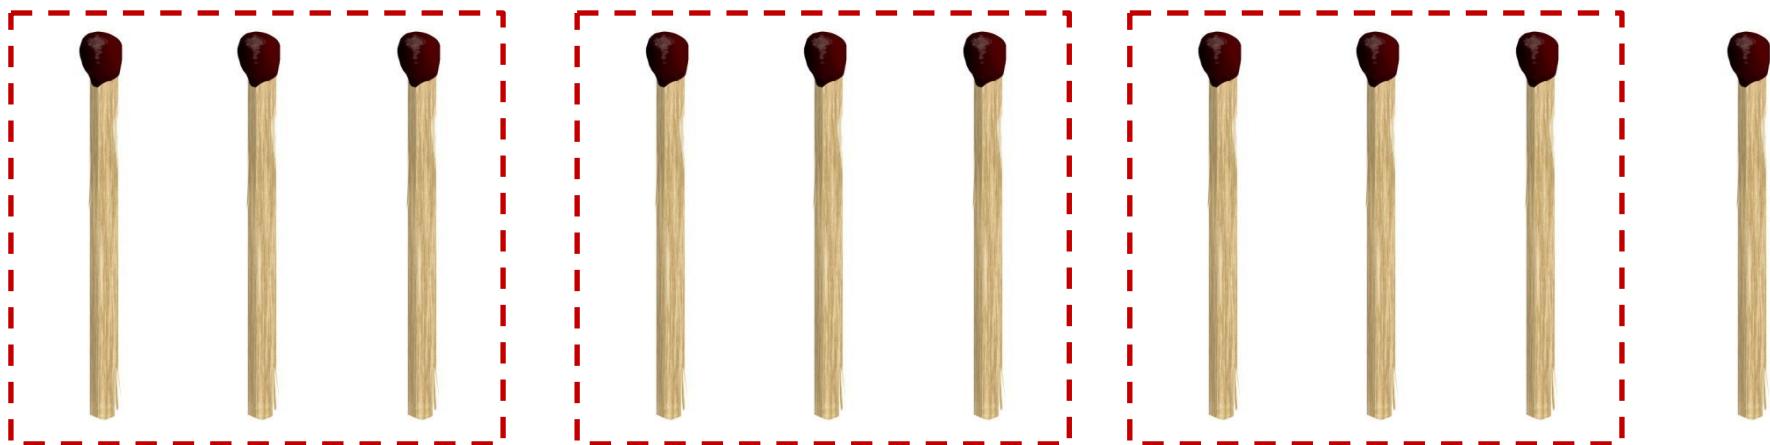
Способ 1

Вообще в этой игре существует выигрышная стратегия для первого игрока. Т.к. вне зависимости от ходов второго, первый может выиграть.

Способ 1

Достаточно первым ходом взять одну палочку, а дальше дополнять ход соперника до трёх палочек.

Что это значит?

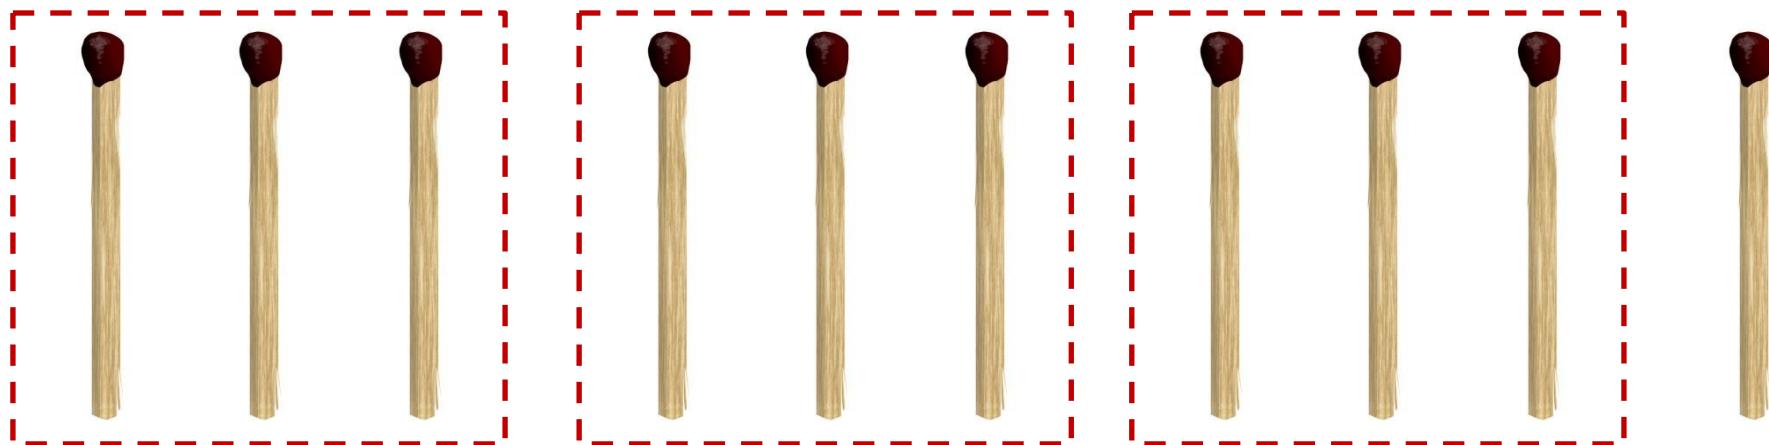


Способ 1

Алгоритм

Если соперник взял 1 палочку – бери ____

Если соперник взял 2 палочки – бери ____



Способ 2

А теперь попробуем создать «искусственный интеллект», который будет сам учиться выигрышной стратегии без наших подсказок.

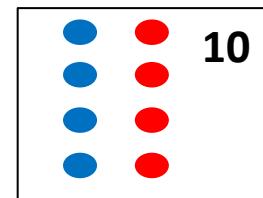
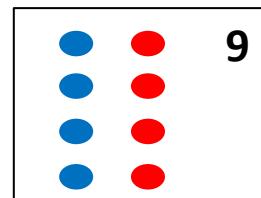
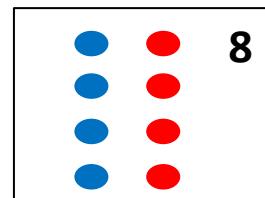
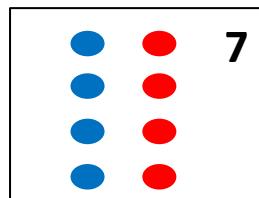
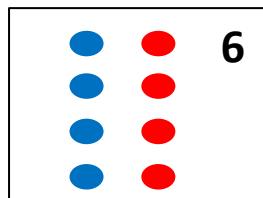
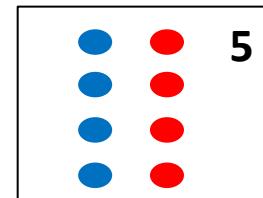
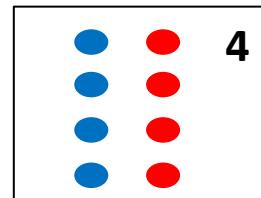
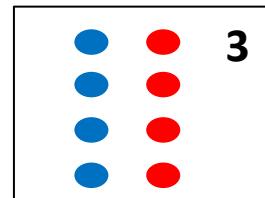
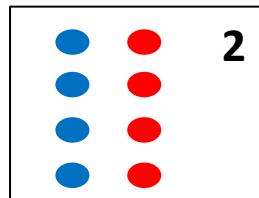
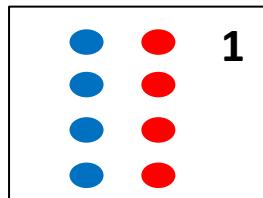


Способ 2

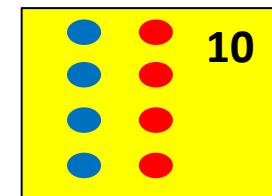
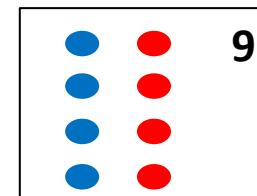
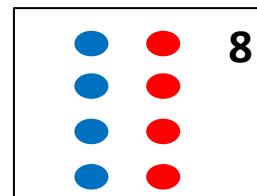
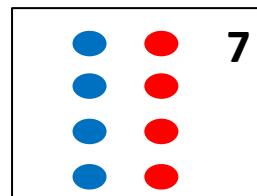
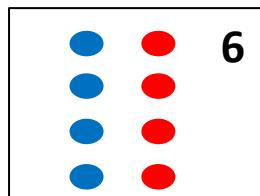
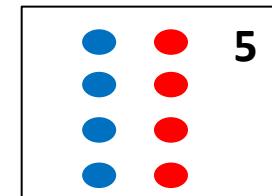
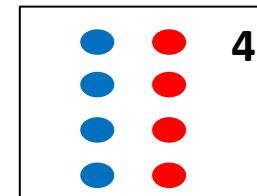
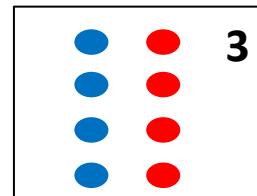
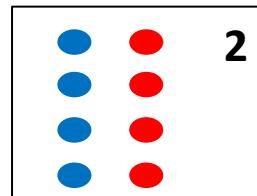
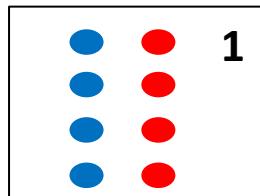
Для этого даже не понадобится компьютер.

Способ 2

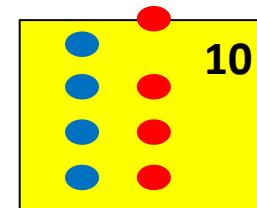
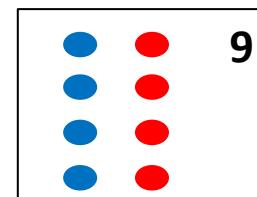
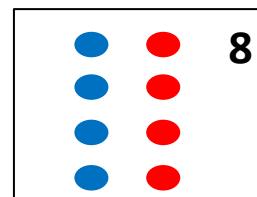
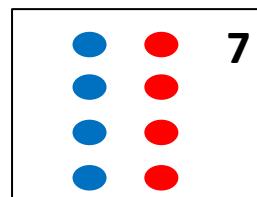
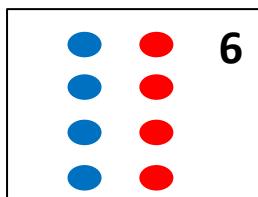
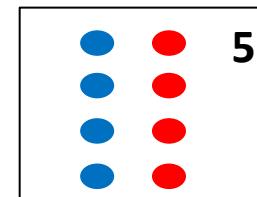
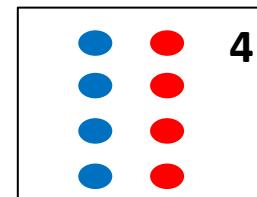
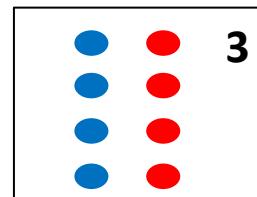
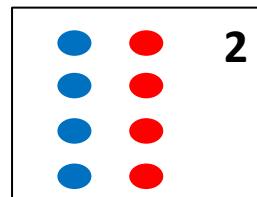
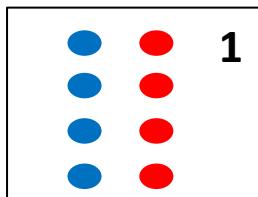
- Всего перед ходом игрока может оказаться 10 вариантов количества палочек на столе: 1, 2, 3, ..., 10.
- Поэтому возьмем 10 коробочек и промаркируем их числами от 1 до 10.
- В каждую из них положим 4 красных и 4 синих пуговицы.



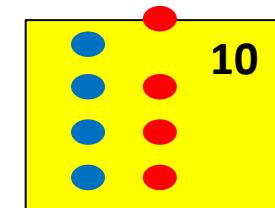
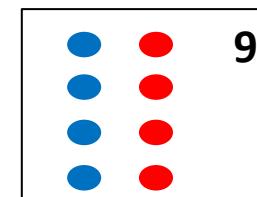
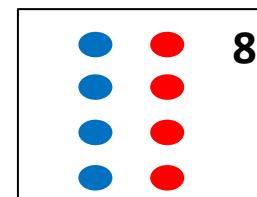
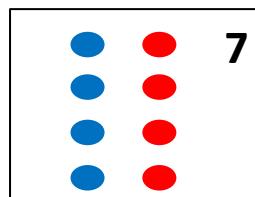
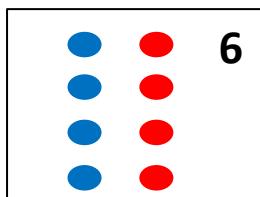
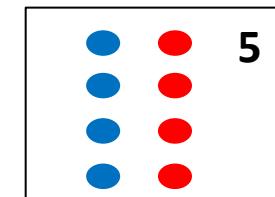
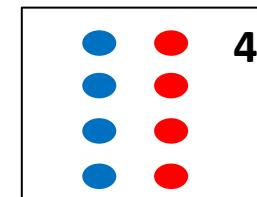
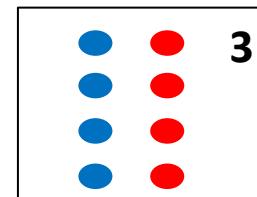
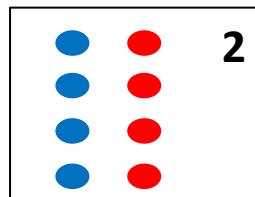
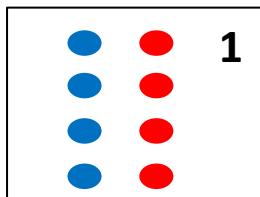
- Перед нами 10 палочек, поэтому возьмем 10-ую коробку и вытащим не глядя одну пуговицу. Если она будет синей – возьмем 1 палочку, если красной, то



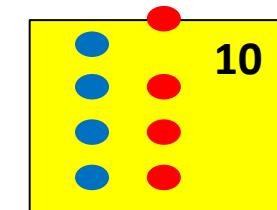
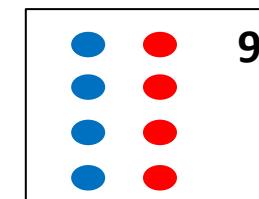
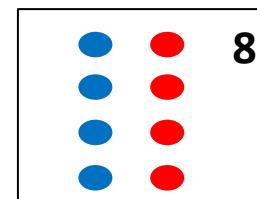
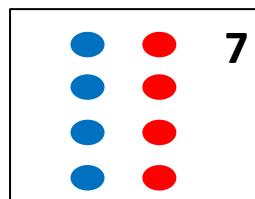
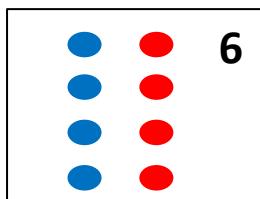
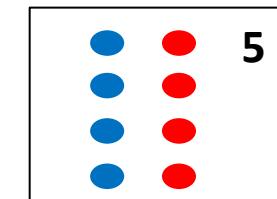
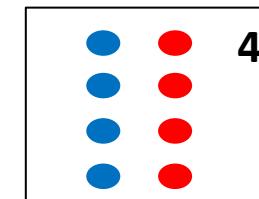
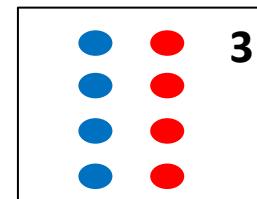
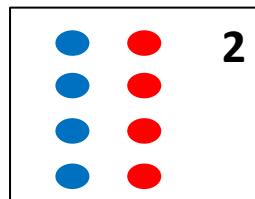
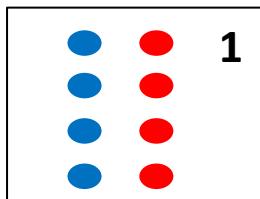
- Перед нами 10 палочек, поэтому возьмем 10-ую коробку и вытащим не глядя одну пуговицу. Если она будет синей – возьмем 1 палочку, если красной, то



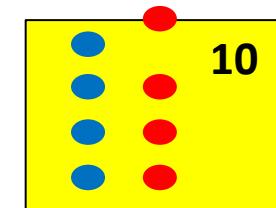
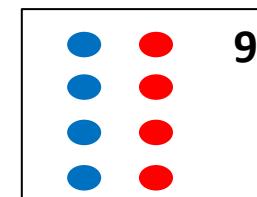
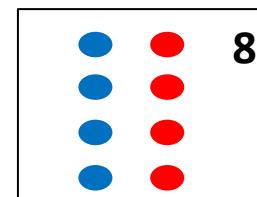
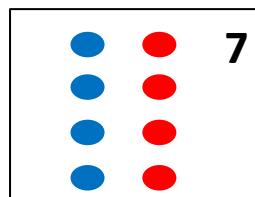
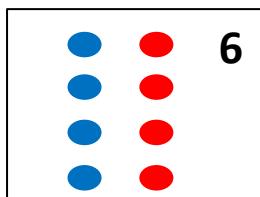
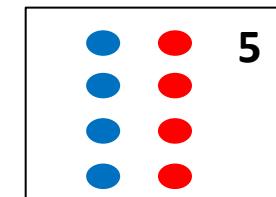
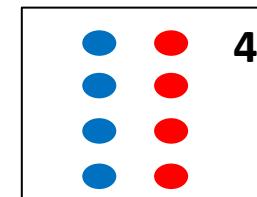
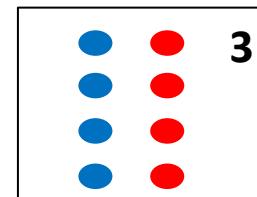
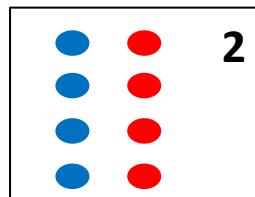
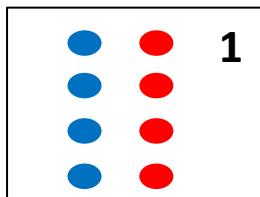
- Перед нами 10 палочек, поэтому возьмем 10-ую коробку и вытащим не глядя одну пуговицу. Если она будет синей – возьмем 1 палочку, если красной, то



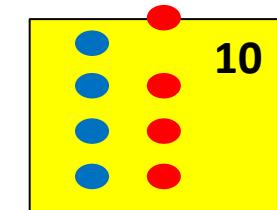
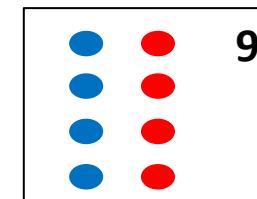
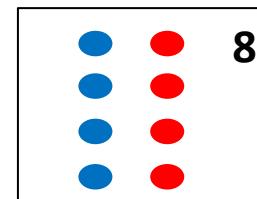
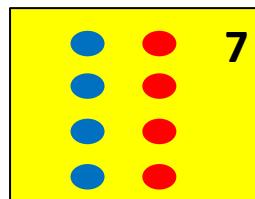
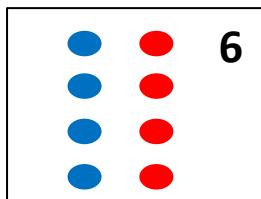
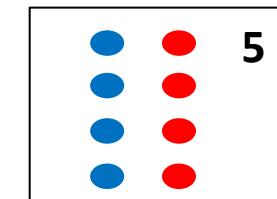
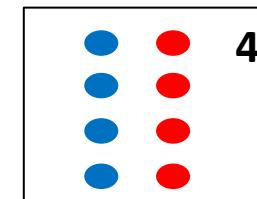
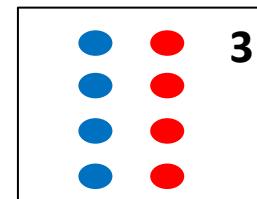
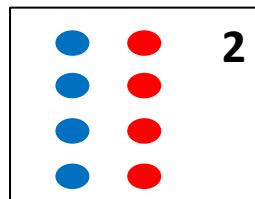
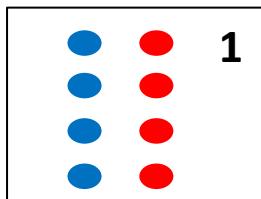
- Теперь ходит первый игрок. Допусти он возьмёт одну палочку.



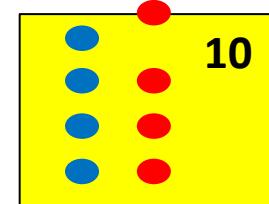
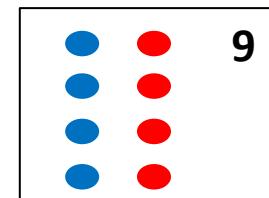
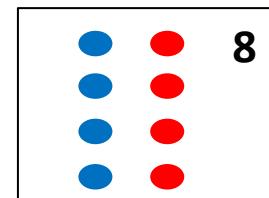
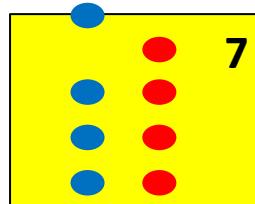
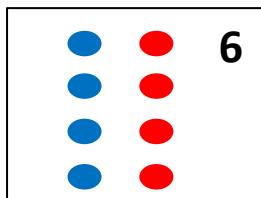
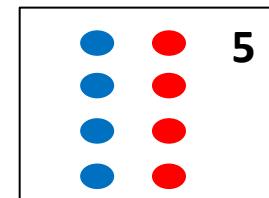
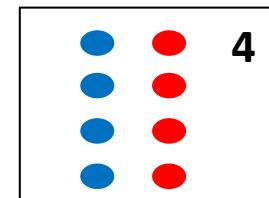
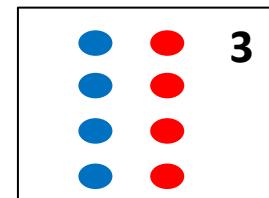
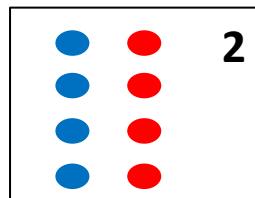
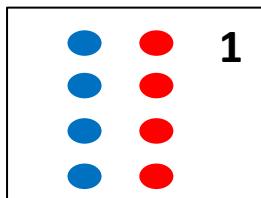
- Теперь ходит первый игрок. Допусти он возьмёт одну палочку.



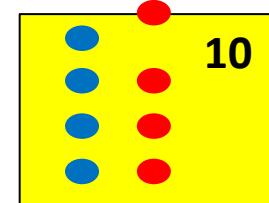
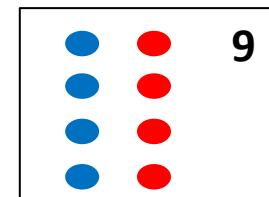
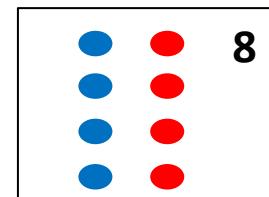
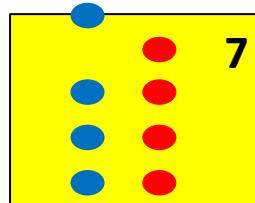
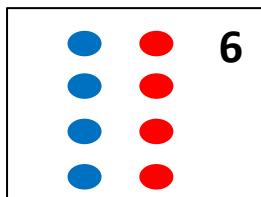
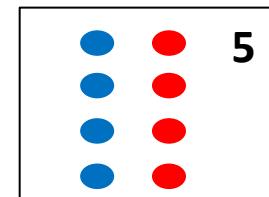
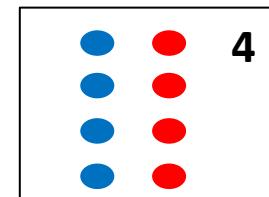
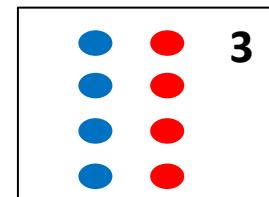
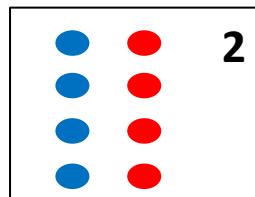
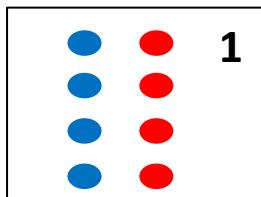
- Перед нами 7 палочек. Поэтому возьмём седьмую коробку.



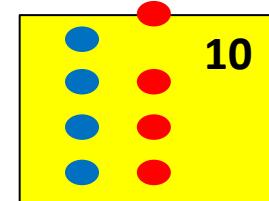
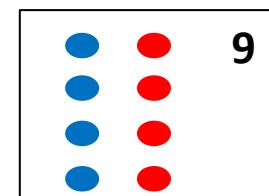
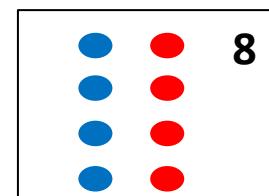
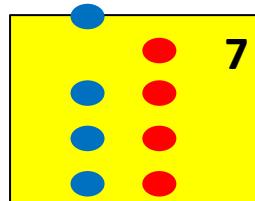
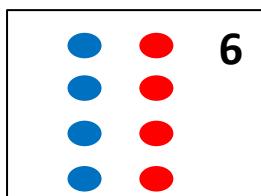
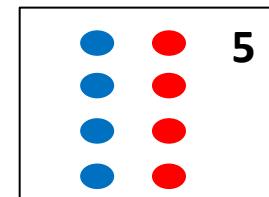
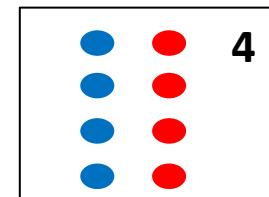
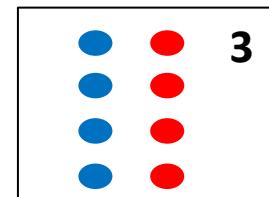
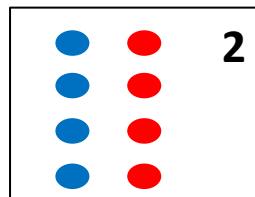
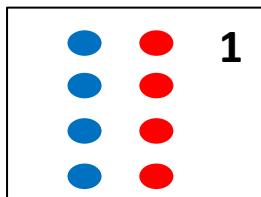
- Вытащим наугад пуговицу



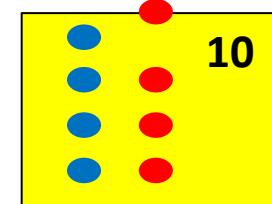
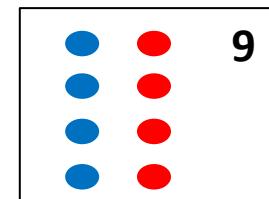
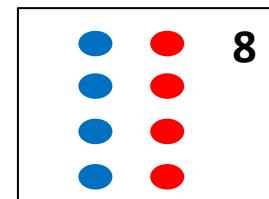
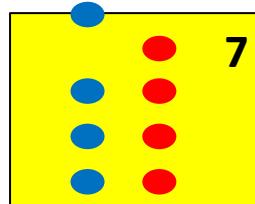
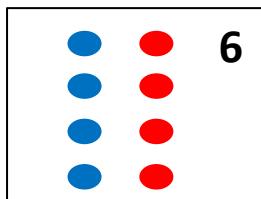
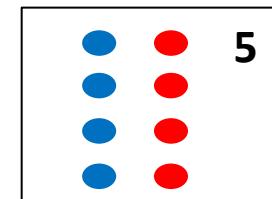
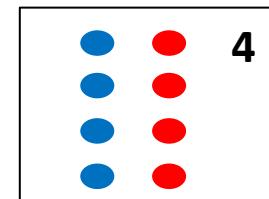
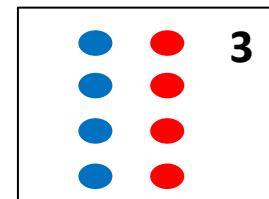
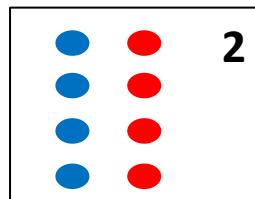
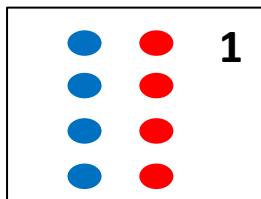
- Сходим



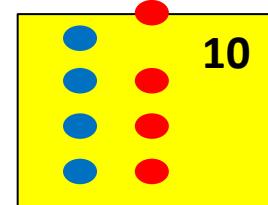
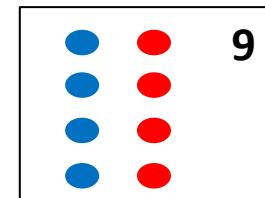
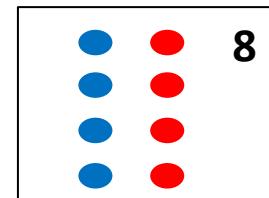
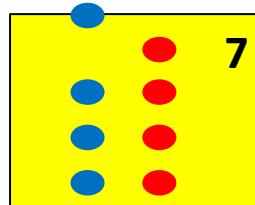
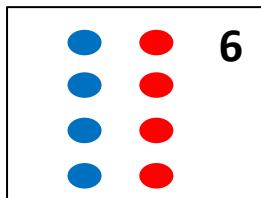
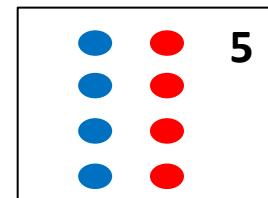
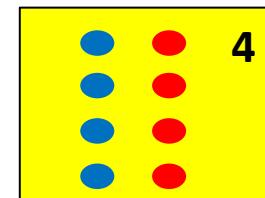
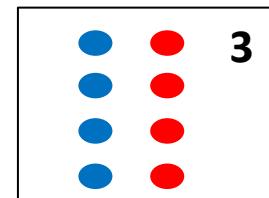
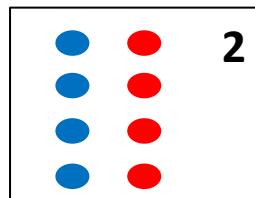
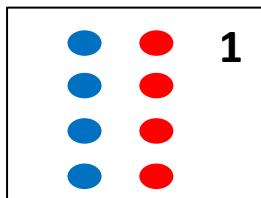
- Допустим игрок возьмёт 2 палочки.



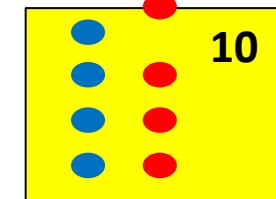
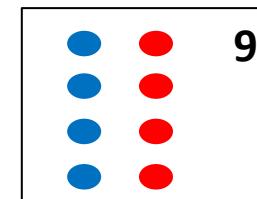
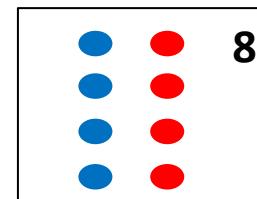
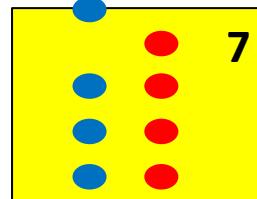
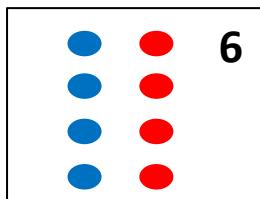
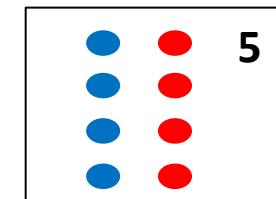
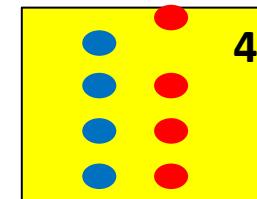
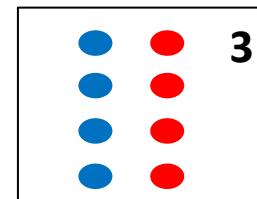
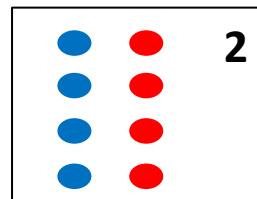
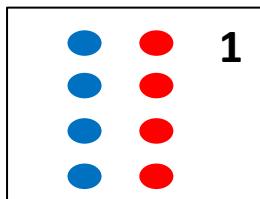
- Допустим игрок возьмёт 2 палочки.



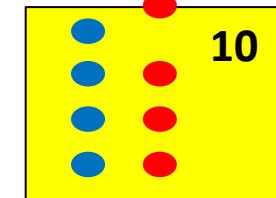
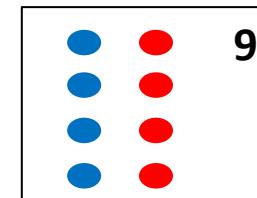
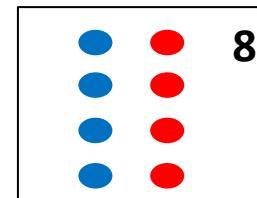
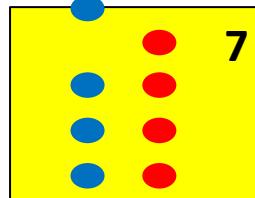
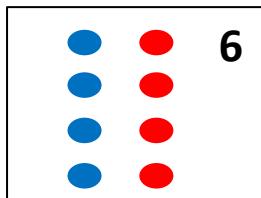
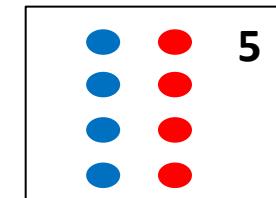
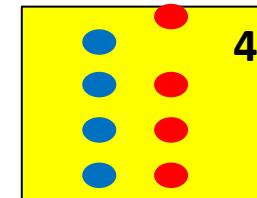
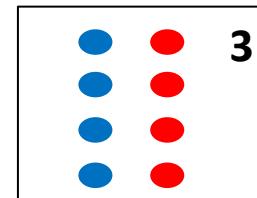
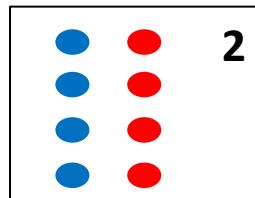
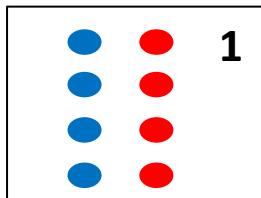
- Перед нами 4 палочки. Берём коробку №4



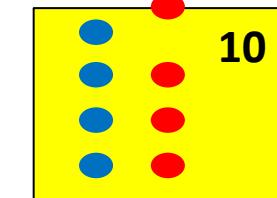
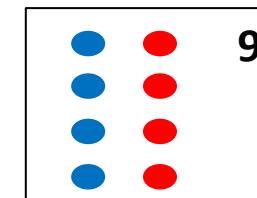
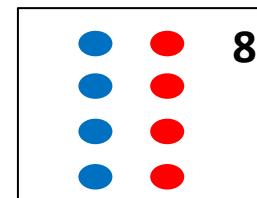
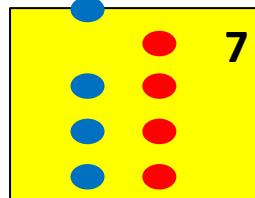
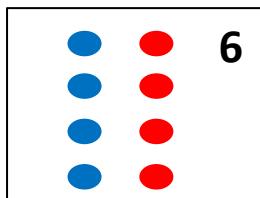
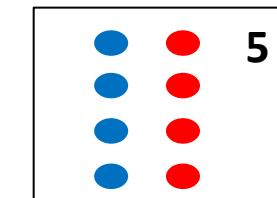
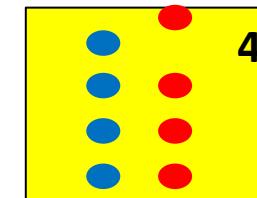
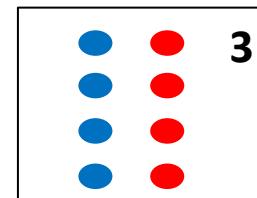
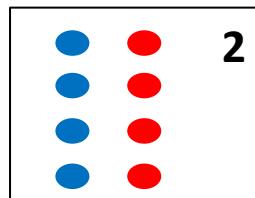
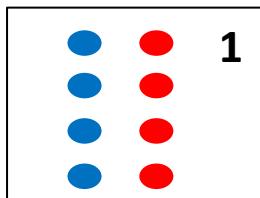
- Тянем пуговицу.



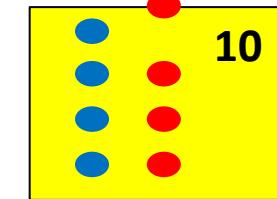
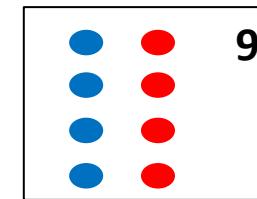
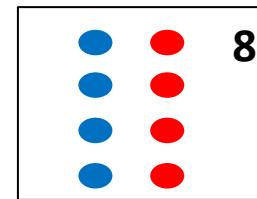
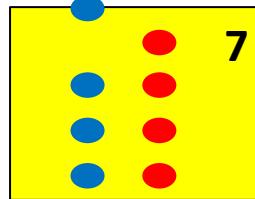
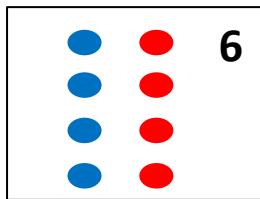
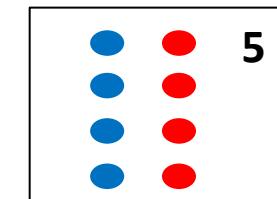
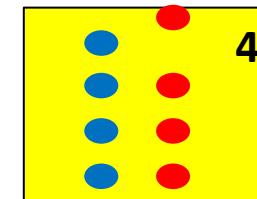
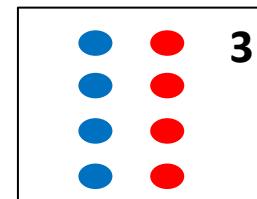
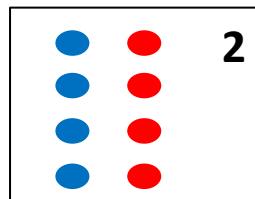
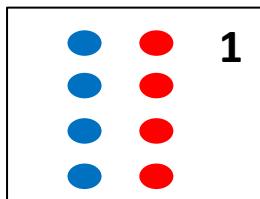
- Делаем ход.



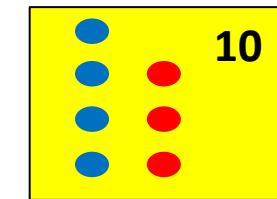
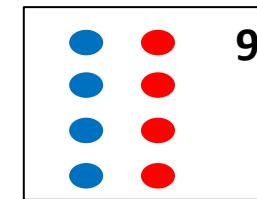
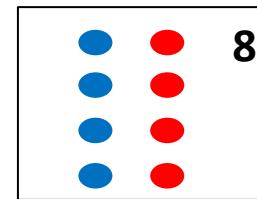
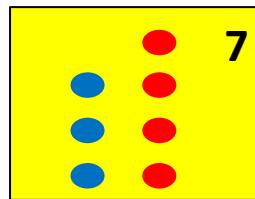
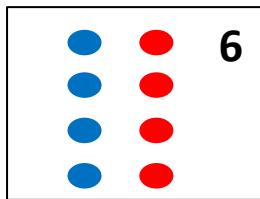
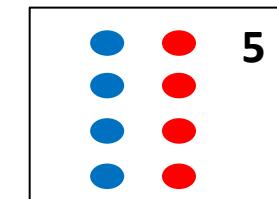
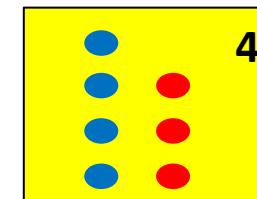
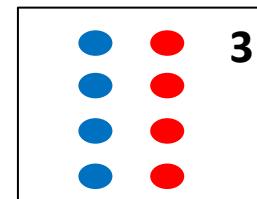
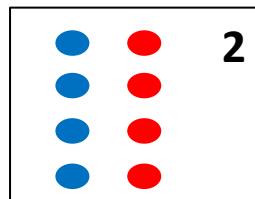
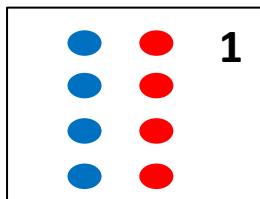
- Первый игрок выигрывает! А наш искусственный интеллект проигрывает



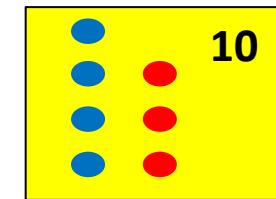
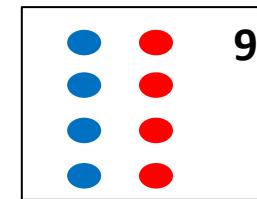
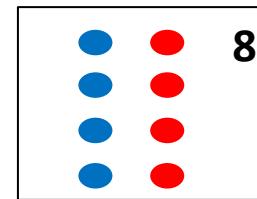
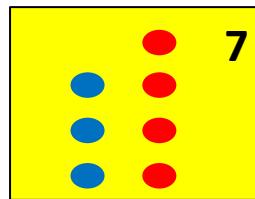
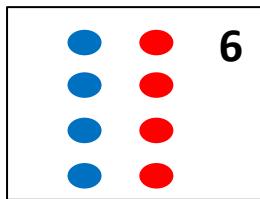
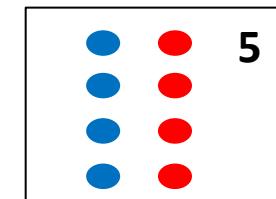
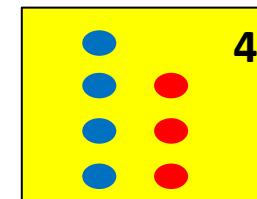
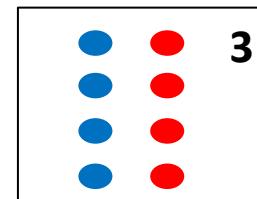
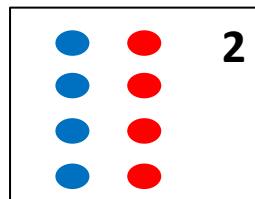
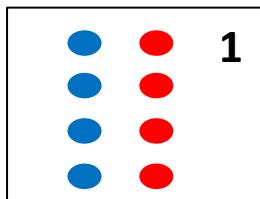
- Поэтому накажем его. И из всех коробочек, с которыми мы работали заберем пуговицы, которые привели нас к проигрышу.



- Поэтому накажем его. И из всех коробочек, с которыми мы работали заберем пуговицы, которые привели нас к проигрышу.

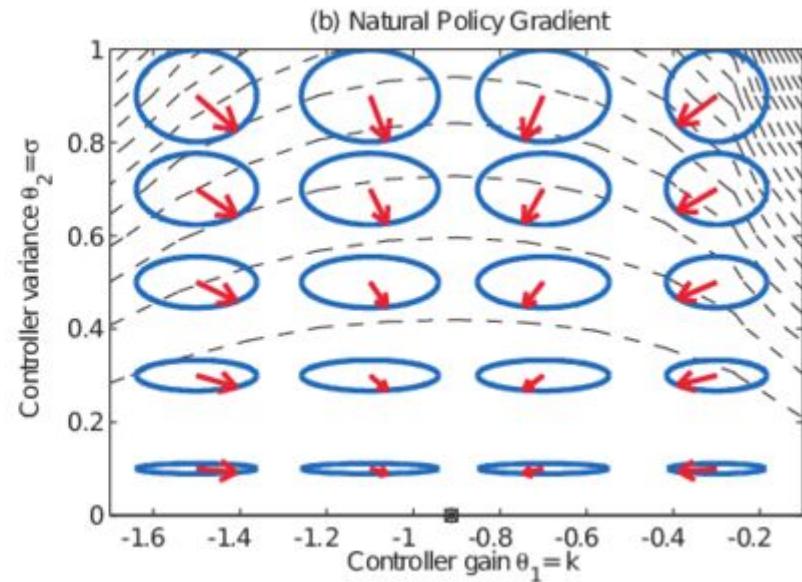
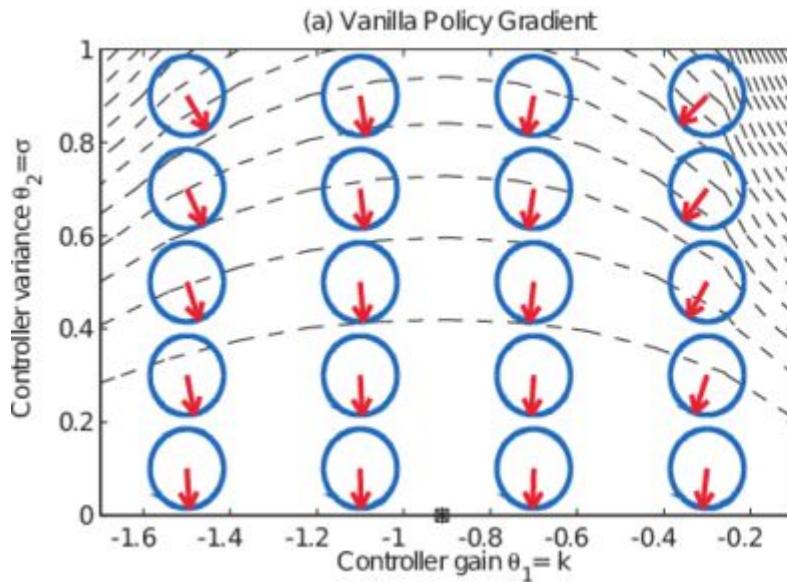


- Если бы мы выиграли – мы бы наоборот добавили по пуговице того цвета, которая привела нас к победе.



Policy gradient vs. Natural policy gradient

Адаптивные шаги!



Классификация

Классификация №1

1. Model free
2. Model based

Классификация №3

1. On-policy
2. Off-policy

Классификация №2

1. Value based
2. Policy based



План

- Buffer replay
- TD = temporal difference
- E-greedy
- Q-learning
- SARSA

Опрос в конце: <https://otus.ru/polls/141248/>

Дисклаймер: В презентации использованы личные
материалы **@dmi3eva**.

Образовательная площадка **Otus** не несет за них
ответственность.